

Identificazione e Stima

Appunti del corso (Prof. Costanzi)

A.A. 2025/2026

Indice

1	Introduzione all'identificazione e alla predizione	3
1.1	Identificazione	3
1.2	Errore di predizione	3
2	Processi stocastici	5
2.1	Caratterizzazione attraverso momenti	5
2.2	Processi stazionari (in senso lato, PSS)	6
2.3	Rumore bianco (WN)	6
3	Processi MA, AR e ARMA	7
3.1	Processo MA (Moving Average (Media Mobile)	7
3.2	Processo AR (Auto Regressivo), $AR(n)$ (di ordine n)	9
3.3	Processo ARMA(n_a, n_c)	11
4	Caratterizzazione in frequenza	11
4.1	Densità spettrale (di potenza)	11
4.2	Spettro (complesso)	12
4.3	Teorema fondamentale dell'analisi spettrale	13
4.4	Dimostrazione del teorema fondamentale dell'analisi spettrale	14
5	Caratteristiche statistiche e spettrali da dati (realizzazione)	15
5.1	Stima della media	15
5.2	Correlogramma	15
5.3	Periodogramma	16
5.4	Test di bianchezza (Anderson)	16
6	Predizione ottima	17
6.1	<i>Fake prediction problem</i> : predittore da rumore	17
6.2	Predittore ottimo dai dati	18
7	Teorema di fattorizzazione spettrale	20
8	Predizione dai dati:	22
8.1	ARMAX	26
9	Identificazione: famiglia di modelli	27
9.1	Approccio predittivo	28
9.2	Predittore in forma unificata (BJ)	30
9.3	Peculiarità del predittore (Linearità nei parametri)	31

10 Stima ai minimi quadrati (ARX/AR)	31
11 Identificabilità	32
11.1 Ingressi persistentemente eccitanti di ordine n	35
12 Stima ARMA/ARMAX: Gauss–Newton iterativo	36
13 Analisi asintotica e scenari di identificazione	40
14 Incertezza di stima	45
15 Selezione della complessità del modello	47
15.1 Processo di Cross-validazione	47
15.2 Final Prediction Error (FPE)	48
15.3 Criterio AIC (Akaike Information Criterion)	48
15.4 Criterio MDL (Minimum Description Length)	49
16 Scelta della famiglia via dati	49
17 Stima:	51
17.1 Stima statica:	51
17.2 Approccio Bayesiano:	52
17.3 Approccio Non Bayesiano:	52
17.4 Approccio Non Bayesiano con i minimi quadrati	56
18 Stima Dinamica	105
19 Recap Stima Dinamica	110
20 Filtro di Kalman – Ricapitolazione	117
21 Filtraggio non lineare	126
21.1 recap Filtraggio non lineare	133
21.2 Particle Filter (PF)	133
21.3 Ricampionamento (Resampling)	134
21.4 Rauch–Tung–Striebel Smoother	135

1 Introduzione all'identificazione e alla predizione

Organizzazione del corso

- Esame unico (si può sostenere in due appelli diversi della stessa sessione, ma è consigliato farlo in un unico appello).
- Lezioni: lunedì e giovedì.

1.1 Identificazione

Ricavare un modello che meglio rappresenti i dati osservati. Il concetto è strettamente legato al concetto di *predizione*.

Sia $v(t)$ un segnale reale a tempo discreto su t . Supponiamo di osservare la variabile agli istanti di tempo $1, 2, 3, \dots, t-1$. Vogliamo predire $v(t)$.

Definizione 1 (Predittore). $\hat{v}(t | t-1)$ è la stima all'istante t basata sulle osservazioni disponibili fino a $t-1$:

$$\hat{v}(t | t-1) = f(v(t-1), v(t-2), \dots, v(1)), \quad t > 1.$$

Una possibilità è scegliere $f(\cdot)$ lineare nelle ultime n osservazioni:

$$\hat{v}(t | t-1) = a_1 v(t-1) + a_2 v(t-2) + \dots + a_n v(t-n).$$

Il problema diventa quindi *scegliere* i coefficienti $a_1, \dots, a_n$.

Spiegazione – Perché identificazione e predizione sono collegate

In identificazione si vuole costruire un modello a partire dai dati osservati. Un modo molto naturale per giudicare se il modello è buono consiste nel chiedersi: “quanto bene riesce a predire il prossimo campione?”. Se il modello usa bene l'informazione contenuta nel passato, allora la differenza tra valore osservato e valore predetto deve contenere solo la parte nuova, cioè la parte che non era ricavabile dai dati precedenti.

Nel caso lineare, il predittore è una combinazione pesata dei campioni passati:


$$\hat{v}(t | t-1) = a_1 v(t-1) + \dots + a_n v(t-n).$$

I coefficienti a_i determinano quanta importanza dare a ciascun valore passato. Identificare il modello significa quindi scegliere questi coefficienti in modo che la previsione sia il più possibile aderente ai dati osservati.

1.2 Errore di predizione

$$\varepsilon(k) = v(k) - \hat{v}(k | k-1),$$

detto *errore di predizione*.



Sia $\bar{\varepsilon}$ la media di $\varepsilon(k)$. Migliorare la regola significa togliere $\bar{\varepsilon}$:

$$\hat{v}(k+1 | k) = a_1 v(t-1) + \dots + a_n v(t-n) - \bar{\varepsilon},$$

così da avere media nulla.

Spiegazione – Come interpretare l'errore di predizione


L'errore di predizione misura ciò che il predittore non è riuscito a spiegare:

$$\varepsilon(k) = v(k) - \hat{v}(k | k-1).$$

Se gli errori hanno una media diversa da zero, il predittore sta sbagliando sistematicamente verso l'alto o verso il basso. Per questo si cerca almeno di ottenere errori a media nulla. Ma la media nulla non basta: un errore può avere media zero e contenere comunque una struttura temporale, ad esempio alternare valori positivi e negativi in modo regolare.

L'obiettivo più forte è quindi ottenere un errore senza struttura residua. In altre parole, dopo aver predetto usando il passato, l'errore non deve essere ancora predicibile dal passato stesso. Questo porta naturalmente all'idea di rumore bianco.

Un'altra possibilità può essere:



In questo caso la media è nulla

Intuizione. Vogliamo un predittore tale per cui l'errore sia a media nulla e senza alcuna regolarità (completamente imprevedibile/impredicibile):

$$\varepsilon(k) \longrightarrow \text{rumore bianco.}$$

Supponiamo quindi di aver trovato $a_1, \dots, a_n$, ovvero un predittore tale che $\varepsilon(k)$ sia rumore bianco. Allora

$$v(t) = \hat{v}(t | t-1) + \varepsilon(t) = a_1 v(t-1) + \dots + a_n v(t-n) + \varepsilon(t).$$


Applicando l'operatore ritardo z^{-1} :

$$(1 - a_1 z^{-1} - a_2 z^{-2} - \dots - a_n z^{-n}) v(t) = \varepsilon(t),$$

ossia

$$v(t) = W(z) \varepsilon(t), \quad W(z) = \frac{1}{1 - a_1 z^{-1} - \dots - a_n z^{-n}} = \frac{z^n}{z^n - a_1 z^{n-1} - \dots - a_n}.$$

Il problema si riconduce a trovare $W(z)$ soggetto a rumore bianco in ingresso che restituisca il segnale osservato $v(t)$.



Dobbiamo studiare questo

Spiegazione – Dal predittore al filtro generatore

Se l'errore di predizione e' rumore bianco, allora il segnale osservato puo' essere visto come il risultato di un filtro dinamico alimentato da una sorgente completamente imprevedibile. La relazione

$$v(t) = a_1 v(t-1) + \dots + a_n v(t-n) + \varepsilon(t)$$

dice che il valore attuale e' composto da una parte prevedibile, costruita con i valori passati, e da una parte nuova, $\varepsilon(t)$.

Portando tutti i termini in v a sinistra si ottiene

$$A(z)v(t) = \varepsilon(t),$$

dove $A(z) = 1 - a_1 z^{-1} - \dots - a_n z^{-n}$. Invertendo formalmente:

$$v(t) = \frac{1}{A(z)} \varepsilon(t) = W(z) \varepsilon(t).$$

Questa e' l'idea fondamentale dei modelli stocastici: descrivere un processo osservato come uscita di un sistema dinamico eccitato da rumore bianco.

2 Processi stocastici

il WN (White Noise) è un processo stocastico. Un *processo stocastico* è una successione di variabili aleatorie ordinate secondo una variabile temporale t :

$$v(t) = v(t, s),$$

dove s è sottinteso e indica la dipendenza dall'esperimento. Fissato $s = \bar{s}$, $v(t, \bar{s})$ è una funzione reale (realizzazione del PS). Fissato $t = \bar{t}$, $v(\bar{t}, s)$ è una V.A. funzione dell'esperimento s .

2.1 Caratterizzazione attraverso momenti

- Funzione di media (in generale del tempo):

$$m(t) = \mathbb{E}[v(t)].$$

- Funzione di varianza:

$$\text{Var}(t) = \mathbb{E}[(v(t) - m(t))^2].$$

- Funzione di (auto)covarianza, relazione fra due v.a. estratte dal processo stocastico per due istanti temporali t_1, t_2 :

$$\gamma(t_1, t_2) = \mathbb{E}[(v(t_1) - m(t_1))(v(t_2) - m(t_2))].$$

Proprietà.

- $\gamma(t_1, t_2) = \gamma(t_2, t_1)$
- Per istanti t_1 e t_2 coincidenti [$t_1 = t_2 = t$]

$$\gamma(t, t) = E[(v(t) - m(t))^2] = \text{Var}(t).$$

Funzione di Varianza

Spiegazione – Processo stocastico e realizzazione

Un processo stocastico e' una famiglia di variabili aleatorie indicizzate dal tempo. Per ogni istante t si ha una variabile aleatoria; per ogni esito dell'esperimento si ottiene invece una sequenza temporale concreta, detta realizzazione.

Questa distinzione e' importante negli appunti:

- le formule con $\mathbb{E}[\cdot]$ descrivono proprieta' teoriche del processo;
- i dati misurati sono una singola realizzazione;
- gli stimatori cercano di ricostruire le proprieta' teoriche usando solo quella realizzazione.

Quindi media, varianza e covarianza sono oggetti del processo, mentre media campionaria e correlogramma sono stime calcolate sui dati disponibili.

2.2 Processi stazionari (in senso lato, PSS)

- $m(t)$ costante: $\mathbb{E}[v(t)] = m$.
- $\gamma(t_1, t_2)$ funzione solo di $t_2 - t_1$:

Definito $\tau = t_2 - t_1$

$$\gamma(\tau) = \mathbb{E}[(v(t) - m)(v(t + \tau) - m)] \quad (\text{funzione pari}).$$

$$[\tau = 0 \rightarrow \gamma(0) \text{ varianza}]$$

Conseguenza: $\text{Var}(t) = \text{costante}$.

Spiegazione – Significato della stazionarieta' in senso lato

La stazionarieta' in senso lato non richiede che l'intera distribuzione probabilistica resti identica nel tempo; richiede solo che restino invariati media e covarianza. Questo e' sufficiente per molti strumenti del corso, perche' predizione lineare, spettro e correlogramma lavorano soprattutto con momenti del primo e del secondo ordine.

La condizione

$$\gamma(t_1, t_2) = \gamma(t_2 - t_1)$$

significa che la dipendenza statistica tra due campioni non dipende dalla loro posizione assoluta nel tempo, ma solo da quanto sono distanti. Per esempio, la relazione tra $v(10)$ e $v(12)$ e' la stessa che tra $v(100)$ e $v(102)$, perche' in entrambi i casi il ritardo e' $\tau = 2$.

2.3 Rumore bianco (WN)

Processo stocastico stazionario tale che $\gamma(\tau) = 0 \quad \forall \tau \neq 0$:

- per t_1, t_2 con $t_1 \neq t_2$, $\rightarrow v(t_1)$ e $v(t_2)$ sono incorrelate;
- conoscere $v(t_1)$ non da' alcun aiuto su $v(t_2)$;
- WN e' un segnale completamente imprevedibile.

Scriviamo: $\eta(t) \sim WN(m, \sigma^2)$ con $\mathbb{E}[\eta] = m$, $\gamma(\tau) = 0 \quad \forall \tau \neq 0$, $\gamma(0) = \sigma^2$ Varianza.

Spiegazione – Perche' il rumore bianco e' il riferimento di imprevedibilita'

Il rumore bianco e' il processo che non contiene correlazione temporale: conoscere un campione non aiuta a predire i campioni successivi tramite relazioni lineari. La sua autocovarianza

e',

$$\gamma_{\eta}(\tau) = \begin{cases} \sigma^2, & \tau = 0, \\ 0, & \tau \neq 0. \end{cases}$$

Per questo, quando l'errore di predizione assomiglia a rumore bianco, significa che il modello ha estratto dai dati tutta la struttura lineare prevedibile. Rimane solo innovazione, cioè informazione nuova che arriva al tempo corrente.

3 Processi MA, AR e ARMA

Usiamo WN per generare altri processi stocastici.

3.1 Processo MA (Moving Average (Media Mobile))

$$v(t) = c_0\eta(t) + c_1\eta(t-1) + \dots + c_n\eta(t-n), \quad \eta \sim WN(0, \sigma^2), \quad c_i \in \mathbb{R}.$$

Caratterizzazione:

$$\text{Media : } \mathbb{E}[v(t)] = c_0\mathbb{E}[\eta(t)] + \dots + c_n\mathbb{E}[\eta(t-n)] = 0 \quad \forall t$$

$$\text{Varianza : } \text{Var}[v(t)] = c_0^2\mathbb{E}[\eta^2(t)] + \dots + c_n^2\mathbb{E}[\eta(t-n)^2] = (c_0^2 + \dots + c_n^2)\sigma^2,$$

$$\text{Covarianza : } t_1, t_2 = t_1 + 1 [t_1 = t, t_2 = t_1 + 1]$$

$$\mathbb{E}[v(t)v(t+1)] = c_0c_1\sigma^2 + \dots + c_{n-1}c_n\sigma^2 = (c_0c_1 + \dots + c_{n-1}c_n)\sigma^2.$$

$$\text{Idem : } \mathbb{E}[v(t)v(t-1)] = \mathbb{E}[v(t)v(t+1)]$$

$$\mathbb{E}[v(t)v(t \pm 2)] = c_0c_2\sigma^2 + \dots + c_{n-2}c_n\sigma^2 = (c_0c_2 + \dots + c_{n-2}c_n)\sigma^2$$

La funzione di covarianza non dipende da t : il processo è *stazionario* per ogni $c_0, \dots, c_n$.

$$\gamma(n) = C_0C_n\sigma^2$$

$$\gamma(n+1) = 0$$

$$\vdots$$

$$= 0$$

In sintesi, MA :

- media costante
- varianza costante
- covarianza funzione solo di $t_2 - t_1 \rightarrow$ PS stazionario $\forall c_0, \dots, c_n$

Spiegazione – Processo MA: memoria finita del rumore

Un processo $MA(n)$ e' costruito sommando il rumore bianco corrente e un numero finito di rumori passati:

$$v(t) = c_0\eta(t) + c_1\eta(t-1) + \dots + c_n\eta(t-n).$$

Il punto chiave e' che $v(t)$ e $v(t+\tau)$ possono essere correlati solo se condividono almeno uno stesso termine di rumore. Se il ritardo τ e' maggiore di n , i due campioni non hanno piu' nessun $\eta(\cdot)$ in comune e quindi la covarianza si annulla.


Per questo gli MA hanno una memoria statistica finita: oltre l'ordine del modello, l'auto-covarianza teorica vale zero. Questa proprieta' sara' poi utile nella scelta della famiglia del modello a partire dai dati.

In funzione di z^{-1} :

$$v(t) = (c_0\eta(t) + c_1z^{-1}\eta(t) + \dots + c_nz^{-n}\eta(t)) = (c_0 + c_1z^{-1} + \dots + c_nz^{-n})\eta(t) = C(z)\eta(t)$$

$$W(z) = C(z) = (c_0 + c_1z^{-1} + \dots + c_nz^{-n}) = \frac{c_0z^n + c_1z^{n-1} + \dots + c_n}{z^n}.$$

F.d.t. con n poli nell'origine e n zeri dipendenti dai c_i .



Spiegazione – Uso dell'operatore ritardo nei modelli MA

L'operatore z^{-1} rappresenta un ritardo di un campione:

$$z^{-1}\eta(t) = \eta(t-1), \quad z^{-2}\eta(t) = \eta(t-2).$$

Questo permette di riscrivere somme temporali come polinomi in z^{-1} . Per un $MA(n)$,

$$v(t) = C(z)\eta(t), \quad C(z) = c_0 + c_1z^{-1} + \dots + c_nz^{-n}.$$

Questa forma e' molto comoda per passare dalla descrizione nel tempo alla descrizione come filtro: il processo $v(t)$ e' l'uscita del filtro $C(z)$ quando l'ingresso e' rumore bianco.

$MA(\infty)$:

$$v(t) = c_0\eta(t) + \dots + c_n\eta(t-n) + \dots \text{infinità di termini}$$

$$\text{Media : } m = 0;$$

$$\text{Varianza : } (c_0^2 + c_1^2 + \dots + c_n^2 + \dots)\sigma^2, \text{ converge } \iff \sum_{i=0}^{\infty} c_i \text{ è finito (convergono anche somme per covarianza)}$$

Esistono generalizzazioni:

- MA generato da WN a media $\neq 0$
- GMA generati da PS non WN

Spiegazione – Perché introdurre $MA(\infty)$

Gli MA finiti hanno memoria finita, ma molti processi reali hanno una memoria che si attenua senza annullarsi esattamente dopo un numero finito di passi. La scrittura $MA(\infty)$

$$v(t) = \sum_{i=0}^{\infty} c_i \eta(t-i)$$

permette di rappresentare processi con memoria infinita ma decrescente. Questa forma è centrale per capire gli AR stabili: un AR stabile può infatti essere sviluppato come un $MA(\infty)$, cioè come una somma infinita di rumori passati pesati da coefficienti che tendono a zero.

3.2 Processo AR (Auto Regressivo), $AR(n)$ (di ordine n)

$$v(t) = a_1 v(t-1) + a_2 v(t-2) + \dots + a_n v(t-n) + \eta(t), \quad \eta \sim WN(0, \sigma^2).$$

Definendo $A(z) = 1 - a_1 z^{-1} - a_2 z^{-2} - \dots - a_n z^{-n}$ si ha $A(z)v(t) = \eta(t)$, ovvero

$$W(z) = \frac{1}{A(z)} = \frac{1}{1 - a_1 z^{-1} - a_2 z^{-2} - \dots - a_n z^{-n}} = \frac{z^n}{z^n - a_1 z^{n-1} - \dots - a_n}.$$

n zeri nell'origine, n poli in funzione di $a_1, \dots, a_n$

Se tutti i poli sono nel cerchio unitario (stabilità), $AR(n)$ è un PSS (Processo stocastico stazionario).

Spiegazione – Processo AR: retroazione dai valori passati

In un $AR(n)$, il valore corrente dipende direttamente dai valori passati del processo stesso:

$$v(t) = a_1 v(t-1) + \dots + a_n v(t-n) + \eta(t).$$

A differenza dell'MA, non si sommano direttamente solo rumori passati: i rumori passati influenzano $v(t)$ attraverso la dinamica ricorsiva. Questo introduce una memoria potenzialmente infinita, perché $v(t-1)$ dipende da $v(t-2)$, che dipende da $v(t-3)$, e così via.

La stabilità del filtro

$$W(z) = \frac{1}{A(z)}$$

garantisce che l'effetto di un rumore passato si attenui nel tempo. Se la dinamica non è stabile, i contributi passati possono crescere e il processo non ha una varianza stazionaria ben definita.

Esempio 1 ($AR(1)$). $v(t) = av(t-1) + \eta(t)$

$$\text{se } a t_0 \rightarrow v(t_0) = v_0$$

$$v(t_0 + 1) = av_0 + \eta(t_0 + 1)$$

$$v(t_0 + 2) = a^2 v_0 + a\eta(t_0 + 1) + \eta(t_0 + 2)$$

$$v(t) = \eta(t) + a\eta(t-1) + a^2\eta(t-2) + \dots + a^{t-t_0}v_0$$

Se $t_0 \rightarrow -\infty$, con $|a| < 1$

$$v(t) = \underbrace{\eta(t) + a\eta(t-1) + a^2\eta(t-2) + \dots}_{MA(\infty)}$$

Con coefficienti:

$$c_0 = 1, \quad c_1 = a, \quad c_2 = a^2, \quad c_3 = a^3$$

$$\sum_{i=0}^{\infty} (c_i)^2 = \sum_{i=0}^{\infty} (a^i)^2 = \sum_{i=0}^{\infty} (a^2)^i$$

Serie geometrica con ragione a^2 , converge $\iff a^2 < 1$ ($|a| < 1$), in questo caso converge a $\frac{1}{1-a^2}$

$$W(z) = \frac{1}{1 - az^{-1}} = \frac{z}{z - a}$$

$AR(1)$ stabile diventa $MA(\infty)$.

$$Var[v(t)] = (c_0^2 + c_1^2 + \dots + c_n^2 + \dots) = \frac{1}{1 - a^2} \sigma^2$$

Covarianza:

$$\gamma(1) = (c_0 c_1 + c_1 c_2 + \dots + c_{n-1} c_n) \sigma^2 = (a + a^3 + a^5 + \dots) \sigma^2 = a(1 + a^2 + a^4 + \dots) \sigma^2 = \frac{a}{1 - a^2} \sigma^2$$

$$\gamma(\tau) = \frac{a^\tau \sigma^2}{1 - a^2} = a \gamma(\tau - 1)$$

Spiegazione – L'esempio $AR(1)$ passo per passo

Nel caso $AR(1)$

$$v(t) = av(t-1) + \eta(t),$$

la ricorsione puo' essere sostituita piu' volte all'indietro:

$$v(t) = \eta(t) + a\eta(t-1) + a^2\eta(t-2) + \dots$$

Ogni rumore passato entra nel valore corrente con peso a^i . Se $|a| < 1$, questi pesi diventano sempre piu' piccoli e la somma ha senso come processo stazionario.

La varianza si ottiene sommando i contributi indipendenti dei rumori:

$$Var[v(t)] = \sigma^2(1 + a^2 + a^4 + \dots) = \frac{\sigma^2}{1 - a^2}.$$

La covarianza a ritardo τ resta proporzionale ad a^τ : se a e' vicino a zero la memoria decade rapidamente; se a e' vicino a uno la memoria e' lunga.

Nel caso $AR(n)$ le equazioni di Yule-Walker (Y-W) sono

$$\gamma(\tau) = a_1 \gamma(\tau - 1) + \dots + a_n \gamma(\tau - n),$$

Spiegazione – Equazioni di Yule-Walker

Le equazioni di Yule-Walker collegano i parametri di un modello AR alla funzione di autocovarianza. Si ottengono moltiplicando l'equazione AR per un valore ritardato del processo e poi facendo il valore atteso.

Per un $AR(n)$, l'equazione

$$v(t) = a_1 v(t-1) + \dots + a_n v(t-n) + \eta(t)$$

porta, per ritardi positivi, a

$$\gamma(\tau) = a_1 \gamma(\tau - 1) + \dots + a_n \gamma(\tau - n).$$

Questo significa che l'autocovarianza di un AR soddisfa la stessa dinamica lineare del processo. Per questo, osservando la forma della covarianza, si possono stimare o riconoscere modelli autoregressivi.

3.3 Processo ARMA(n_a, n_c)

$$v(t) = a_1 v(t-1) + a_2 v(t-2) + \dots + a_{n_a} v(t-n_a) + c_0 \eta(t) + c_1 \eta(t-1) + \dots + c_{n_c} \eta(t-n_c).$$


$$a_1, \dots, a_{n_a}, c_0, \dots, c_{n_c} \in \mathbb{R}, \quad \eta \sim WN(0, \sigma^2)$$

Ponendo:

$$A(z) = 1 - a_1 z^{-1} - \dots - a_{n_a} z^{-n_a}$$

$$C(z) = c_0 + c_1 z^{-1} + \dots + c_{n_c} z^{-n_c} :$$

$$A(z)v(t) = C(z)\eta(t), \quad W(z) = \frac{C(z)}{A(z)}.$$



Con $n = \max(n_a, n_c)$:

$$W(z) = \frac{c_0 + c_1 z^{-1} + \dots + c_{n_c} z^{-n_c}}{1 - a_1 z^{-1} - \dots - a_{n_a} z^{-n_a}} = \frac{c_0 z^n + c_1 z^{n-1} + \dots}{z^n - a_1 z^{n-1} - \dots - a_{n_a} z^{n-n_a}}.$$

Se $W(z)$ è stabile, il processo ARMA è stazionario.

Spiegazione – ARMA come combinazione di AR e MA

Un ARMA unisce due meccanismi:

- la parte AR, descritta da $A(z)$, introduce dipendenza dai valori passati del processo;
- la parte MA, descritta da $C(z)$, introduce dipendenza da rumori correnti e passati.

La forma compatta e'

$$A(z)v(t) = C(z)\eta(t), \quad v(t) = \frac{C(z)}{A(z)}\eta(t).$$

Quindi l'ARMA e' ancora un filtro alimentato da rumore bianco, ma il filtro e' razionale. Rispetto a un AR puro o a un MA puro, un ARMA puo' descrivere dinamiche ricche usando meno parametri, perche' combina poli e zeri.

4 Caratterizzazione in frequenza

Caratteristiche spettrali per un PSS

4.1 Densità spettrale (di potenza)

$$\varphi(\omega) = \sum_{\tau=-\infty}^{+\infty} \gamma(\tau) e^{-j\omega\tau} \quad \text{Trasformata di Fourier di } \gamma$$

$$\gamma(\tau) = \frac{1}{2\pi} \int_{-\pi}^{\pi} \varphi(\omega) e^{j\omega\tau} d\omega.$$

Proprietà :

$\varphi(\omega)$ reale, periodica di 2π , $\varphi(-\omega) = \varphi(\omega)$, $\varphi(\omega) \geq 0 \forall \omega$.

Verifica, considero: $\pm\tau$

$$\text{esempio: } \pm 1, \gamma(1)e^{-j\omega} + \gamma(-1)e^{j\omega} = 2\gamma(1)\cos\omega.$$

Consider la relazione inversa per $\tau = 0$:

$$\gamma(0) = \frac{1}{2\pi} \int_{-\pi}^{\pi} \varphi(\omega) d\omega,$$

a meno di $\frac{1}{2\pi}$ l'area sottesa a $\varphi(\omega)$ sul periodo $(-\pi, \pi)$ è la varianza.

Per il *rumore bianco*:

$$\varphi(\omega) = \sum \gamma(\tau) e^{-j\omega\tau} = \gamma(0), \text{ costante.}$$

Spiegazione – Densità spettrale come distribuzione della varianza

La densità spettrale di potenza è la trasformata di Fourier della funzione di autocovarianza:

$$\varphi(\omega) = \sum_{\tau=-\infty}^{+\infty} \gamma(\tau) e^{-j\omega\tau}.$$

Essa descrive come la varianza del processo si distribuisce sulle frequenze. Infatti

$$\gamma(0) = \frac{1}{2\pi} \int_{-\pi}^{\pi} \varphi(\omega) d\omega,$$

e $\gamma(0)$ è proprio la varianza del processo.

Se lo spettro ha picchi, il processo contiene componenti statisticamente forti in certe frequenze. Se lo spettro è piatto, come nel rumore bianco, nessuna frequenza è privilegiata.

4.2 Spettro (complesso)

$$\Phi(z) = \sum_{\tau=-\infty}^{+\infty} \gamma(\tau) z^{-\tau}, \quad z \text{ complesso}$$

$$\varphi(\omega) = \Phi(z) \Big|_{z=e^{j\omega}}$$

Coincide con lo spettro valutato sulla circonferenza unitaria

Spiegazione – Relazione tra spettro complesso e densità spettrale

Lo spettro complesso $\Phi(z)$ è una rappresentazione algebrica della stessa informazione contenuta nella densità spettrale. La densità spettrale si ottiene valutando $\Phi(z)$ sulla circonferenza unitaria:

$$z = e^{j\omega}.$$

Questa idea è utile per i modelli razionali, perché se il processo è generato da una funzione di trasferimento $W(z)$, allora lo spettro si può scrivere direttamente in termini di $W(z)$ e $W(z^{-1})$.

4.3 Teorema fondamentale dell'analisi spettrale

Ciò che conosciamo attualmente:

- Caratteristiche spettrali ingresso
- f.d.t sistema

Dato un sistema SISO con f.d.t. $W(z)$, ingresso stazionario con spettro $\Phi_{uu}(z)$ e densità spettrale $\varphi_{uu}(\omega)$, le caratteristiche spettrali dell'uscita $y(\cdot)$ sono:

$$\Phi_{yy}(z) = W(z)W(z^{-1})\Phi_{uu}(z), \quad \varphi_{yy}(\omega) = |W(e^{j\omega})|^2 \varphi_{uu}(\omega).$$

Caso ARMA con $W(z)$ e ingresso $u(t) \sim WN(0, \sigma^2)$:

$$\Phi_{yy}(z) = W(z)W(z^{-1})\sigma^2, \quad \varphi_{yy}(\omega) = |W(e^{j\omega})|^2 \sigma^2.$$

Spiegazione – Cosa dice il teorema spettrale

Il teorema fondamentale dell'analisi spettrale dice come cambia lo spettro quando un processo passa attraverso un sistema lineare. Se l'ingresso ha densità spettrale $\varphi_{uu}(\omega)$ e il sistema ha funzione di trasferimento $W(z)$, allora l'uscita ha densità

$$\varphi_{yy}(\omega) = |W(e^{j\omega})|^2 \varphi_{uu}(\omega).$$

Il modulo quadro del filtro amplifica o attenua la potenza alle varie frequenze. Nel caso in cui l'ingresso sia rumore bianco, lo spettro in ingresso è costante; quindi tutta la forma dello spettro in uscita è determinata da $|W(e^{j\omega})|^2$.

Esempio 2 (MA(1)).

$$v(t) = \eta(t) + c\eta(t-1), \quad W(z) = 1 + cz^{-1}$$

$$\gamma(t) = \begin{cases} (1+c^2)\sigma^2 & t=0 \\ c\sigma^2 & t=1 \\ 0 & t>1 \end{cases}$$

$$\varphi(\omega) = [1+c^2+2c\cos\omega]\sigma^2, \quad \Phi(z) = (1+cz^{-1})(1+cz)\sigma^2 = (1+c^2+c(z^{-1}+z))\sigma^2.$$

Valutando $\Phi(z)$ per $z = e^{j\omega}$ e usando formula di Eulero per il coseno, otterrei $\varphi(\omega)$ come sopra.

Spiegazione – L'esempio MA(1) nello spettro

Nel processo

$$v(t) = \eta(t) + c\eta(t-1),$$

il campione corrente e quello precedente condividono un termine di rumore, quindi la covarianza è non nulla solo per ritardo 0 e 1. La densità spettrale risultante è

$$\varphi(\omega) = \sigma^2(1+c^2+2c\cos\omega).$$

Il termine $2c\cos\omega$ mostra come il parametro c modella la distribuzione frequenziale. Se $c > 0$, le basse frequenze sono favorite; se $c < 0$, vengono favorite frequenze più alte. Quindi anche un modello MA molto semplice può colorare un rumore bianco.

Generalizzazione multivariabile.

$$\Phi_{yy}(z) = W(z)\Phi_{uu}(z)W^T(z^{-1}), \quad \varphi_{yy}(\omega) = W(e^{j\omega})\varphi_{uu}(\omega)W^T(e^{-j\omega}).$$

4.4 Dimostrazione del teorema fondamentale dell'analisi spettrale

Sia $W(z) = w_0 + w_1 z^{-1} + w_2 z^{-2} + \dots$

f.d.t $\{w_i\}$ risposta impulsiva

$$y(t) = w_0 u(t) + w_1 u(t-1) + w_2 u(t-2) + \dots = \sum_{i=0}^{\infty} w_i u(t-i)$$

Prodotto di convoluzione tra risposta impulsiva $\{W_i\}$ e ingresso $\{u_i\}$

Valuto in t_2 e multiplico per $u(t_1)$, $y(t_1)$

$$u(t_1)y(t_2) = \sum_{i=0}^{\infty} w_i u(t_1)u(t_2-i)$$

$$y(t_1)y(t_2) = \sum_{i=0}^{\infty} w_i y(t_1)u(t_2-i)$$

$$\gamma_{uy}(t_1, t_2) = \sum_{i=0}^{\infty} w_i \gamma_{uu}(t_1, t_2-i)$$

$$\gamma_{yy}(t_1, t_2) = \sum_{i=0}^{\infty} w_i \gamma_{yu}(t_1, t_2-i)$$

Chiamo $t_2 - t_1 = \tau$

$$\left. \begin{aligned} \gamma_{uy}(\tau) &= \sum_{i=0}^{\infty} W_i \gamma_{uu}(\tau-i) \\ \gamma_{yy}(\tau) &= \sum_{i=0}^{\infty} W_i \gamma_{yu}(\tau-i) \end{aligned} \right\} \quad z \text{ trasformo e ottengo:}$$

$$\Phi_{uy}(z) = W(z)\Phi_{uu}(z)$$

$$\Phi_{yy}(z) = W(z)\Phi_{yu}(z)$$

con

$$\boxed{\gamma_{uy}(\tau) = \gamma_{yu}(-\tau) \text{ e } \Phi_{uy}(z) = \Phi_{yu}(z^{-1})}$$

Componendo si conclude:

$$\Phi_{yy}(z) = W(z)W(z^{-1})\Phi_{uu}(z^{-1})$$

$\downarrow$

$$\varphi_{yy}(\omega)$$

(notare che $\Phi_{uu}(z^{-1}) = \Phi_{uu}(z)$)

Spiegazione – Idea della dimostrazione

La dimostrazione parte dalla convoluzione nel tempo:

$$y(t) = \sum_{i=0}^{\infty} w_i u(t-i).$$

Per trovare lo spettro dell'uscita si studiano prima le covarianze tra ingresso e uscita e poi

tra uscita e uscita. La convoluzione nel tempo diventa prodotto nel dominio z . Per questo compaiono i fattori $W(z)$ e $W(z^{-1})$: uno deriva dal filtro applicato al primo segnale, l'altro dal filtro applicato al segnale ritardato nella covarianza.

Il risultato finale e' che un filtro lineare modifica lo spettro moltiplicandolo per il proprio guadagno in frequenza al quadrato.

5 Caratteristiche statistiche e spettrali da dati (realizzazione)

5.1 Stima della media

Siano $v(1), \dots, v(N)$ V.A. e $x(1), \dots, x(N)$ i campioni (realizzazione). Stima:

$$\hat{m}(x) = \frac{1}{N} \sum_{t=1}^N x(t) \quad \hat{m}_N(x) \rightarrow \text{Basato su } N \text{ campioni}$$

Stimatore:

$$\hat{m}_N(v) = \frac{1}{N} \sum_{t=1}^N v(t).$$

Per caratterizzare la bontà dello stimatore:

- Non polarizzato: $\mathbb{E}[\hat{m}(v)] = m$ (eventualmente questa proprietà potrebbe valere in maniera asintotica, $\mathbb{E}[\hat{m}_N(v)] \xrightarrow{N \rightarrow \infty} m$).
- Consistenza: $\mathbb{E}[(\hat{m}(v) - m)^2] \xrightarrow{N \rightarrow \infty} 0$.

$$\hat{m}(v) = \frac{1}{N} \sum_{t=1}^N v(t) \quad \rightarrow \quad \frac{1}{N} \sum_{t=1}^N \mathbb{E}[v(t)] = \frac{1}{N} N m = m$$

NON Polarizzato

Spiegazione – Media teorica e media campionaria

La media teorica

$$m = \mathbb{E}[v(t)]$$

e' una proprietà del processo. Nella pratica, però, si osserva una sola realizzazione finita $x(1), \dots, x(N)$, quindi si usa la media campionaria

$$\hat{m}_N = \frac{1}{N} \sum_{t=1}^N x(t).$$

Dire che lo stimatore e' non polarizzato significa che, se si potesse ripetere l'esperimento molte volte, la media delle stime ottenute sarebbe uguale al valore vero m . Dire che e' consistente significa invece che, aumentando il numero di campioni, la stima tende a concentrarsi attorno al valore vero.

5.2 Correlogramma

Stima della funzione di covarianza:

$$\hat{\gamma}_N(\tau, x) = \frac{1}{N} \sum_{t=1}^{N-\tau} (x(t) - \hat{m}(x))(x(t + \tau) - \hat{m}(x)).$$

Richiede $N \gtrsim 50$, $\tau < N/4$. Questo stimatore è asintoticamente non polarizzato.

Spiegazione – Correlogramma come stima della memoria

Il correlogramma stima la covarianza a diversi ritardi. Per ogni ritardo τ , si moltiplicano campioni distanti τ istanti e si fa una media:

$$\hat{\gamma}_N(\tau) = \frac{1}{N} \sum_{t=1}^{N-\tau} (x(t) - \hat{m})(x(t+\tau) - \hat{m}).$$

Se $\hat{\gamma}_N(\tau)$ e' grande in modulo, i campioni separati da quel ritardo sono statisticamente legati. Se invece e' vicino a zero, quel ritardo non mostra una relazione lineare evidente. Per ritardi grandi ci sono meno coppie disponibili, quindi la stima diventa meno affidabile. Per questo si usano solo ritardi abbastanza piccoli rispetto a N .

5.3 Periodogramma

Caratteristiche nel dominio della frequenza: Partendo dal correlogramma e usando:

$$\hat{\gamma}_N(-\tau, x) = \hat{\gamma}_N(\tau, x)$$

Stima della densità spettrale: (ricordo: $\varphi_N(\omega, x) = \sum_{\tau=-\infty}^{\infty} \gamma(\tau, x) e^{-j\omega\tau}$)

$$\hat{\varphi}_N(\omega, x) = \sum_{\tau=-(N-1)}^{N-1} \hat{\gamma}_N(\tau, x) e^{-j\omega\tau}.$$

Questa struttura si chiama Periodogramma. Proprietà:

$$\mathbb{E}[\hat{\varphi}_N(\omega, x)] \xrightarrow{N \rightarrow \infty} \varphi(\omega) \quad (\text{asint. non polarizzato}),$$

$$\mathbb{E}[(\hat{\varphi}_N(\omega, x) - \varphi(\omega))^2] \xrightarrow{N \rightarrow \infty} \varphi^2(\omega) \quad (\text{non consistente}),$$

$$\mathbb{E}[(\hat{\varphi}_N(\omega, x) - \varphi(\omega))(\hat{\varphi}_N(\tilde{\omega}, x) - \varphi(\tilde{\omega}))] \xrightarrow{N \rightarrow \infty} 0 \quad (\omega \neq \tilde{\omega}).$$

Servono metodi di regolarizzazione.

Spiegazione – Periodogramma e bisogno di regolarizzazione

Il periodogramma nasce applicando la trasformata di Fourier al correlogramma stimato. Serve a ottenere una stima della densità spettrale a partire dai dati. Il problema e' che, anche con molti campioni, il periodogramma resta molto oscillante: e' asintoticamente non polarizzato, ma non consistente.

Per renderlo piu' leggibile e utile si introducono tecniche di regolarizzazione, ad esempio medie su finestre o modelli parametrici. L'idea e' ridurre la variabilità della stima accettando una piccola perdita di risoluzione.

5.4 Test di bianchezza (Anderson)

Basato sull'analisi del correlogramma (stima di $\gamma(\tau)$ per $WN = 0 \quad \forall \tau \neq 0$). Sia $\varepsilon(\cdot)$ il segnale da testare (media nulla),

$$\hat{\gamma}(\tau) = \frac{1}{N} \sum_{t=1}^{N-\tau} \varepsilon(t) \varepsilon(t+\tau)$$

$$\hat{\gamma}(0) \quad \text{Varianza}$$

$$\hat{\gamma}(\tau) \quad \text{Covarianza tra } \varepsilon(t) \text{ e } \varepsilon(t+\tau)$$

$$\hat{\rho}(\tau) = \frac{\hat{\gamma}(\tau)}{\hat{\gamma}(0)} \quad (\text{correlogramma normalizzato})$$

Per N grande ($N \rightarrow \infty$), per $\tau > 0$, $\hat{\rho}(\tau) \rightarrow$ Gaussiana a media nulla e varianza $\frac{1}{N}$

$$\sqrt{N} \hat{\rho}(\tau) \stackrel{\text{Asint.}}{\sim} \mathcal{N}(0, 1), \quad \hat{\rho}(i), \hat{\rho}(j) \text{ incorrelati } \forall i \neq j.$$

Test con intervallo di confidenza $\alpha \in (0, 1)$: si contano i $\hat{\rho}(\tau)$ che cadono fuori da $(-\beta, \beta)$; se $< \alpha$, test superato.

Esempio 3. $\alpha = 5\% = 0,05$; 95% di area tra $-\beta$ e β , si valutano $\hat{\rho}(1), \hat{\rho}(2), \dots, \hat{\rho}(30)$, quanti cascano fuori? più o meno del 5%?


Spiegazione – Come leggere il test di bianchezza

Il test di bianchezza controlla se un segnale residuo contiene ancora correlazioni temporali significative. Per un rumore bianco, le autocorrelazioni normalizzate

$$\hat{\rho}(\tau) = \frac{\hat{\gamma}(\tau)}{\hat{\gamma}(0)}$$

devono essere vicine a zero per $\tau > 0$.

Il grafico con la gaussiana rappresenta l'idea di intervallo di confidenza: se il residuo fosse davvero bianco, la maggior parte dei valori stimati di $\hat{\rho}(\tau)$ dovrebbe cadere dentro le bande. Se molti valori cadono fuori, significa che l'errore contiene ancora struttura e quindi il modello non ha catturato tutta la dinamica presente nei dati.



6 Predizione ottima

6.1 Fake prediction problem: predittore da rumore

Assumiamo in prima battuta di conoscere il modello, quindi uscita di un sistema (fdt nota $W(z)$) con rumore bianco in ingresso di varianza nota. Questo in letteratura è chiamato il Fake prediction problem e la soluzione è il Fake predictor.

$$v(t) = W(z)\eta(t), \quad \eta \sim WN(0, \sigma^2), \quad W(z) = w_0 + w_1 z^{-1} + w_2 z^{-2} + \dots :$$

$$v(t) = w_0 \eta(t) + w_1 \eta(t-1) + w_2 \eta(t-2) + \dots$$

Problema: noti $\eta(t), \eta(t-1), \dots$, stimare $v(t+r)$, $r \geq 1$, ovvero una stima di v nel futuro (predizione):

$$v(t+r) = \underbrace{w_0 \eta(t+r) + w_1 \eta(t+r-1) + \dots + w_{r-1} \eta(t+1)}_{\alpha(t)} + \underbrace{w_r \eta(t) + w_{r+1} \eta(t-1) + \dots}_{\beta(t)}$$

$\alpha(t)$ e $\beta(t)$ sono incorrelati (separati nel tempo). $\beta(t)$ è calcolabile dalle osservazioni passate, $\alpha(t)$ è imprevedibile rispetto al passato.

Quanto vale la media di $\alpha(t)$?

$$\mathbb{E}[\alpha(t)] = w_0 \mathbb{E}[\eta(t+r)] + \dots + w_{r-1} \mathbb{E}[\eta(t+1)] = 0.$$

Il predittore (fittizio) ottimo è:

$$\hat{v}(t+r | t) = \beta(t) = w_r \eta(t) + w_{r+1} \eta(t-1) + \dots$$

L'errore di predizione associato vale:

$$v(t+r) - \hat{v}(t+r | t) = \alpha(t) \rightarrow MA$$

$$\text{Var}[\alpha(t)] = (w_0^2 + w_1^2 + \dots + w_{r-1}^2) \sigma^2.$$

All'aumentare di r aumenta la varianza.

Casi limite:

- $r = 1$ ($w_0 = 1$) $\rightarrow \text{Var}[\alpha(t)] = \sigma^2$ Varianza rumore bianco
- $r \rightarrow \infty \rightarrow (w_0^2 + w_1^2 + \dots) \sigma^2 \rightarrow \text{Varianza di } v(t)$

Spiegazione – Predizione ottima nel fake prediction problem

In questa sezione si assume di conoscere direttamente il rumore bianco $\eta(t)$ che genera il processo. Per predire $v(t+r)$ si separano i termini in due gruppi:

$$v(t+r) = \alpha(t) + \beta(t).$$

La parte $\beta(t)$ contiene rumori fino al tempo t , quindi è nota al predittore. La parte $\alpha(t)$ contiene rumori futuri, da $\eta(t+1)$ a $\eta(t+r)$, quindi non è prevedibile usando l'informazione disponibile al tempo t .

Il miglior predittore è dunque

$$\hat{v}(t+r | t) = \beta(t),$$

mentre l'errore di predizione è $\alpha(t)$. All'aumentare di r entrano più rumori futuri nell'errore, perciò la varianza dell'errore cresce fino ad avvicinarsi alla varianza complessiva del processo.


6.2 Predittore ottimo dai dati

Sia


$$\hat{W}_r(z) = w_r + w_{r+1}z^{-1} + w_{r+2}z^{-2} + \dots \implies \hat{v}(t+r | t) = \hat{W}_r(z)\eta(t).$$

$$\text{La fdt tra } \eta(t) \text{ e } \beta(t) = [\hat{v}(t+r | t)]$$

In blocchi:



Io conosco:



Si ottiene $\hat{W}_r(z)$ a partire da $W(z)$ via *lunga divisione*:

$$W(z) = w_0 + w_1 z^{-1} + \dots + w_{r-1} z^{-(r-1)} + w_r z^{-r} + w_{r+1} z^{-(r+1)} + \dots = w_0 + w_1 z^{-1} + \dots + w_{r-1} z^{-(r-1)} + z^{-r} \hat{W}_r(z).$$

Esempio 4 (AR(1)). $W(z) = \frac{1}{1-az^{-1}}$, $|a| < 1$. Con lunga divisione

$$W(z) = 1 + az^{-1} + a^2z^{-2} + \dots + \frac{a^r z^{-r}}{1 - az^{-1}},$$

quindi il predittore ottimo a r passi (dal rumore) è

$$\hat{W}_r(z) = \frac{a^r}{1 - az^{-1}}.$$

Nota: il denominatore rimane sempre quello di $W(z)$ ad ogni passo.

Varianza dell'errore di predizione a r passi: $(1 + a^2 + a^4 + \dots + a^{2(r-1)})\sigma^2$.

(Ps: eventualmente aggiungere passaggi intermedi)

Spiegazione – Lunga divisione e predittore a piu' passi

La lunga divisione serve a separare la risposta impulsiva di $W(z)$ in due parti:

$$W(z) = w_0 + w_1z^{-1} + \dots + w_{r-1}z^{-(r-1)} + z^{-r}\hat{W}_r(z).$$

I primi r coefficienti moltiplicano rumori futuri quando si predice $v(t+r)$ dal tempo t , quindi generano l'errore di predizione. La coda, rappresentata da $\hat{W}_r(z)$, moltiplica rumori già disponibili e quindi genera il predittore.

Nel caso AR(1), la divisione produce potenze di a :

$$W(z) = 1 + az^{-1} + a^2z^{-2} + \dots.$$

Per questo il predittore a r passi conserva lo stesso denominatore ma ha numeratore moltiplicato da a^r .

Esistono molteplici rappresentazioni ARMA per lo stesso processo stocastico $v(t)$:

Ricordiamo il Teo. Fond. Analisi spettrale

$$\Phi(z) = W(z)W(z^{-1})\sigma^2$$

Le trasformazioni che lasciano invariato il processo sono:

1. Divido per una costante

$$\tilde{W}(z) = \frac{1}{\alpha}W(z)$$

$$\tilde{\sigma}^2 = \alpha^2\sigma^2$$

$$\tilde{\Phi}(z) = \frac{1}{\alpha}W(z) \frac{1}{\alpha}W(z^{-1}) = \frac{1}{\alpha^2}W(z)W(z^{-1})\alpha^2\sigma^2 = \Phi(z)$$

sto usando due rappresentazioni dello stesso processo stocastico.

- 2.

$$\tilde{W}(z) = z^{-k}W(z) \quad \tilde{\sigma}^2 = \sigma^2 \quad \text{Traslazione temporale}$$

$$\tilde{\Phi}(z) = z^{-k}W(z) W(z^{-1}) z^k\sigma^2 = \Phi(z)$$

3. Moltiplico numeratore e denominatore per lo stesso polinomio

4.

$$T(z) = \rho \frac{z + \alpha}{z + \frac{1}{\alpha}} \quad 1 \text{ polo e } 1 \text{ zero reciproci}$$

$$T(z)T(z^{-1}) = \rho \frac{z + \alpha}{z + \frac{1}{\alpha}} \cdot \rho \frac{z^{-1} + \alpha}{z^{-1} + \frac{1}{\alpha}}$$

$$= \rho^2 \frac{z + \alpha}{z + \frac{1}{\alpha}} \cdot \frac{z^{-1} + \alpha}{z^{-1} + \frac{1}{\alpha}} \cdot \frac{z}{z}$$

$$= \rho^2 \frac{z + \alpha}{z + \frac{1}{\alpha}} \frac{1 + \alpha z}{1 + \frac{z}{\alpha}} = \rho^2 \alpha^2$$

se

$$\rho^2 = \frac{1}{\alpha^2} \quad T(z)T(z^{-1}) = 1$$

$$\tilde{W}(z) = W(z)T(z) \quad \text{Rappresenta lo stesso processo stocastico}$$

$$W(z) \propto z + \frac{1}{\alpha}$$

7 Teorema di fattorizzazione spettrale

Dato un processo ARMA stazionario, esiste un'unica rappresentazione tale che numeratore e denominatore sono monici, hanno lo stesso grado e sono coprimi, con tutti i poli e gli zeri nel cerchio unitario.

1. Sono monici: fa fuori la 1.
2. Stesso grado: fa fuori la 2.
3. Coprimi: fa fuori la 3.
4. Tutti poli e zeri nel cerchio unitario: fa fuori la 4.

Fissata la rappresentazione (Canonica) $\hat{W}(z)$ detto **Fattore spettrale canonico** $\implies$ Rumore bianco univoco $\xi(t)$ come conseguenza.

Spiegazione – Perché serve la fattorizzazione spettrale

Lo stesso spettro può essere prodotto da più rappresentazioni filtro-rumore. Per esempio, si possono cambiare scale, introdurre ritardi o riflettere zeri senza modificare la densità spettrale del processo. La fattorizzazione spettrale serve a scegliere una rappresentazione unica e ben normalizzata.

La rappresentazione canonica richiede poli e zeri nel cerchio unitario, polinomi coprimi e normalizzazioni precise. In questa forma, il rumore bianco $\xi(t)$ è l'innovazione del processo: la parte nuova che non può essere prevista dal passato. Questo rende possibile costruire un predittore ottimo direttamente dai dati osservati.

Esempio 5 (MA).

$$v(t) = 2\eta(t-1) + 4\eta(t-2) \quad \eta \sim WN(0, \sigma^2)$$

$$W(z) = 2z^{-1} + 4z^{-2} = \frac{2z + 4}{z^2}, \quad \text{non canonica.}$$

- posso moltiplicare il denominatore per z^{-1} , otterrò $\frac{2z+4}{z}$
- Divido per 2 numeratore, otterrò $\frac{z+2}{z}$
- Reciproco dello zero $\frac{z+0.5}{z} = 1 + 0.5z^{-1} \rightarrow v(t) = \xi(t) + 0.5\xi(t-1)$, quanto vale $\xi(t)$?

$$v(t) = 2\eta(t-1) + 4\eta(t-2), \quad \text{Var}[v(t)] = (2^2 + 4^2)\sigma^2 = 20\sigma^2$$

$$v(t) = \xi(t) + 0.5\xi(t-1), \quad \text{Var}[v] = (1^2 + 0.5^2)\mu^2 = 1.25\mu^2$$

$$20\sigma^2 = 1.25\mu^2 \rightarrow \mu^2 = 16\sigma^2$$

Spiegazione – L'esempio MA e il cambio di rappresentazione

Nell'esempio, il processo è scritto inizialmente come

$$v(t) = 2\eta(t-1) + 4\eta(t-2).$$

Questa rappresentazione contiene un ritardo comune e coefficienti non normalizzati. La fattorizzazione porta a una rappresentazione equivalente ma canonica:


$$v(t) = \xi(t) + 0.5\xi(t-1).$$

Le due scritture descrivono lo stesso processo, quindi devono produrre la stessa varianza. Per questo si confrontano le varianze:

$$20\sigma^2 = 1.25\mu^2.$$

Il cambio di filtro viene compensato da un cambio della varianza del rumore bianco in ingresso.

Filtro sbiancante. Per un processo a rappresentazione canonica $\hat{W}(z)$, l'inverso $\hat{W}^{-1}(z) = \check{W}(z)$ è stabile (poli nel cerchio unitario) e può essere usato per recuperare $\xi(t)$ da $v(t)$.



Spiegazione – Filtro sbiancante

Il filtro sbiancante è l'inverso del fattore spettrale canonico:

$$\check{W}(z) = \hat{W}^{-1}(z).$$

Applicandolo al processo osservato $v(t)$ si recupera l'innovazione:

$$\xi(t) = \check{W}(z)v(t).$$

Il nome “sbiancante” deriva dal fatto che trasforma un processo colorato, cioè con correlazioni temporali, in rumore bianco. Questo passaggio è fondamentale per la predizione: una volta recuperata l'innovazione, si può usare la teoria del predittore da rumore.

8 Predizione dai dati:

ARMA stazionario (nota rappresentazione standard)


Nota: possiamo applicare il predittore ottimo $\hat{W}_r(z)$ a r passi a $\xi(t)$

$\hat{W}(z)$ e $\hat{W}_r(z)$ stesso denominatore

$$\hat{W}(z) = \frac{C(z)}{A(z)}$$

$$\hat{W}_r(z) = \frac{C_r(z)}{A(z)}$$

Nota: Possiamo “recuperare” $\xi(t)$ da $v(t)$ con filtro sbiancante



$$W_r(z) = \check{W}(z) \hat{W}_r(z) = \frac{A(z)}{C(z)} \cdot \frac{C_r(z)}{A(z)} = \frac{C_r(z)}{C(z)}.$$

Più avanti generalizziamo per

AR(1), MA(1), ARMA.

Esprimere $W(z)$ in potenze negative di z (Lunga divisione)



$$W(z) = \frac{\text{Num}}{\text{Den}} = \text{Quoziente} + \frac{\text{Resto}}{\text{Den}}$$

$$W(z) = \frac{z}{z-a} = 1 + \frac{a}{z-a} = 1 + az^{-1} + \frac{a^2 z^{-1}}{z-a} = 1 + az^{-1} + a^2 z^{-2} + \frac{a^3 z^{-2}}{z-a}$$

Nota: Manca la tabellina della lunga divisione ma tant'è.

Predittore ottimo (a r passi) da rumore bianco $\hat{W}_r(z) = \frac{C_r(z)}{A(z)}$

ottenuto per lunga divisione da $\hat{W}(z) = \frac{C(z)}{A(z)}$



$$\underbrace{\frac{A(z)}{C(z)}}_{\check{W}(z)} \cdot \underbrace{\frac{C_r(z)}{A(z)}}_{\hat{W}_r(z)} = \frac{C_r(z)}{C(z)} \rightarrow \text{ottimo dai dati}$$

Spiegazione – Dal predittore da rumore al predittore dai dati

Nel fake prediction problem si assumeva di conoscere il rumore bianco. Nei dati reali, invece, si osserva solo $v(t)$. Per questo si usa il filtro sbiancante:

$$\xi(t) = \frac{A(z)}{C(z)}v(t).$$

Poi si applica il predittore da rumore:

$$\hat{v}(t+r | t) = \hat{W}_r(z)\xi(t).$$

Componendo i due filtri si ottiene il predittore direttamente dai dati:

$$W_r(z) = \frac{A(z)}{C(z)} \frac{C_r(z)}{A(z)} = \frac{C_r(z)}{C(z)}.$$

Questa formula spiega perché nel predittore dai dati compare il denominatore $C(z)$: esso nasce dal fatto che bisogna stimare l'innovazione a partire dal processo osservato.

AR(1):

$$\hat{W}(z) = \frac{1}{1 - az^{-1}} \quad |a| < 1$$

Predittore a uno/due passi da rumore:

$$\hat{W}(z) = 1 + \frac{az^{-1}}{1 - az^{-1}} = 1 + az^{-1} + \frac{a^2z^{-1}}{1 - az^{-1}} \quad (\text{Lunga divisione})$$

Dunque predittore ottimo da $\xi(t)$

$$\mathbf{1 \text{ passo:}} \quad \hat{W}_1(z) = \frac{a}{1 - az^{-1}} \quad [C_1(z) = a]$$

$$\mathbf{2 \text{ passi:}} \quad \hat{W}_2(z) = \frac{a^2}{1 - az^{-1}} \quad [C_2(z) = a^2]$$

Predittore ottimo da $v(t)$

$$\mathbf{1 \text{ passo:}} \quad a$$

$$\mathbf{2 \text{ passo:}} \quad a^2$$

Nel tempo:

$$\hat{v}(t+1|t) = av(t)$$

$$\hat{v}(t+2|t) = a^2v(t)$$

$$\mathbf{a \text{ r passi nel tempo:}} \quad \hat{v}(t+r|t) = a^r v(t)$$

$$r \rightarrow \infty \quad \hat{v}(t+r|t) = 0$$

Spiegazione – Predizione AR(1) dai dati

Per un AR(1),

$$v(t) = av(t-1) + \xi(t),$$

tutta l'informazione utile per predire il futuro è contenuta nell'ultimo valore osservato. Il predittore a un passo è

$$\hat{v}(t+1 | t) = av(t),$$

quello a due passi e'

$$\hat{v}(t+2 | t) = a^2 v(t),$$

e in generale

$$\hat{v}(t+r | t) = a^r v(t).$$

Se $|a| < 1$, al crescere dell'orizzonte r il termine a^r tende a zero: molto lontano nel futuro, la miglior previsione torna alla media del processo, che qui e' nulla.

MA(1) Consideriamo il processo

$$v(t) = \xi(t) + c \xi(t-1), \quad |c| < 1, \quad \xi(t) \sim WN(0, \sigma^2).$$

$$\hat{W}(z) = 1 + c z^{-1}.$$

Per il predittore ottimo dal rumore si ha:

$$\hat{W}_1(z) = c,$$

$$\hat{W}_2(z) = 0,$$

$$\vdots$$

$$\hat{W}_k(z) = 0, \quad \forall k \geq 2.$$

Quindi il solo coefficiente non nullo è il primo.

Ottimo dai dati:

$$W_1(z) = \frac{c}{1 + c z^{-1}},$$

$$W_k(z) = 0, \quad \text{per } k \geq 2.$$

Nel tempo:

$$1 \text{ passo: } \hat{v}(t+1 | t) = \frac{c}{1 + c z^{-1}} v(t)$$

equivalentemente,

$$(1 + c z^{-1}) \hat{v}(t+1 | t) = c v(t),$$

da cui

$$\hat{v}(t+1 | t) = -c \hat{v}(t | t-1) + c v(t).$$

$$2 \text{ passi: } \hat{v}(t+2 | t) = 0 \quad \gamma(\tau) = 0 \quad \tau > 1$$

più in generale (più passi),

$$\hat{v}(t+r | t) = 0, \quad r > 1.$$

Spiegazione – Predizione MA(1)

Un MA(1) ha memoria molto corta:

$$v(t) = \xi(t) + c \xi(t-1).$$

Per predire $v(t+1)$, il termine $c \xi(t)$ e' in parte ricostruibile dai dati passati tramite il filtro inverso. Per questo il predittore a un passo non e' nullo.

Per $r > 1$, invece, $v(t+r)$ dipende da innovazioni future che non sono note al tempo t .

Poiche' il processo ha media nulla e non c'e' altra informazione sfruttabile, il predittore ottimo diventa

$$\hat{v}(t+r | t) = 0, \quad r > 1.$$

Questa e' una conseguenza diretta della memoria finita degli MA.

Processo ARMA

$$A(z)v(t) = C(z)\xi(t) \quad n = \max(n_a, n_c)$$

$$A(z) = 1 - a_1 z^{-1} - a_2 z^{-2} - \dots - a_{n_a} z^{-n_a}$$

$$C(z) = 1 + c_1 z^{-1} + c_2 z^{-2} + \dots + c_{n_c} z^{-n_c}$$

$$\frac{z^n C(z)}{z^n A(z)} = \frac{z^n + c_1 z^{n-1} + \dots}{z^n - a_1 z^{n-1} - \dots}$$

Assumiamo

- No cancellazioni
- poli e zeri nel cerchio unitario

Lunga Divisione

$$\frac{C(z)}{A(z)} = 1 + \frac{C(z) - A(z)}{A(z)} = 1 + z^{-1} \frac{z(C(z) - A(z))}{A(z)}$$

Predittore ottimo a un passo (a partire dai dati):

$$W_1(z) = z \frac{C(z) - A(z)}{C(z)}$$

$$\hat{v}(t+1 | t) = z \frac{C(z) - A(z)}{C(z)} v(t)$$

$$C(z) \hat{v}(t+1 | t) = (C(z) - A(z)) v(t+1)$$

$C(z) \hat{v}(t+1 | t)$ è una combinazione di $\hat{v}(t+1 | t)$ a istanti precedenti, mentre $(C(z) - A(z)) v(t+1)$ dipende al più (tardi) da $v(t)$, infatti è uguale a

$$(c_1 + a_1)v(t) + (c_2 + a_2)v(t-1) + \dots$$

Nel tempo: $\hat{v}(t+1 | t) = -c_1 \hat{v}(t | t-1) - c_2 \hat{v}(t-1 | t-2) - \dots + (c_1 + a_1)v(t) + (c_2 + a_2)v(t-1) + \dots$

Spiegazione – Predittore ARMA a un passo

Nel caso ARMA, il predittore a un passo contiene due tipi di termini:

- valori passati del processo $v(t), v(t-1), \dots$;
- predizioni passate $\hat{v}(t | t-1), \hat{v}(t-1 | t-2), \dots$.

Le predizioni passate compaiono perché il denominatore $C(z)$ introduce una ricorsione nel predittore. La formula

$$C(z) \hat{v}(t+1 | t) = (C(z) - A(z))v(t+1)$$

va letta ricordando che $C(z) - A(z)$ non ha termine costante quando A e C sono monici. Quindi, applicato a $v(t+1)$, produce solo campioni disponibili fino al tempo t .

8.1 ARMAX

Generalizzazione degli ARMA con variabili esogene (ingressi).

(A questo punto il segnale risultante $\rightarrow y(t)$)

$$A(z)y(t) = C(z)\xi(t) + f(t) \quad \text{con } f(t) \text{ funzione della variabile esogena}$$

Esempio:

sistema soggetto a variabile di controllo $u(t)$:

$$f(t) = b_1 u(t-1) + b_2 u(t-2) + \dots + b_{n_b} u(t-n_b) = B(z)u(t).$$

se


$$B(z) = b_1 z^{-1} + b_2 z^{-2} + \dots + b_{n_b} z^{-n_b}$$

ho

$$A(z)y(t) = B(z)u(t) + C(z)\xi(t)$$

Volendo esplicitare, con $k > 1$ ritardo di ingresso-uscita:

$$A(z)y(t) = B(z)u(t-k) + C(z)\xi(t).$$



ARMAX (predizione)

$$A(z)y(t+k) = B(z)u(t) + C(z)\xi(t+k)$$

Lunga Divisione k Passi

$$\frac{C(z)}{A(z)} \quad C(z) = A(z)E(z) + z^{-k}\tilde{F}(z)$$

con $A(z)E(z)$ Risultato della divisione e $z^{-k}\tilde{F}(z)$ Resto dopo k passi

$$E(z) = e_0 + e_1 z^{-1} + e_2 z^{-2} + \dots + e_{k-1} z^{-k+1}$$

$$e_0 = 1 \quad (A(z) \text{ e } C(z) \text{ sono Monici})$$

$$A(z)E(z)y(t+k) = B(z)E(z)u(t) + C(z)E(z)\xi(t+k)$$

$$C(z)y(t+k) = B(z)E(z)u(t) + (C(z) - A(z)E(z))y(t+k) + C(z)E(z)\xi(t+k)$$

$$\text{Dove } C(z) - A(z)E(z) = z^{-k}\tilde{F}(z)$$

$$\text{dunque } y(t+k) = \frac{\tilde{F}(z)}{C(z)}y(t) + \frac{B(z)E(z)}{C(z)}u(t) + E(z)\xi(t+k)$$

- $\frac{F(z)}{C(z)}y(t)$ dipende da y fino a tempo t
- $\frac{B(z)E(z)}{C(z)}$ dipende da u fino a tempo t
- $E(z)\xi(t+k) \rightarrow e_0\xi(t+k) + e_1\xi(t+k-1) + \dots + e_{k-1}\xi(t+1)$

Spiegazione – Predizione ARMAX e ruolo dell'ingresso

Nel modello ARMAX si aggiunge un ingresso esterno $u(t)$:

$$A(z)y(t) = B(z)u(t-k) + C(z)\xi(t).$$

La predizione deve quindi usare due fonti di informazione: il passato dell'uscita y e i valori dell'ingresso u disponibili o programmati. La divisione

$$C(z) = A(z)E(z) + z^{-k}\tilde{F}(z)$$

serve a separare i contributi futuri del rumore, non predicibili, dai contributi legati a y e u , che invece sono utilizzabili.

La forma finale del predittore contiene quindi una parte dovuta alla dinamica libera del sistema, tramite $y(t)$, e una parte forzata dall'ingresso, tramite $u(t)$.

Predittore ottimo (k passi)

$$C(z)\hat{y}(t+k | t) = \tilde{F}(z)y(t) + B(z)E(z)u(t) \rightarrow \text{dai dati}$$

Caso particolare $k = 1$: $E(z) = 1$:

$$\frac{C(z)}{A(z)} = 1 + z^{-1} \frac{z(C(z) - A(z))}{A(z)}$$

Da cui

$$C(z) = A(z) + z^{-1}[z(C(z) - A(z))]$$

$$C(z)\hat{y}(t+1 | t) = (C(z) - A(z))y(t+1) + B(z)u(t).$$

Nel caso ARMA:

$$C(z)\hat{y}(t+1 | t) = (C(z) - A(z))y(t+1)$$

9 Identificazione: famiglia di modelli

Formulare una famigliaandidata per i modelli (vari modelli nella stessa famiglia), con descrizione analitica comune (ogni modello è specificato da uno o più parametri).

- Raccolta dei dati e analisi.

- Scelta fra modello fisico o sintetico.
- Scelta della famiglia di modelli (AR, MA, ARMA, ...).
- Scelta di una complessità adeguata (ordine).
- Stima dei parametri.
- Analisi critica dei risultati (validazione).

Denoteremo $\mathcal{M} = \{M(\theta) \mid \theta \in \Theta\}$ con θ vettore dei parametri. Obiettivo: determinare θ dall'analisi dei dati (Misura di una o più variabili sul sistema S).

Spiegazione – Che cosa significa scegliere una famiglia di modelli

Una famiglia di modelli e' un insieme di possibili descrizioni del sistema, tutte con la stessa struttura ma con parametri diversi:

$$\mathcal{M} = \{M(\theta) \mid \theta \in \Theta\}.$$

Scegliere la famiglia significa decidere quali dinamiche si vogliono ammettere: AR, MA, ARMA, ARX, ARMAX, Box-Jenkins, ecc. Una volta fissata la famiglia e l'ordine, l'identificazione diventa il problema di trovare il valore di θ che rende il modello piu' coerente con i dati.

La scelta della famiglia e' delicata: una famiglia troppo semplice non riesce a rappresentare il sistema; una troppo complessa rischia di adattarsi al rumore e perdere capacita' predittiva su nuovi dati.

9.1 Approccio predittivo

(stima dei parametri, ipotizzando di aver già fatto tutti gli altri step)

Abbiamo una famiglia $\mathcal{M} = \{M(\theta) \mid \theta \in \Theta\}$ di complessità fissata, abbiamo a disposizione quantità misurabili su un intervallo da 1 a N. I dati:

- Sequenze di $y(t)$ nel caso di serie temporali
- sequenze di coppie I-O $u(t), y(t)$ nel caso di sistemi

Obiettivo: estrarre da questi dati il miglior modello, ovvero il miglior insieme di parametri $\theta \in \Theta$. Dove θ è il vettore dei parametri.

Miglior modello $\rightarrow$ errore di predizione "piccolo". $y(\cdot)$ segnale misurato su un intervallo di tempo, descrivibile attraverso ARMA (caratterizzato da parametri θ). Il predittore corrispondente $\hat{y}(t+1 \mid t)$ è funzione dei dati passati $\{y(t), y(t-1), \dots\} \rightarrow y^t$:

$$\hat{M}(\theta): \hat{y}(t+1 \mid t) = f(y^t, \theta)$$

oppure, nei sistemi,

$$\hat{y}(t+1 \mid t) = f(u^t, y^t, \theta).$$


con $\{u(t), u(t-1), \dots\} = u^t$

Per ogni istante, il predittore è valutabile numericamente. Come detto prima il miglior modello è quella associato a un "piccolo" errore di predizione $\epsilon(t)$.

Il funzionale da minimizzare è:

$$J(\theta) = \frac{1}{N} \sum_{t=1}^N \epsilon^2(t), \quad \epsilon(t) = y(t) - \hat{y}(t \mid t-1).$$

Con $\theta \in \Theta$



Identificazione $\equiv$ Ottimizzazione, ci vogliono algoritmi di ottimizzazione adeguati alle peculiarità del sistema, ma la valutazione della bontà del modello deve passare anche da altri aspetti (Es: Test di bianchezza su errore di predizione).

Spiegazione – Approccio predittivo

Nell'approccio predittivo ogni modello $M(\theta)$ genera un proprio predittore:

$$\hat{y}_\theta(t | t-1) = f(u^t, y^t, \theta).$$

Il parametro migliore e' quello che rende piccolo l'errore di predizione:


$$\varepsilon_\theta(t) = y(t) - \hat{y}_\theta(t | t-1).$$

Il funzionale

$$J(\theta) = \frac{1}{N} \sum_{t=1}^N \varepsilon_\theta^2(t)$$

misura l'errore quadratico medio sui dati disponibili. Quindi stimare θ significa risolvere un problema di ottimizzazione. Dopo la stima, però, bisogna controllare se il residuo e' davvero privo di struttura: un errore piccolo ma correlato segnala che il modello non ha ancora catturato tutta la dinamica.


Modelli Box–Jenkins



Segnale

$$y(t) = W(z) \xi(t)$$

Segnale modellato



Sistema

$$\underbrace{y(t) = G(z)u(t-1) + W(z)\xi(t)}_{\text{B-J}}$$

$$\xi \sim WN(0, \sigma^2).$$

- ARX: $A(z)y(t) = B(z)u(t-1) + \xi(t)$, $G(z) = B(z)/A(z)$, $W = 1/A(z)$.
- AR: $A(z)y(t) = \xi(t)$, $W(z) = 1/A(z)$.
- ARMAX: $A(z)y(t) = B(z)u(t-1) + C(z)\xi(t)$, $G(z) = B(z)/A(z)$, $W(z) = C(z)/A(z)$.
- ARMA: $A(z)y(t) = C(z)\xi(t)$, $W(z) = C(z)/A(z)$.
- OE(output error):
 $A(z)\tilde{y}(t) = B(z)u(t-1)$, con $y(t) = \tilde{y}(t) + \xi(t)$
 $A(z)y(t) = B(z)u(t-1) + A(z)\xi(t)$. Da questa ricavo $G(z)$ e $W(z)$ con B-J
- ARXAR: $A(z)y(t) = B(z)u(t-1) + \frac{1}{D(z)}\xi(t)$ con $\frac{1}{D(z)}\xi(t)$ AR, da cui
 $A(z)D(z)y(t) = B(z)D(z)u(t-1) + \xi(t)$. Da qui derivo $G(z)$ e $W(z)$ B-J.

Spiegazione – Lettura dei modelli Box–Jenkins

La forma Box–Jenkins

$$y(t) = G(z)u(t-1) + W(z)\xi(t)$$

separa due effetti:

- $G(z)$ descrive come l'ingresso controllabile u influenza l'uscita;
- $W(z)$ descrive come il disturbo non misurato ξ entra nell'uscita.

Le varie famiglie nascono imponendo vincoli diversi su G e W . Per esempio, nel modello ARX il denominatore $A(z)$ e' condiviso tra dinamica ingresso-uscita e dinamica del rumore. Nei modelli piu' generali, come BJ, le due dinamiche possono essere separate, aumentando flessibilita' ma anche complessita' di stima.

9.2 Predittore in forma unificata (BJ)

Uniformare trattazione a livello di predittore.

B-J:

$$\mathcal{M}(\theta) : y(t) = G(z)u(t-1) + W(z)\xi(t) \text{ con } \xi(t) \sim WN(0, \sigma^2)$$

$$y(t) = \left[1 - \frac{1}{W(z)}\right]y(t) + \frac{G(z)}{W(z)}u(t-1) + \xi(t),$$

con il primo pezzo dipendente al più da $y(t-1)$, il secondo al più da $u(t-1)$, $\xi(t)$ WN al tempo t , mentre $\frac{1}{W(z)}$ ottenuto da lunga divisione, ovvero $1 + \dots$ [Rapporto tra polinomi monici] Quindi:

$$\hat{\mathcal{M}}(\theta) : \hat{y}_\theta(t | t-1) = \left[1 - \frac{1}{W(z)}\right]y(t) + \frac{G(z)}{W(z)}u(t-1).$$

(o $y(\hat{t})$ per alleggerire la notazione)

Casi particolari:

- ARX: Famiglia del predittore associata: $\hat{\mathcal{M}}(\theta) : \hat{y}(t) = [1 - A(z)]y(t) + B(z)u(t-1)$.
Ricordo: $\mathcal{M}(\theta) : A(z)y(t) = B(z)u(t-1) + \xi(t)$ (non lo sto a riscrivere anche per gli altri, lo ritrovi sopra sotto modelli B-J)

- AR: $\hat{\mathcal{M}}(\theta) : \hat{y}(t) = [1 - A(z)]y(t)$.
- ARMAX: $\hat{\mathcal{M}}(\theta) : C(z)\hat{y}(t) = [C(z) - A(z)]y(t) + B(z)u(t-1)$.
- ARMA: $\hat{\mathcal{M}}(\theta) : C(z)\hat{y}(t) = [C(z) - A(z)]y(t)$

Spiegazione – Predittore BJ in forma unificata

La forma

$$\hat{y}_\theta(t | t-1) = \left[1 - \frac{1}{W(z)}\right] y(t) + \frac{G(z)}{W(z)} u(t-1)$$

mostra che il predittore usa due blocchi: uno costruito dal passato dell'uscita e uno costruito dall'ingresso. Il termine $\xi(t)$ non compare nel predittore perché è l'innovazione al tempo t , quindi non è nota al tempo $t-1$.

Questa formula è utile per confrontare famiglie diverse con un'unica logica: dato un modello, si ricava il suo predittore; dato il predittore, si definisce l'errore; dato l'errore, si costruisce il criterio di stima.

9.3 Peculiarità del predittore (Linearità nei parametri)

- ARX: predittore *lineare* nei parametri.
- ARMAX: non lineare nei parametri (per $C(z) \neq 1$). (da aggiungere esempio ARMAX(1,1,1)).

Spiegazione – Perché la linearità nei parametri conta

Se il predittore è lineare nei parametri, come nel caso ARX, il criterio quadratico $J(\theta)$ diventa una funzione quadratica di θ . Il minimo si trova allora con formule chiuse di minimi quadrati.

Se invece il predittore contiene i parametri anche al denominatore, come nei modelli ARMAX con $C(z) \neq 1$, il problema diventa non lineare. In quel caso non basta risolvere equazioni normali: servono algoritmi iterativi come Gauss-Newton.

10 Stima ai minimi quadrati (ARX/AR)

ARX: Ricordo: $\mathcal{M}(\theta) : y(t) = a_1 y(t-1) + \dots + a_{n_a} y(t-n_a) + b_1 u(t-1) + \dots + b_{n_b} u(t-n_b) + \xi(t) = *$

Raccogliamo i parametri in:

$$\theta = [a_1, \dots, a_{n_a}, b_1, \dots, b_{n_b}]^\top,$$

e le osservazioni in:

$$\varphi(t) = [y(t-1), \dots, y(t-n_a), u(t-1), \dots, u(t-n_b)]^\top.$$

Il modello $*$ si scrive $y(t) = \varphi^\top(t)\theta + \xi(t)$ e il predittore

$$\hat{\mathcal{M}}(\theta) : \hat{y}(t) = \varphi^\top(t)\theta, \quad \varepsilon(t) = y(t) - \varphi^\top(t)\theta.$$

Funzionale:

$$J(\theta) = \frac{1}{N} \sum_{t=1}^N (y(t) - \varphi^\top(t)\theta)^2.$$

Imponendo $\partial J / \partial \theta = 0$: (cerco il minimo rispetto a θ , il -2 va via dato che stiamo ponendo $= 0$)

$$\frac{1}{N} \sum_{t=1}^N \varphi(t) y(t) - \underbrace{\frac{1}{N} \sum_{t=1}^N \varphi(t) \varphi^T(t)}_{R(N)} \theta = 0 \iff \frac{1}{N} \sum_{t=1}^N \varphi(t) \varphi^T(t) \theta = \frac{1}{N} \sum_{t=1}^N \varphi(t) y(t).$$

Vorrei far notare inoltre che $\varphi(t) \varphi^T(t)$ è una matrice mentre θ un vettore colonna, quindi ottengo sempre un vettore colonna. Se $R(N)$ (o equivalentemente $S(N)$, dato che differiscono solo per un $1/N$) non è singolare, ottengo una soluzione unica:

$$\hat{\theta} = \left[\sum_{t=1}^N \varphi(t) \varphi^T(t) \right]^{-1} \sum_{t=1}^N \varphi(t) y(t),$$

stima ai minimi quadrati. Se $R(N)$ è singolare, esistono infinite soluzioni tutte associate allo stesso valore (minimo) del funzionale.

Spiegazione – Minimi quadrati per ARX e AR

Nel modello ARX il predittore ha la forma

$$\hat{y}(t) = \varphi^T(t) \theta.$$

Quindi l'errore è

$$\varepsilon(t) = y(t) - \varphi^T(t) \theta.$$

Poiché θ compare linearmente, minimizzare

$$J(\theta) = \frac{1}{N} \sum_{t=1}^N (y(t) - \varphi^T(t) \theta)^2$$

porta alle equazioni normali:

$$\left(\sum_{t=1}^N \varphi(t) \varphi^T(t) \right) \hat{\theta} = \sum_{t=1}^N \varphi(t) y(t).$$

La matrice $\sum \varphi \varphi^T$ contiene l'informazione disponibile nei regressori. Se è invertibile, i dati permettono di distinguere tutti i parametri; se è singolare, alcune combinazioni di parametri producono lo stesso predittore.

11 Identificabilità

- *Strutturale*: legata alla struttura adottata per il modello.
- *Sperimentale*: legata alle caratteristiche dell'esperimento.

Esempio 6. Sistema vero S : $G^\circ(z) = \frac{z}{(z+0.5)(z+0.3)}$. Modello $\mathcal{M}(\theta)$: $y(t) = a_1 y(t-1) + a_2 y(t-2) + a_3 y(t-3) + b_1 u(t-1) + b_2 u(t-2)$, $\theta = [a_1, a_2, a_3, b_1, b_2]^T$, $G(z) = \frac{z(b_1 z + b_2)}{(z-\delta_1)(z-\delta_2)(z-\delta_3)}$. S è incluso nella famiglia di modelli? Sì! esistono infinite triplette (b_1, b_2, δ_3) , ovvero infinite soluzioni per il problema di identificazione, che danno luogo a quel modello: struttura "sovradimensionata" rispetto a S .

Esempio 7. Consideriamo lo stesso sistema e supponiamo un ingresso costante:

$$u(t) = \bar{u}.$$

Definiamo il guadagno statico del sistema come

$$\mu_0 = G(z)|_{z=1}.$$

Di conseguenza, l'uscita a regime vale

$$\bar{y} = \mu_0 \bar{u}.$$

Nel caso in esame si ha

$$\mu_0 = G(z)|_{z=1} = \frac{b_1 + b_2}{1 - a_1 - a_2 - a_3}.$$

Quindi, da misure a regime, si può stimare

$$\mu_0 = \frac{\bar{y}}{\bar{u}}.$$

Osservazione: in questo modo non si riesce a risalire ai singoli parametri, ma solo al loro rapporto complessivo che determina il guadagno statico.

Per questo motivo bisogna lavorare con quantità aggregate come $S(N)$ oppure $R(N)$; noi studieremo una delle due formulazioni, che è equivalente all'altra.

Spiegazione – Identificabilità strutturale e sperimentale

L'identificabilità strutturale riguarda la famiglia scelta: chiede se parametri diversi possono descrivere lo stesso sistema. Se la struttura è sovradimensionata, possono esistere infiniti parametri equivalenti.

L'identificabilità sperimentale riguarda invece i dati raccolti. Anche se la struttura è corretta, un esperimento poco informativo può non eccitare abbastanza il sistema. L'esempio dell'ingresso costante mostra che da dati a regime si può stimare il guadagno statico, ma non i singoli parametri dinamici.

Per questo si studia la matrice

$$R(N) = \frac{1}{N} \sum_{t=1}^N \varphi(t) \varphi^T(t),$$

che misura quanta informazione sui parametri è contenuta nei regressori.

Studiamo $R(N)$

$$R(N) = \frac{1}{N} \sum_{t=1}^N \varphi(t) \varphi^T(t)$$

Per $N \rightarrow \infty$,

$$\bar{R} = \lim_{N \rightarrow \infty} R(N) = \mathbb{E}[\varphi(t) \varphi^T(t)].$$

Se $\bar{R}$ è invertibile si può sperare che anche $R(N)$ lo sia per N grande (con "tante" osservazioni).

Esempio 8. $ARX(1,1)$:

$$\varphi(t) = [y(t-1) \quad u(t-1)]^T$$

$$\varphi(t) \varphi^T(t) = \begin{bmatrix} y^2(t-1) & y(t-1)u(t-1) \\ y(t-1)u(t-1) & u^2(t-1) \end{bmatrix}$$

$$R(N) = \frac{1}{N} S(N) = \frac{1}{N} \sum \varphi(t) \varphi^T(t) = \begin{bmatrix} \frac{1}{N} \sum y^2(t-1) & \frac{1}{N} \sum y(t-1)u(t-1) \\ \frac{1}{N} \sum y(t-1)u(t-1) & \frac{1}{N} \sum u^2(t-1) \end{bmatrix}$$

$$\frac{1}{N} \sum y^2(t-1) = \gamma_{yy}(0) \quad N \rightarrow \infty$$

$$\bar{R} = \begin{bmatrix} \gamma_{yy}(0) & \gamma_{yu}(0) \\ \gamma_{uy}(0) & \gamma_{uu}(0) \end{bmatrix}$$

Per ARX(n_a, n_b), (ARX generico)

$$\varphi(t) = \left[\underbrace{y(t-1) \ y(t-2) \ \cdots \ y(t-n_a)}_{n_a} \ \underbrace{u(t-1) \ \cdots \ u(t-n_b)}_{n_b} \right]^T$$

$$\bar{R} = \begin{bmatrix} \bar{R}_{yy}^{n_a} & \bar{R}_{yu} \\ \bar{R}_{uy} & \bar{R}_{uu}^{n_b} \end{bmatrix},$$

dove $\bar{R}_{uu}^{n_b}$ è la matrice di Toeplitz (così, una piccola curiosità)

$$\bar{R}_{uu}^{n_b} = \begin{bmatrix} \begin{bmatrix} u(t-1) \\ u(t-2) \\ \vdots \\ u(t-h_b) \end{bmatrix} & \begin{bmatrix} u(t-1) & u(t-2) & \cdots & u(t-h_b) \end{bmatrix} \end{bmatrix}$$

$$\bar{R}_{yy}^{n_a} = \begin{bmatrix} \begin{bmatrix} y(t-1) \\ \vdots \\ y(t-h_a) \end{bmatrix} & \begin{bmatrix} y(t-1) & \cdots & y(t-h_a) \end{bmatrix} \end{bmatrix}$$

Quelli incrociati non li scriviamo tanto non ci serviranno.

$$\bar{R}_{uu}^{n_b} = \begin{bmatrix} \gamma_{uu}(0) & \gamma_{uu}(1) & \cdots & \gamma_{uu}(n_b-1) \\ \gamma_{uu}(1) & \gamma_{uu}(0) & & \vdots \\ \vdots & & \ddots & \\ \gamma_{uu}(n_b-1) & \cdots & & \gamma_{uu}(0) \end{bmatrix}.$$

Per l'identificabilità è necessario che $\bar{R}$ sia invertibile.

Essendo

$$\bar{R} = E[\varphi(t) \varphi^T(t)],$$

si ha che $\bar{R}$ è semidefinita positiva.

Quindi, condizione necessaria per l'identificabilità:

$$\bar{R} \text{ definita positiva} \iff x^T \bar{R} x > 0, \quad \forall x \neq 0.$$

In particolare, tale condizione deve valere per vettori del tipo

$$x = \begin{bmatrix} 0 \\ \tilde{x} \end{bmatrix} \quad \begin{matrix} \} n_a \\ \} n_b \end{matrix}$$

In questo caso si ottiene

$$x^T \bar{R} x = \tilde{x}^T \bar{R}_{uu}^{n_b} \tilde{x}.$$

Quindi una condizione necessaria per l'identificabilità è

$$\boxed{\bar{R}_{uu}^{n_b} \text{ definita positiva}}.$$

(gli ingressi li scelgo io!)

Questa è quindi una condizione sugli ingressi, e fornisce un criterio utile per la progettazione dell'esperimento.

Spiegazione – Ruolo della matrice $\bar{R}$

La matrice limite

$$\bar{R} = \mathbb{E}[\varphi(t)\varphi^T(t)]$$

riassume l'informazione media contenuta nei dati. Se $\bar{R}$ è definita positiva, allora ogni direzione nello spazio dei parametri modifica in modo osservabile il predittore. Se invece esiste un vettore non nullo x tale che

$$x^T \bar{R} x = 0,$$

allora una certa combinazione dei regressori è nulla o ridondante, quindi i parametri lungo quella direzione non possono essere stimati in modo univoco.

La sottomatrice $\bar{R}_{uu}^{n_b}$ riguarda solo l'ingresso. Per identificare bene la parte legata a $B(z)$, l'ingresso deve essere abbastanza ricco da rendere questa matrice definita positiva.

11.1 Ingressi persistentemente eccitanti di ordine n

Definizione 2. $u(\cdot)$ è un segnale persistentemente eccitante di ordine n se $\bar{R}_{uu}^n$ è invertibile.

Per identificare $\text{ARX}(n_a, n_b)$ è necessario un ingresso PE di ordine n_b .

Esempio 9. Rumore bianco $u(\cdot) \sim WN(0, \sigma^2) \Rightarrow \bar{R}_{uu}^{n_b} = \sigma^2 I_{n_b \times n_b}$. ($u(\cdot)$ segnale PE di ordine qualunque) Nota: R_{uu}^{n-1} è sottomatrice di R_{uu}^n , se $u(\cdot)$ è PE di ordine n lo sarà anche di ordine $n-1$ e inferiori.

Interpretazione in frequenza.

$$\alpha = [\alpha_1 \quad \alpha_2 \quad \cdots \quad \alpha_n]^T$$

consideriamo $\tilde{u}(\cdot)$ ottenuto filtrando $u(\cdot)$

$$\tilde{u}(t) = \alpha_1 u(t-1) + \alpha_2 u(t-2) + \cdots + \alpha_n u(t-n)$$

f.d.t del filtro

$$\begin{aligned} H_\alpha(z) &= \alpha_1 z^{-1} + \alpha_2 z^{-2} + \cdots + \alpha_n z^{-n} \\ &= \frac{\alpha_1 z^{n-1} + \alpha_2 z^{n-2} + \cdots + \alpha_n}{z^n} \end{aligned}$$

$$\tilde{u}(t) = H_\alpha(z)u(t)$$

$\tilde{u}(t)$ processo GMA (MA generalizzato)

$$\rightarrow \text{Varianza} \quad \text{Var}[\tilde{u}(t)] = \alpha^T \bar{R}_{uu}^n \alpha$$

$$\forall \text{ processo} \quad \text{Var}[\tilde{u}(t)] = \frac{1}{2\pi} \int_{-\pi}^{\pi} \varphi_{\tilde{u}\tilde{u}}(\omega) d\omega$$

Teorema fondamentale dell'analisi spettrale

$$\varphi_{\tilde{u}\tilde{u}}(\omega) = |H_\alpha(e^{j\omega})|^2 \varphi_{uu}(\omega)$$

concludendo

$$\text{Var}[\tilde{u}(t)] = \alpha^T \bar{R}_{uu}^n \alpha = \frac{1}{2\pi} \int_{-\pi}^{\pi} |H_\alpha(e^{j\omega})|^2 \varphi_{uu}(\omega) d\omega.$$

Questa, $\forall \alpha$ deve essere > 0 affinché sia PE di ordine n .
se esiste almeno un $\alpha \neq 0$ tale che

$$\int_{-\pi}^{\pi} |H_\alpha(e^{j\omega})|^2 \varphi_{uu}(\omega) d\omega = 0.$$

non è persistentemente eccitante di ordine n .

Se la densità spettrale di $u(\cdot)$ è non nulla per almeno n frequenze ω distinte, allora non esiste $\alpha \neq 0$ che annulli l'integrale, dunque $u(\cdot)$ è PE di ordine n .

Spiegazione – Ingressi persistentemente eccitanti

Un ingresso persistentemente eccitante di ordine n contiene abbastanza variazione per stimare modelli con n ritardi dell'ingresso. In termini matriciali, significa che la matrice di autocovarianza dei regressori d'ingresso è invertibile:

$$\bar{R}_{uu}^n > 0.$$

In termini frequenziali, significa che lo spettro dell'ingresso non è concentrato in troppo poche frequenze. Un rumore bianco è l'esempio ideale: ha spettro piatto e quindi eccita tutte le frequenze.

Questa nozione è importante nella progettazione dell'esperimento: se posso scegliere $u(t)$, devo sceglierlo in modo da rendere osservabili le dinamiche che voglio identificare.

12 Stima ARMA/ARMAX: Gauss–Newton iterativo

Ricordo, ARMAX:

$$M(\theta) : \quad A(z)y(t) = B(z)u(t-1) + C(z)\xi(t)$$

Forma di Predizione:

$$C(z)\hat{y}(t) = [C(z) - A(z)]y(t) + B(z)u(t-1)$$

Non lineare nei parametri.

$$J(\theta) = \frac{1}{N} \sum_{t=1}^N \varepsilon^2(t) \quad \varepsilon(t) = y(t) - \hat{y}(t)$$

$$\varepsilon(t) ?$$

$$A(z)y(t) - C(z)\hat{y}(t) = B(z)u(t-1) + C(z)\xi(t) - [C(z) - A(z)]y(t) - B(z)u(t-1)$$

Dopo qualche manipolazione

$$C(z)\varepsilon(t) = C(z)\xi(t) \quad \rightarrow \quad \boxed{C(z)\varepsilon(t) = A(z)y(t) - B(z)u(t-1)}$$


Quindi, per ARMAX il funzionale $J(\theta)$ non è quadratico nei parametri: si usa un algoritmo iterativo (procedura iterativa di minimizzazione, fino a convergenza).

$$C(z)\hat{y}(t) = [C(z) - A(z)]y(t) + B(z)u(t-1), \quad C(z)\varepsilon(t) = A(z)y(t) - B(z)u(t-1).$$

Metodo di Gauss-Newton iterativo: Ad ogni iterazione approssimiamo $J(\theta)$ con una forma quadratica $V(\theta)$ e calcoliamo il minimo, all'iterazione r -esima avrò che il minimo è $\theta^{(r)}$. Dato $\theta^{(r)}$, $V(\theta)$ è t.c.

- $V(\theta)$ coincide con $J(\theta)$ in $\theta^{(r)}$
- il gradiente di $V(\theta)$ e di $J(\theta)$ coincidono in $\theta^{(r)}$
- l'Hessiano $V(\theta)$ e di $J(\theta)$ coincidono in $\theta^{(r)}$

Esempio grafico in 2D:



$$V(\theta) = J(\theta^{(r)}) + \frac{dJ(\theta^{(r)})}{d\theta}(\theta - \theta^{(r)}) + \frac{1}{2}(\theta - \theta^{(r)})^T \frac{d^2 J(\theta^{(r)})}{d\theta^2}(\theta - \theta^{(r)}).$$

Il punto di minimo di $V(\theta)$ è

$$\theta^{(r+1)} = \theta^{(r)} - \left(\frac{d^2 J(\theta^{(r)})}{d\theta^2} \right)^{-1} \left(\frac{dJ(\theta^{(r)})}{d\theta} \right)^T.$$

Si itera fino a convergenza: $\Delta\theta$ o ΔJ sono “piccoli”

- NON è garantita convergenza a minimo globale
- Può portare Direzione di salita (se Hessiano non è Semi Def. Positivo)

Spiegazione – Idea del metodo di Gauss–Newton

Nei modelli ARMA/ARMAX il criterio

$$J(\theta) = \frac{1}{N} \sum_{t=1}^N \varepsilon^2(t)$$

non è una funzione quadratica semplice dei parametri, perché l'errore dipende da filtri che contengono i parametri stessi. Per questo non esiste, in generale, una formula chiusa come nei minimi quadrati ARX.

Gauss–Newton procede iterativamente. A partire da una stima corrente $\theta^{(r)}$, si approssima localmente il criterio con una funzione quadratica più semplice, si minimizza questa approssimazione e si ottiene un nuovo valore $\theta^{(r+1)}$. Il procedimento si ripete finché i parametri o il valore di J cambiano poco.

Gradiente e Hessiano dai dati. Introduciamo $\psi(t) = -\frac{d\varepsilon(t)}{d\theta}^T$, Abbiamo

$$J(\theta) = \sum_{t=1}^N \varepsilon^2(t)$$

Gradiente:

$$\frac{dJ}{d\theta} = \frac{2}{N} \sum_{t=1}^N \varepsilon(t) \frac{d\varepsilon(t)}{d\theta} = -\frac{2}{N} \sum_{t=1}^N \varepsilon(t) \psi^T(t),$$

Hessiano:

$$\frac{d^2 J(\theta)}{d\theta^2} = \frac{2}{N} \sum_{t=1}^N \left(\varepsilon(t) \frac{d^2 \varepsilon(t)}{d\theta^2} + \frac{d\varepsilon^T(t)}{d\theta} \frac{d\varepsilon(t)}{d\theta} \right) = \frac{2}{N} \sum_{t=1}^N \left[\psi(t) \psi^T(t) + \varepsilon(t) \frac{d^2 \varepsilon(t)}{d\theta^2} \right] \approx \frac{2}{N} \sum_{t=1}^N \psi(t) \psi^T(t).$$

(forma quadratica, sempre discesa)

Quindi

$$\theta^{(r+1)} \approx \theta^{(r)} + \left(\sum_{t=1}^N \psi(t) \psi^T(t) \right)^{-1} \sum_{t=1}^N \varepsilon(t) \psi(t).$$

(il trasposto va via col trasposto di ψ)

Spiegazione – Ruolo di $\psi(t)$

Il vettore

$$\psi(t) = -\frac{d\varepsilon(t)}{d\theta}^T$$

misura quanto l'errore di predizione cambia se si modificano i parametri. E' quindi una sensibilita' del residuo rispetto al modello.

La matrice

$$\sum_{t=1}^N \psi(t) \psi^T(t)$$

ha un ruolo analogo alla matrice dei regressori nei minimi quadrati. Se questa matrice e' ben condizionata, le direzioni dei parametri sono distinguibili localmente. Il termine

$$\sum_{t=1}^N \varepsilon(t) \psi(t)$$

indica invece in quale direzione modificare i parametri per ridurre l'errore.

Determinazione di $\varepsilon(t)$ e $\psi(t)$ dai dati

$\varepsilon(t)$ è legato ai dati $C(z)\varepsilon(t) = A(z)y(t) - B(z)u(t-1)$, filtrando $y(t)$ e $u(t-1)$ con $A(z)/C(z)$ e $B(z)/C(z)$ si ottiene $\varepsilon(t)$. E per quanto riguarda ψ ? ricordo $\psi(t) = -\frac{d\varepsilon(t)}{d\theta}^T$, θ contiene a_i, b_j, c_k .
Ho il vettore:

$$\psi(t) = [\alpha_1(t) \dots \alpha_{n_a}(t) \beta_1(t) \dots \beta_{n_b}(t) \gamma_1(t) \dots \gamma_{n_c}(t)]^T,$$

Da cui: $\alpha_i(t) = -\frac{d\varepsilon(t)}{da_i}$, e via dicendo per gli altri.
come ottenere $\alpha_i, \beta_j, \gamma_k$?

$$-C(z)\alpha_i(t) = -y(t-i)$$

↓

$$+C(z)\alpha_i(t) = +y(t-i)$$

$$\alpha_1(t) = \frac{1}{C(z)} y(t-1)$$

$$\alpha_2(t) = \frac{1}{C(z)} y(t-2) = \frac{1}{C(z)} z^{-1} y(t-1) = \alpha_1(t-1)$$

$$\alpha_3(t) = \alpha_1(t-2)$$

$$\alpha_4(t) = \alpha_1(t-3)$$

$$\vdots$$

e così via

Definisco α soluzione di

$$C(z)\alpha(t) = y(t)$$

$$\Rightarrow \boxed{\alpha_i(t) = \alpha(t-i)}$$

Nota: questo α è una nuova cosa definita ora come soluzione di questa equazione, non c'entra con gli α_i .

Per β_j :

$$-C(z)\beta_j(t) = -u(t-j)$$

$$\downarrow$$

$$+C(z)\beta_j(t) = +u(t-j)$$

$$C(z)\beta(t) = u(t)$$

$$\beta_j(t) = \beta(t-j)$$

(stessa cosa di prima)

Per γ_k :

$$-C(z)\gamma_k(t) + \varepsilon(t-k) = 0$$

$$C(z)\gamma_k(t) = \varepsilon(t-k)$$

$$C(z)\gamma(t) = \varepsilon(t)$$

$$\downarrow$$

$$\gamma_k(t) = \gamma(t - k)$$

(stessa cosa di prima)

Otteniamo così:

$$\psi(t) = [\alpha(t-1) \quad \cdots \quad \alpha(t-n_a) \quad \beta(t-1) \quad \cdots \quad \beta(t-n_b) \quad \gamma(t-1) \quad \cdots \quad \gamma(t-n_c)]^T$$

Schema iterativo. Iterazione $r \rightarrow r+1$ (noto $\theta^{(r)}$):

1. Determinare stime dei polinomi $A^{(r)}, B^{(r)}, C^{(r)}$.
2. Filtrare i dati disponibili per ottenere $\alpha^{(r)}(t)$ e $\beta^{(r)}(t)$, ovvero:

$$C^{(r)}(z)\alpha(t) = y(t) \quad \rightarrow \quad \alpha^{(r)}(t)$$

$$C^{(r)}(z)\beta(t) = u(t) \quad \rightarrow \quad \beta^{(r)}(t)$$

3. Ricavare $\varepsilon(\cdot)$ per ottenere $\gamma(\cdot)$, ovvero:

$$C^{(r)}(z)\varepsilon(t) = A^{(r)}(z)y(t) - B^{(r)}(z)u(t-1)$$

Filtro $\varepsilon(\cdot)$ per ottenere $\gamma(\cdot)$

$$C(z)\gamma(t) = \varepsilon(t) \quad \rightarrow \quad \gamma^{(r)}(t)$$

4. Ottengo così

$$\psi(t) = [\alpha^{(r)}(t-1) \quad \cdots \quad \alpha^{(r)}(t-n_a) \quad \beta^{(r)}(t-1) \quad \cdots \quad \beta^{(r)}(t-n_b) \quad \gamma^{(r)}(t-1) \quad \cdots \quad \gamma^{(r)}(t-n_c)]^T$$

5. Calcolare $\theta^{(r+1)}$ (attenzione alle singularità di $C^{(r)}(z)$).

$$\text{Ricordo: } \theta^{(r+1)} = \theta^{(r)} + [\sum \psi(t)\psi^T(t)]^{-1} [\sum \varepsilon(t)\psi^T(t)]^T$$

Spiegazione – Schema iterativo e filtri ausiliari

A ogni iterazione si fissano temporaneamente i polinomi $A^{(r)}, B^{(r)}, C^{(r)}$. Con questi si filtrano i dati per ottenere:

$$C^{(r)}(z)\alpha(t) = y(t), \quad C^{(r)}(z)\beta(t) = u(t),$$

e poi si calcola il residuo $\varepsilon(t)$ e la sequenza $\gamma(t)$. Queste sequenze filtrate servono a costruire il vettore $\psi(t)$.

Il metodo somiglia ai minimi quadrati, ma con regressori che cambiano a ogni iterazione. Questa è la differenza essenziale rispetto al caso ARX: nei modelli ARMAX i regressori dipendono dai parametri stimati, quindi devono essere aggiornati progressivamente.

13 Analisi asintotica e scenari di identificazione

Sia $\{\mathcal{M}(\theta) \mid \theta \in \Theta\}$ modello ottimo minimizzando

$$J_N(\theta) = \frac{1}{N} \sum_t \varepsilon_\theta^2(t), \quad \text{con } \varepsilon_\theta(t) = y(t) - \hat{y}_\theta(t) \quad (\text{errore di previsione}).$$

Si arriva alla soluzione $\hat{\theta}_N$.

Analisi asintotica per $N \rightarrow \infty$, $J_N(\theta, s) \rightarrow \bar{J}(\theta)$ (s è l'esperimento)

$\hat{\theta}_N \rightarrow \bar{\theta}$ minimo della funzione deterministica $\bar{J}(\theta)$.

Il modello per cui andiamo a studiare la bontà, ovvero quanto bene rappresenta i dati, è il modello stimato asintoticamente $\mathcal{M}(\bar{\theta})$. Se il minimo non è unico studiamo Δ , insieme dei punti di minimo e $\{\mathcal{M}(\theta) \mid \theta \in \Delta\}$

Esempio 10. S (sistema vero) appartiene alla classe di modelli $\exists! \theta^0 \in \Theta$ t.c. $\mathcal{M}(\theta^0) \equiv S$ o in alternativa ci chiediamo se $\hat{\theta}_N \rightarrow \theta^0$?

$$S : A^0(z)y(t) = B^0(z)u(t-1) + C^0(z)\eta(t) \quad \text{con } \eta(t) \sim WN(0, \sigma^2)$$

$$A^0, B^0, C^0 \text{ Polinomi corrispondenti a } \theta^0$$

Famiglia di modelli considerati:

$$\mathcal{M} : A(z)y(t) = B(z)u(t-1) + C(z)\xi(t)$$

Assumiamo A, B, C dello stesso ordine di A^0, B^0, C^0

Errore di Predizione:

$$\varepsilon(t) = \frac{A(z)}{C(z)}y(t) - \frac{B(z)}{C(z)}u(t-1)$$

Apriamo una parentesi: se consideriamo A^0, B^0, C^0

$\varepsilon(t)$ coincide con $\mu(t)$ rumore bianco che ha generato il Processo. (che poi dovrebbe essere η ma dettagli)

Altrimenti NON possiamo dire neanche che è WN.

$$M(\hat{\theta}_N) \rightarrow S ?$$

$$\varepsilon_\theta(t) = y(t) - \hat{y}_\theta(t) = (y(t) - \hat{y}_{\theta^0}(t)) + (\hat{y}_{\theta^0}(t) - \hat{y}_\theta(t))$$

$\hat{y}_{\theta^0}$ Predizione a un passo se ho i Parametri giusti

$$J = \frac{1}{N} \sum_{t=1}^N \varepsilon_\theta^2(t)$$

$$\Rightarrow \bar{J}(\theta) = E[\varepsilon_\theta^2(t)] = E[(y(t) - \hat{y}_{\theta^0}(t))^2] + \overbrace{E[(\hat{y}_{\theta^0}(t) - \hat{y}_\theta(t))^2]}^{\text{forma quadratica}} + 2E \underbrace{\left[\overbrace{(y(t) - \hat{y}_{\theta^0}(t))}^{WN: \mu(t)} \overbrace{(\hat{y}_{\theta^0}(t) - \hat{y}_\theta(t))}^{\text{entrambi predittori funzioni di } y, u \text{ fino a } t-1} \right]}_{=0}$$

Dunque:

$$\bar{J}(\theta) \geq \underbrace{E[(y(t) - \hat{y}_{\theta^0}(t))^2]}_{\bar{J}(\theta^0)}$$

θ^0 punto di minimo per $\bar{J}(\theta)$, se $\bar{J}(\theta)$ ha un unico minimo globale $\rightarrow$ a questo convergiamo.

se abbiamo più minimi globali convergiamo a θ^0 o ad un $\bar{\theta}$ t.c.

$$\bar{J}(\bar{\theta}) = \bar{J}(\theta^0)$$

Spiegazione – Quando il sistema vero appartiene alla famiglia

Supponiamo che il sistema vero S appartenga alla famiglia di modelli considerata. Questo significa che esiste almeno un parametro $\theta^0 \in \Theta$ tale che

$$\mathcal{M}(\theta^0) = S.$$

In altre parole, per una scelta opportuna dei parametri, il modello coincide esattamente con il sistema che ha generato i dati.

Il sistema vero può essere scritto nella forma

$$A^0(z)y(t) = B^0(z)u(t-1) + C^0(z)\eta(t),$$

dove $\eta(t)$ è il rumore bianco generatore del processo. Se si costruisce l'errore di predizione usando proprio i polinomi veri $A^0(z)$, $B^0(z)$ e $C^0(z)$, si ottiene

$$\varepsilon_{\theta^0}(t) = \frac{A^0(z)}{C^0(z)}y(t) - \frac{B^0(z)}{C^0(z)}u(t-1) = \eta(t).$$

Quindi, usando il modello corretto, l'errore di predizione coincide con l'innovazione del processo: la parte nuova di $y(t)$ che non può essere prevista a partire dal passato.

Per un generico parametro θ , l'errore di predizione può essere scomposto aggiungendo e sottraendo la predizione ottenuta con il parametro vero:

$$\varepsilon_{\theta}(t) = y(t) - \hat{y}_{\theta}(t) = (y(t) - \hat{y}_{\theta^0}(t)) + (\hat{y}_{\theta^0}(t) - \hat{y}_{\theta}(t)).$$

Il primo termine,

$$y(t) - \hat{y}_{\theta^0}(t),$$

è l'innovazione vera. Il secondo termine,

$$\hat{y}_{\theta^0}(t) - \hat{y}_{\theta}(t),$$

misura invece quanto il predittore associato a θ differisce dal predittore corretto.

Passando al costo medio asintotico,

$$\bar{J}(\theta) = E[\varepsilon_{\theta}^2(t)],$$

si ottiene

$$\bar{J}(\theta) = E[(y(t) - \hat{y}_{\theta^0}(t))^2] + E[(\hat{y}_{\theta^0}(t) - \hat{y}_{\theta}(t))^2] + 2E[(y(t) - \hat{y}_{\theta^0}(t))(\hat{y}_{\theta^0}(t) - \hat{y}_{\theta}(t))].$$

Il termine incrociato è nullo perché l'innovazione al tempo t è incorrelata con qualunque quantità costruita usando l'informazione disponibile fino a $t-1$. Entrambi i predittori, infatti, dipendono solo dai dati passati.

Rimane quindi

$$\bar{J}(\theta) = J(\theta^0) + E[(\hat{y}_{\theta^0}(t) - \hat{y}_{\theta}(t))^2],$$

dove

$$J(\theta^0) = E[(y(t) - \hat{y}_{\theta^0}(t))^2].$$

Poiché il secondo termine è sempre non negativo, segue che

$$\bar{J}(\theta) \geq J(\theta^0).$$

Dunque θ^0 è un punto di minimo della funzione costo asintotica.

Se tale minimo è unico, allora la stima asintotica converge al parametro vero:

$$\hat{\theta}_N \rightarrow \theta^0.$$

Se invece esistono più minimi globali, la stima può convergere a un parametro diverso $\bar{\theta}$, purché produca lo stesso valore minimo del costo:

$$\bar{J}(\bar{\theta}) = J(\theta^0).$$

In questo caso il modello stimato è equivalente al sistema vero dal punto di vista della predizione, ma il parametro non è identificabile in modo univoco.

Esempio 11. *Altro esempio:*

S fuori dalla classe di modelli considerati

$$S : MA \quad y(t) = \eta(t) + c\eta(t-1) \quad \eta(t) \sim WN(0, \sigma^2)$$

$$c \neq 0 \quad y(\cdot) \text{ processo stazionario a media nulla con covarianza}$$

$$\gamma_{yy}(0) = (1 + c^2)\sigma^2$$

$$\gamma_{yy}(1) = c\sigma^2$$

Modello per Identificazione:

$$AR(1)$$

$$\hat{M}(\theta) = \hat{M}(a) : \quad \hat{y}(t) = a y(t-1)$$

$$\bar{J}(\theta) = E[(y(t) - \hat{y}(t))^2] = E[(y(t) - a y(t-1))^2]$$

$$= E[y^2(t)] + a^2 E[y^2(t-1)] - 2a E[y(t)y(t-1)]$$

$$= \gamma_{yy}(0) + a^2 \gamma_{yy}(0) - 2a \gamma_{yy}(1) = (1 + a^2) \gamma_{yy}(0) - 2a \gamma_{yy}(1)$$

$$\frac{d\bar{J}(\theta)}{da} = 0 \quad \Rightarrow \quad 2a \gamma_{yy}(0) - 2 \gamma_{yy}(1) = 0$$

$$\Rightarrow \quad \bar{a} = \underbrace{\frac{\gamma_{yy}(1)}{\gamma_{yy}(0)}}_{a \text{ ottimo dipende da } c} = \frac{c}{1 + c^2}$$

Posso accorgermi che il miglior AR(1) NON rappresenta S?

$$\varepsilon(t) = y(t) - \hat{y}(t) = y(t) - \bar{a}y(t-1)$$

con:

$$y(t) = \eta(t) + c\eta(t-1)$$

ovvero, $y(t)$ comb lineare di $\eta(t)$ e $\eta(t-1)$ mentre $y(t-1)$ comb lineare di $\eta(t-1)$ e $\eta(t-2) \rightarrow \varepsilon$ combinazione lineare di $\eta(t)$, $\eta(t-1)$ ed $\eta(t-2) \rightarrow MA(2)$ DUNQUE NON è WN!

Spiegazione – Quando il sistema vero non appartiene alla famiglia

Se il sistema vero non è contenuto nella famiglia scelta, la stima non può convergere al sistema vero. Converte invece al modello che, dentro quella famiglia, minimizza l'errore di predizione medio.

Nell'esempio, il sistema vero è $MA(1)$, ma si identifica un $AR(1)$. Il valore ottimo di a diventa

$$\bar{a} = \frac{\gamma_{yy}(1)}{\gamma_{yy}(0)}.$$

Questo è il miglior $AR(1)$ possibile secondo il criterio quadratico, ma non coincide con il processo vero. Il residuo risultante non è bianco: contiene ancora struttura. Questo mostra perché la validazione dei residui è essenziale.

Piccolo Recap

$$\theta^0 \rightarrow \text{Studio Asintotico } \bar{J}(\theta)$$

2 esempi

$$\begin{cases} ARMAX & \text{con } S \in M(\theta) \rightarrow \theta^0 \text{ è un punto di minimo, eventualmente con altri} \\ MA & \text{con } S \notin M(\theta) \rightarrow \text{Identificare con AR} \end{cases}$$

$$AR/ARX \rightarrow \text{minimi quadrati} \quad J(\theta) = \frac{1}{N} \sum \varepsilon_{\theta}^2(t)$$

$$ARMA/ARMAX \rightarrow G-N \text{ Iterativo}$$

Fissata la famiglia di modelli $\mathcal{M}(\theta) \mid \theta \in \Theta$ ho N dati a disposizione $\rightarrow$ il $\hat{\theta}$ selezionato è il punto di minimo di $J(\theta)$ con $\varepsilon_{\theta}(t)$ errore di Predizione Asintoticamente convergente a


$$\bar{J}(\theta) = E[\varepsilon_{\theta}^2(t)]$$

Ci aspettiamo che la stima converga al minimo di $\bar{J}(\theta)$.


Chiamiamo Δ (insieme dei punti di minimo di $\bar{J}(\theta)$).

Scenari.


1. S incluso nella famiglia e Δ è un unico punto $\bar{\theta} \equiv \theta^0$ (quello vero) (con $S = M(\theta^0)$): $\hat{\theta}_N \rightarrow \theta^0$.




2. S non incluso nella famiglia e Δ unico punto: $\bar{J}$ ha un unico punto di minimo $\bar{\theta}$, quindi la stima converge a $\bar{\theta}$ e $\mathcal{M}(\bar{\theta})$ migliore approssimazione di S nella famiglia.



3. S nella famiglia, Δ più punti: in $\Delta \exists \theta^0$ tale che il sistema coincide con il modello $S = \mathcal{M}(\theta')$. La stima converge a un punto di Δ (θ^0 o un altro); tutti i modelli in Δ sono equivalenti dal punto di vista dell'errore di predizione.



4. S non nella famiglia, Δ è composto da più punti: tutti i modelli in Δ sono equivalentemente la migliore approssimazione di S nella famiglia.



La stima convergerà a uno dei punti all'interno di Δ .

Spiegazione – Interpretazione dei quattro scenari

Gli scenari combinano due domande:

- il sistema vero appartiene alla famiglia scelta?
- il minimo del costo medio $\bar{J}(\theta)$ e' unico?

Se il sistema appartiene alla famiglia e il minimo e' unico, la stima converge al parametro vero. Se il sistema non appartiene alla famiglia ma il minimo e' unico, si converge alla migliore approssimazione disponibile.

Quando i minimi sono molteplici, i dati e il criterio di stima non distinguono tra piu' modelli equivalenti. In quel caso non ha senso parlare di un singolo parametro identificato, ma di un insieme Δ di parametri che danno la stessa prestazione asintotica.

14 Incertezza di stima

Scenario 1: S nella famiglia, e Δ è un punto $\bar{\theta} = \theta^0$ tale che $S = \mathcal{M}(\theta')$. Come al solito, $\varepsilon(t, \theta)$ errore di predizione, Sia $\psi(t, \theta) = -\frac{d\varepsilon(t, \theta)}{d\theta}^T$, considero la matrice $\bar{R} = \mathbb{E}[\psi(t, \theta^0)\psi^T(t, \theta^0)]$. Si può dimostrare che per N grande, la varianza di $\hat{\theta}_N$ tende a $\frac{1}{N} \text{Var}[\varepsilon(t, \theta^0)] \bar{R}^{-1}$ In altri termini:

$$\sqrt{N}(\hat{\theta}_N - \theta^0) \sim \mathcal{N}(0, \bar{P}), \quad \bar{P} = \text{Var}[\varepsilon(t, \theta^0)] \bar{R}^{-1}.$$

Spiegazione – Significato dell'incertezza di stima

Anche quando il modello è corretto e la stima converge al parametro vero, con un numero finito di dati resta sempre incertezza. La relazione

$$\sqrt{N}(\hat{\theta}_N - \theta^0) \sim \mathcal{N}(0, \bar{P})$$

indica che l'errore di stima decresce come $1/\sqrt{N}$. Equivalentemente, la covarianza della stima decresce come $1/N$.

La matrice

$$\bar{P} = \text{Var}[\varepsilon(t, \theta^0)] \bar{R}^{-1}$$

mostra due fattori: più rumore aumenta l'incertezza, mentre più informazione nei regressori, cioè una $\bar{R}$ grande e ben condizionata, la riduce.

Quantità campionarie. Ricavo una stima della covarianza usando quantità campionarie:

$$\bar{R} \approx \frac{1}{N} \sum \psi(t, \hat{\theta}_N) \psi^T(t, \hat{\theta}_N), \quad \text{Var}[\varepsilon(t, \theta^0)] \approx \frac{1}{N} \sum \varepsilon^2(t, \hat{\theta}_N),$$

(Varianza tende a zero con $\frac{1}{N}$)

Minimi quadrati

$$\hat{y}(t, \theta) = \varphi^T(t) \theta \rightarrow \text{errore di predizione: } \varepsilon(t, \theta) = y(t) - \hat{y}(t, \theta) = y(t) - \varphi^T(t) \theta$$

quindi $\psi(t, \theta) = -\frac{d}{d\theta} \varepsilon(t, \theta)^T = \varphi(t)$, dunque nel caso dei minimi quadrati $\psi(t, \theta) = \varphi(t)$ è indipendente da θ .

$\bar{R}$ si può costruire senza conoscere θ^0

$$\bar{R} = E[\psi(t, \theta^0) \psi^T(t, \theta^0)] = E[\varphi(t) \varphi^T(t)]$$

Per N grande

$$\text{Var}(\hat{\theta}_N - \theta^0) = \frac{1}{N} \text{Var}(\varepsilon(t, \theta^0)) E[\varphi(t) \varphi^T(t)]^{-1} \approx \frac{1}{N} \left(\frac{1}{N} \sum \varepsilon^2(t, \hat{\theta}_N) \right) \left(\frac{1}{N} \sum_{t=1}^N \varphi(t) \varphi^T(t) \right)^{-1}$$

Esempio 12 (AR(1)). $S: y(t) = a^0 y(t-1) + \eta(t)$, $\eta \sim WN(0, \sigma^2)$, $|a^0| < 1$.

$$\text{Stimatore AR(1)} \rightarrow \hat{\mathcal{M}}: \hat{y}(t) = a y(t-1)$$

$$\text{errore di predizione} \rightarrow \varepsilon(t) = y(t) - \hat{y}(t) = y(t) - a y(t-1)$$

$$J_N(a) = \frac{1}{N} \sum \varepsilon^2(t) = \frac{1}{N} \sum (y(t) - a y(t-1))^2$$

$$\frac{dJ_N}{da} = -\frac{2}{N} \sum (y(t) - a y(t-1)) y(t-1) = 0$$

$$\frac{1}{N} \sum y(t) y(t-1) = a \frac{1}{N} \sum y^2(t-1)$$

$$\hat{a}_N = \frac{\frac{1}{N} \sum y(t) y(t-1)}{\frac{1}{N} \sum y^2(t-1)} \xrightarrow{N \rightarrow \infty} \frac{\gamma(1)}{\gamma(0)} = a^0,$$

Questo perché per $AR(1)$ $\gamma(1)$ e $\gamma(0)$ sono legate da $\gamma(1) = a\gamma(0)$ e per S , per N crescenti $\frac{\gamma(1)}{\gamma(0)} = a^0$,

$$\lim_{N \rightarrow \infty} \hat{a}_N = a^0$$

Inoltre $\varphi(t) = y(t-1)$, quindi $\bar{R} = E[\varphi(t)\varphi^T(t)] = E[y^2(t-1)] = \gamma(0)$

Dunque:

$$\text{Var}(\hat{a}_N) = \frac{1}{N} \cdot \frac{\sigma^2}{\gamma(0)} \approx \frac{1}{N} \left[\frac{1}{N} \sum \varepsilon^2(t) \right] \left[\frac{1}{N} \sum y^2(t-1) \right]^{-1}.$$

L'incertezza della stima è inversamente proporzionale al rapporto segnale/rumore.

15 Selezione della complessità del modello

Complessità del modello: quanto il modello rappresentato approssima il sistema. Se $\hat{\theta}_N$ è il punto di minimo adottato, il funzionale $J(\hat{\theta}_N)$ mi dice quanto $\mathcal{M}(\hat{\theta}_N)$ è adeguato ai dati.

1. All'aumentare di N , J è monotona decrescente; in prossimità di un N giusto può esserci un cambio di comportamento, ovvero dopo un certo N avrò una decrescita più contenuta.
2. Si può eseguire il test di bianchezza sull'errore di predizione in corrispondenza di diversi N . In corrispondenza dell' N giusto il test passa da non superato a superato.

Nella realtà è più frequente che $J(\hat{\theta}_N)$ decresca senza cambio netto di comportamento e che non superi il test di bianchezza. Inoltre, aumentare N favorisce il fit sui dati (in parte sul modello e in parte sulla realizzazione del rumore), questo porta all'**OVERFITTING**.

Spiegazione – Complessità e overfitting

Aumentare la complessità del modello significa aumentare il numero di parametri o l'ordine dei polinomi. Un modello più complesso riesce quasi sempre a ridurre l'errore sui dati usati per la stima, perché ha più gradi di libertà. Tuttavia, una parte di questa riduzione può derivare dall'adattamento alla specifica realizzazione del rumore.

Questo fenomeno si chiama overfitting: il modello descrive molto bene il dataset di identificazione, ma generalizza peggio su nuovi dati. Per evitarlo si confrontano modelli di complessità diversa usando dati di validazione o criteri che penalizzano il numero di parametri.

15.1 Processo di Cross-validazione

Questo risolve l'overfitting, dato un dataset di N campioni:

- (A) una parte la uso per l'identificazione (70–80% di N).
- (B) una parte la uso per la validazione (20–30% di N).

Per $n_1 < n < n_2$ uso (A) per ricavare $\hat{\theta}_N$, poi calcolo l'indice di prestazione J su (B). Si sceglie l' N “giusto” per J minimo.

Spiegazione – Cross-validazione

La cross-validazione separa i dati in due insiemi: uno per stimare il modello e uno per valutarlo. Il punto è che il modello non deve essere giudicato solo sui dati che ha già usato per scegliere i parametri.

La procedura è:

- si sceglie una complessità;
- si stimano i parametri usando il dataset A;

- si calcola l'errore di predizione sul dataset B;
- si ripete per complessità diverse e si sceglie quella con errore di validazione minore.

In questo modo si privilegia il modello che predice meglio dati nuovi, non quello che si adatta meglio ai dati di stima.

15.2 Final Prediction Error (FPE)

Capacità di $\mathcal{M}(\theta)$ di rappresentare il processo? Abbiamo a disposizione una realizzazione s $y(t) = y(t, s) \rightarrow$ predittore sarà $\hat{y}(t, S, \theta)$.

Si definisce:

$$\bar{J}(\theta) = \mathbb{E}[(y(t, s) - \hat{y}(t, s, \theta))^2]$$

è la bontà del modello $\mathcal{M}(\theta)$ su tutte le possibili realizzazioni. Se valuto $\bar{J}$ in un punto $\hat{\theta}$, da valutare il fatto che il modello è stimato dai dati $\rightarrow \hat{\theta}_N = \hat{\theta}_N(s)$.

$\bar{J}(\hat{\theta}_N(s))$ rappresenta la bontà del modello $\mathcal{M}(\hat{\theta}_N)$ su tutte le possibili sequenze di dati. (è solo un modello tra gli infiniti che possono essere stimati). Per essere "completamente" oggettivi si usa $\mathbb{E}[\bar{J}(\hat{\theta}_N(S))]$ su tutti gli s . Minimizzare FPE porta alla complessità ottima (non c'è più il problema di overfitting). Voglio da un data set (risultati dall'esperimento) ricostruire una stima della FPE.

$$\text{FPE} = \frac{N+n}{N-n} J(\hat{\theta}_N)^{(n)}, \quad n = n_a + n_b + n_c.$$

Dove n corrisponde al grado di complessità, calcolo quindi J in una complessità di tipo n , e per l' n per cui è minimo ho un comportamento ottimo sulla rappresentazione del modello. Quando n cresce, $\frac{N+n}{N-n}$ cresce ($\frac{N+n}{N-n} \rightarrow \infty$ per $n \rightarrow \infty$), mentre $J(\hat{\theta}_N)$ decresce: FPE inizialmente decresce (domina $J(\hat{\theta}_N)$), poi inizia a crescere (domina il fattore $\frac{N+n}{N-n}$). La complessità scelta è quella che minimizza la FPE.

Spiegazione – FPE, AIC e MDL

FPE, AIC e MDL cercano di bilanciare due effetti opposti:

- il fit sui dati, misurato da $J(\hat{\theta}_N)$;
- la complessità del modello, misurata dal numero di parametri n .

La FPE moltiplica l'errore di stima per un fattore che cresce con n :

$$\text{FPE} = \frac{N+n}{N-n} J(\hat{\theta}_N)^{(n)}.$$

AIC e MDL usano invece una penalizzazione additiva sul logaritmo dell'errore. AIC tende a essere più permissivo, mentre MDL penalizza maggiormente la complessità quando N cresce, favorendo modelli più parsimoniosi.

15.3 Criterio AIC (Akaike Information Criterion)

Usa il Kullback distance tra PDF e PDF dei dati che sarebbero generati dal modello.

$$\text{AIC} = 2 \frac{n}{N} + \ln J(\hat{\theta}_N)^{(n)}$$

complessità ottima si ha per AIC minimo.

$$\ln(\text{FPE}) = \ln\left(1 + \frac{n}{N}\right) - \ln\left(1 - \frac{n}{N}\right) + \ln(J(\hat{\theta}_N)^{(n)})$$

$$\lim_{x \rightarrow 0} \frac{\ln(1+x)}{x} = 1$$

$$\ln(FPE) \approx \frac{n}{N} + \frac{n}{N} + \ln(J(\hat{\theta}_N)^{(n)}) = \frac{2n}{N} + \ln(J(\hat{\theta}_N)^{(n)})$$

Con N "grande" FPE e AIC danno circa lo stesso risultato.

15.4 Criterio MDL (Minimum Description Length)

$$MDL = (\ln N) \frac{n}{N} + \ln J(\hat{\theta}_N)^{(n)}$$

è più conservativo, ci si ferma su indici più piccoli. Sotto l'ipotesi che $S \in$ alla famiglia desiderata, FPE e AIC hanno probabilità non nulla di sovrastimare n ; MDL converge alla corretta complessità n .

16 Scelta della famiglia via dati

Non ci siamo chiesti su cosa lavoriamo, AR, ARX e via dicendo. Classi AR, MA, ARMA $\rightarrow$ passiamo dai dati per capire quale famiglia scegliere, ma come scelgo tra le tre data la sequenza di dati?

Esempio 13 (MA(n)). Per MA di ordine n , la funzione di covarianza per $\tau \geq n+1$ è nulla:

$$\gamma(\tau) \text{ o } \frac{\gamma(\tau)}{\gamma(0)} = 0$$

Esiste un procedimento analogo per AR?

Esempio 14 (AR(1)).

$$y(t) = a_1 y(t-1) + \eta(t) \quad \text{con} \quad \eta(t) \sim WN(0, \sigma^2)$$

Per le equazioni di Y-W:

$$\begin{cases} \gamma(0) = a_1 \gamma(1) + \sigma^2, & \tau = 0, \\ \gamma(\tau) = a_1 \gamma(\tau-1), & \tau \geq 1. \end{cases}$$

Ricavare a_1 dalla seconda equazione come:

$$a_1 = \frac{\gamma(\tau)}{\gamma(\tau-1)}$$

e possiamo ricavare:

$$\sigma^2 = \gamma(0) - a_1 \gamma(1)$$

Questo vale $\forall \tau$, ma sfruttiamo una stima (conviene usare indici di τ bassi, tipo $\tau = 1$):

$$\hat{\gamma}_N(\tau) = \frac{1}{N} \sum_{t=1}^{N-\tau} y(t)y(t+\tau)$$

Ho quindi:

$$a_1 = \frac{\gamma(1)}{\gamma(0)}$$

da cui ricavo

$$\sigma^2 = \gamma(0) - \frac{(\gamma(1))^2}{\gamma(0)}$$

Esempio 15 (AR(2)).

$$\left\{ \begin{array}{l} \gamma(0) = A_1\gamma(1) + A_2\gamma(2) + \Sigma^2 \\ \gamma(1) = A_1\gamma(0) + A_2\gamma(1) \\ \gamma(2) = A_1\gamma(1) + A_2\gamma(0) \end{array} \right\} \quad \begin{bmatrix} A_1 \\ A_2 \end{bmatrix} = \begin{bmatrix} \gamma(0) & \gamma(1) \\ \gamma(1) & \gamma(0) \end{bmatrix}^{-1} \begin{bmatrix} \gamma(1) \\ \gamma(2) \end{bmatrix}$$

$$\Sigma^2 = \gamma(0) - A_1\gamma(1) - A_2\gamma(2)$$

$\gamma(1), \gamma(2), \gamma(0)$ Posso ricavarli dai coeff del Processo AR(2)? Sì!

$$\left\{ \begin{array}{l} A_2 = \frac{1}{\sigma^2} [\gamma(2) - a_1\gamma(1)] \\ A_1 = a_1 - A_2 \frac{\gamma(1)}{\gamma(0)} \\ \Sigma^2 = \sigma^2(1 - A_2^2) \end{array} \right.$$

$$W(z) = \frac{1}{1 - A_1z^{-1} - A_2z^{-2}} = \frac{z^2}{z^2 - A_1z - A_2}$$

$A_2 \rightarrow$ è il prodotto dei poli

$$|A_2| < 1 \quad \rightarrow \quad \Sigma^2 \text{ si riduce perché } (1 - A_2) < 1$$

cosa succede se

$\gamma(2) - a_1\gamma(1) = 0$? Condizioni di Y-W per AR(1)

$$\left\{ \begin{array}{l} A_2 = 0 \\ A_1 = a_1 \\ \Sigma^2 \rightarrow \sigma^2 \end{array} \right.$$

Per AR(n) a un certo punto smetto di calcolarne i parametri perché degenero al caso precedente $\rightarrow$ si riduce ad AR(1).

Covarianza parziale:

$$a_{n+1}^{(n+1)} = \frac{1}{\sigma_{(n)}^2} \left[\gamma(n+1) - \sum_{i=1}^n a_i^{(n)} \gamma(n+1-i) \right],$$

$$a_i^{(n+1)} = a_i^{(n)} - a_{n+1}^{(n+1)} a_{n+1-i}^{(n)}$$

$$\sigma_{(n+1)}^2 = [1 - (a_{n+1}^{(n+1)})^2] \sigma_{(n)}^2.$$

a_{n+1}^{n+1} può essere costruito e manipolato tale per cui se è 0 può suggerire che il processo AR(1) è di ordine n (forse intendeva AR, non AR(1)). In parallelo la chiamo **Covarianza Parziale**

AR, MA, ARMA? Guardo la funzione di covarianza $\gamma(\tau)$, la funzione di covarianza parziale $a_\tau^{(\tau)}$.

Se $\gamma(n) = 0 \rightarrow MA(n)$, altrimenti ARMA usando FPE, AIC, MDL per complessità.

$$\text{Se } a_{n+1}^{(n+1)} = 0 \rightarrow AR(n)$$

Nella realtà sollecitare con un rumore bianco non è banale, si usano solitamente delle approssimazioni del rumore bianco.

Spiegazione – Scelta tra AR, MA e ARMA

La scelta della famiglia può essere guidata dalla forma della funzione di autocovarianza e della covarianza parziale:

- nei modelli MA, l'autocovarianza si annulla oltre l'ordine del modello;
- nei modelli AR, la covarianza parziale si annulla oltre l'ordine del modello;
- nei modelli ARMA, entrambe tendono a decadere senza un taglio netto immediato.

Sui dati reali non si osservano zeri esatti, ma valori piccoli rispetto all'incertezza statistica. Quindi ACF e PACF servono per proporre modelli candidati; la scelta finale va poi verificata con criteri di complessità e test sui residui.

17 Stima:

Comprendere una variabile dalle osservazioni.

Parametri:

- Quantità costanti nel tempo: **Stima statica**
- Stato di un sistema dinamico: evolve nel tempo, **Stima dinamica**

17.1 Stima statica:

Problema: stimare il parametro x dato un insieme di osservazioni $z(j)$.

Modello dell'osservazione $\rightarrow$ funzione $h(\cdot) \rightarrow z(j) = h(j, x, w(j))$, con $w(j)$ disturbo (rumore di misura).

Devo restituire una $\hat{x}(k) = \hat{x}(k, z^k)$ (stimatore), con $z^k = \{z(j)\}_{j=1}^k$. Tutte le misure da 1 a k .

Il valore assunto dallo stimatore per un particolare set di osservazioni prende il nome di stima. Vogliamo quantificare l'errore di stima $\tilde{x} := x - \hat{x}$. Dove x è il valore vero.

Approccio non Bayesiano (alla Fisher) Stimiamo una quantità costante con valore vero e con x_0 non aleatorio (deterministico).

Approccio Bayesiano Stimiamo la variabile aleatoria, descritta da una PDF a priori $f_{\underline{x}}(x)$. Osserviamo che si sia verificata una realizzazione di $\underline{x}$ secondo $f_{\underline{x}}(x)$ e che il valore assunto rimanga costante durante l'osservazione.

Nel caso di identificazione abbiamo determinato le misure attraverso le osservazioni e quindi eravamo nel caso Non bayesiano.

Spiegazione – Stima statica: approccio non bayesiano e bayesiano

Nella stima statica si vuole stimare un parametro costante x usando osservazioni $z(1), \dots, z(k)$. Ci sono due modi concettualmente diversi di vedere x :

- nell'approccio non bayesiano, x è un valore deterministico ignoto;
- nell'approccio bayesiano, x è una variabile aleatoria con distribuzione a priori.

Nel primo caso si usa la verosimiglianza per capire quali valori di x rendono più plausibili le misure osservate. Nel secondo caso si combina la verosimiglianza con l'informazione a priori

per ottenere una distribuzione a posteriori.

17.2 Approccio Bayesiano:

Abbiamo PDF a priori $f_{\bar{x}}(x)$ e vogliamo ricavare una caratterizzazione statistica (PDF) a posteriori rispetto alle osservazioni (esperimento).

$$f_{\bar{x}|z}(x | z) = \frac{f_{\bar{z}|\bar{x}}(z | x) f_{\bar{x}}(x)}{f_z(z)} = \frac{1}{c} \underbrace{f_{\bar{z}|\bar{x}}(z | x)}_{\text{verosimiglianza}} \underbrace{f_{\bar{x}}(x)}_{\text{priori}}.$$

Con

$f_{\bar{x}|z}(x | z) \rightarrow$ PDF a posteriori e $f_z(z)$ rispetto a x è costante

17.3 Approccio Non Bayesiano:

La $f_{\bar{x}}(x)$ qui non esiste. Non possiamo ricavare nemmeno quella a posteriori, dato che non è definita quella a priori, però possiamo usare la verosimiglianza.

$$f_{\bar{z}|\bar{x}}(\bar{z} | x) = \Lambda_z(x)$$

Ovvero quanto x è verosimile rispetto alle mis. $\bar{z}$.

Spiegazione – Verosimiglianza e posterior

La verosimiglianza

$$\Lambda_z(x) = f_{\bar{z}|x}(\bar{z} | x)$$

non è una PDF di x : è una funzione che misura quanto il valore x rende plausibile il dato osservato $\bar{z}$.

Nel caso bayesiano, invece, si costruisce la PDF a posteriori:

$$f_{x|z}(x | z) \propto f_{\bar{z}|x}(z | x) f_x(x).$$

Quindi la posterior è proporzionale al prodotto tra ciò che dicono i dati e ciò che si sapeva prima dell'osservazione.

Bayes:
Prob. Posteriori

$$f_{\bar{x}|z}(x | z) \rightarrow \text{Stimatore MAP (Massimo A Posteriori)}$$

Non Bayes:
Verosimiglianza

$$f_{z|\bar{x}}(\bar{z} | x) \rightarrow \text{MLE (Massima Verosimiglianza)}$$

↓

estriamo la stima come il max per entrambi i casi

$$\hat{X}^{ML}(z) = \arg \max_x \Lambda_z(x) = \arg \max_x f_{z|\bar{x}}(z | x)$$

(Anche se non è il caso Bayessiano $\hat{x}^{ML}(z)$ è sempre aleatoria perché dipende dalle misure) La soluzione è usare la derivata rispetto a x :

$$\frac{d}{dx} \Lambda_z(x) = 0$$

$$\hat{x}^{MAP}(z) = \arg \max_x f_{\bar{x}|z}(x | z) = \arg \max_x f_{z|\bar{x}}(\bar{z} | x) f_{\bar{x}}(x)$$

(Anche $\hat{x}^{MAP}(z)$ è una variabile aleatoria)

Esercizio singola misura, singola osservazione

$$z = x + w \quad \text{caso Gaussiano } W \sim \mathcal{N}(0, \sigma^2)$$

PDF a Priori non disponibile (caso non Bayesiano) Determino la max verosimiglianza ML.

$$\Lambda_z(x) = f_{z|\bar{x}}(z | x) = \mathcal{N}(z | x, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(z-x)^2}{2\sigma^2}}$$

- z è una V.A.
- x (media) e σ^2 sono parametri.

$$\hat{x}^{ML} = \arg \max_x \Lambda_z(x) = z$$

Spiegazione – Esempio ML con una misura gaussiana

Se

$$z = x + w, \quad w \sim \mathcal{N}(0, \sigma^2),$$

allora, fissato x , la misura z ha distribuzione gaussiana centrata in x . La verosimiglianza è

$$\Lambda_z(x) \propto e^{-\frac{(z-x)^2}{2\sigma^2}}.$$

Massimizzare questa funzione equivale a minimizzare $(z-x)^2$. Il valore che rende minima la distanza quadratica tra parametro e misura è quindi

$$\hat{x}^{ML} = z.$$

Con una sola misura e senza prior, la stima di massima verosimiglianza coincide semplicemente con la misura osservata.

PDF a Priori disponibile

$f_{\bar{x}}(x) \sim \mathcal{N}(x; \bar{x}, \sigma_0^2)$ ci aspettiamo che x è indep da W

$$f_{\bar{x}|z}(x | z) = \frac{f_{z|\bar{x}}(z | x) f_{\bar{x}}(x)}{f_z(z)} \propto e^{-\frac{(z-x)^2}{2\sigma^2}} e^{-\frac{(x-\bar{x})^2}{2\sigma_0^2}}$$

$$\rightarrow f_{\bar{x}|z}(x | z) = \mathcal{N}(x; \xi(z), \sigma_1^2)$$

$$\xi(z) = \frac{\sigma^2}{\sigma_0^2 + \sigma^2} \bar{x} + \frac{\sigma_0^2}{\sigma_0^2 + \sigma^2} z$$

$$\sigma_1^2 = \frac{\sigma_0^2 \sigma^2}{\sigma_0^2 + \sigma^2}$$

$$\hat{x}^{MAP}(z) = \xi(z)$$

Spiegazione – MAP gaussiano come media pesata

Quando sia la prior sia il rumore di misura sono gaussiani, anche la posterior e' gaussiana. La stima MAP e' la media della posterior:

$$\hat{x}^{MAP}(z) = \frac{\sigma^2}{\sigma_0^2 + \sigma^2} \bar{x} + \frac{\sigma_0^2}{\sigma_0^2 + \sigma^2} z.$$

La stima e' una media pesata tra informazione a priori $\bar{x}$ e misura z . Se la misura e' molto precisa, cioe' σ^2 e' piccola, pesa di piu' z . Se la prior e' molto precisa, cioe' σ_0^2 e' piccola, pesa di piu' $\bar{x}$.

$$\frac{1}{\sigma_0^2} + \frac{1}{\sigma^2} = \frac{\sigma_0^2 + \sigma^2}{\sigma_0^2 \sigma^2}$$

$$\rightarrow \xi(z) = (\sigma_0^{-2} + \sigma^{-2})^{-1} \sigma_0^{-2} \bar{x} + (\sigma_0^{-2} + \sigma^{-2})^{-1} \sigma^{-2} z$$

i pesi sono inversi proporzionali alle rispettive varianze

$$\sigma_1^{-2} = \sigma_0^{-2} + \sigma^{-2}$$

(l'inverso della varianza si chiama INFORMAZIONE)

(quando è certa)

ML e MAP


sono legati in qualche modo $\rightarrow \exists$ una PDF a Priori $f_{\bar{x}}(x)$

tale che

$$\hat{x}^{ML}(z) \equiv \hat{x}^{MAP}(z) ? \quad \text{Sì!}$$

$$\begin{aligned} f_{\bar{x}|z}(x, z) &= \frac{f_{z|\bar{x}}(z, x) f_{\bar{x}}(x)}{f_z(z)} = \\ &= \frac{f_{z|\bar{x}}(z, x) f_{\bar{x}}(x)}{\int_{-\infty}^{+\infty} f_{z|\bar{x}}(z, x) f_{\bar{x}}(x) dx} = (*) \end{aligned}$$

PDF $f_{\bar{x}}(x) = \varepsilon \quad \text{per } |x| < \frac{4}{2\varepsilon}$



$\varepsilon > 0$ “Piccolo” uniforme su “tutto” il dominio

$$(*) = \frac{f_{z|\bar{x}}(z, x) \varepsilon}{\varepsilon \int_{-\infty}^{+\infty} f_{z|\bar{x}}(z, x) dx} \propto f_{z|x}(z | x)$$

Con $\int_{-\infty}^{+\infty} f_{z|\bar{x}}(z, x) dx$ costante su x

PDF diffusa a tutto il dominio è **non informativa**, non aggiunge niente, tutti i valori sono equiprobabili $\rightarrow \hat{x}^{ML}(z) \equiv \hat{x}^{MAP}(z)$

Spiegazione – Relazione tra ML e MAP

ML e MAP coincidono quando la prior non introduce preferenze tra i valori possibili di x . In modo intuitivo, una prior uniforme molto larga assegna quasi lo stesso peso a tutti i valori rilevanti di x , quindi il massimo della posterior coincide con il massimo della verosimiglianza. Nel caso gaussiano, questo corrisponde al limite

$$\sigma_0^2 \rightarrow \infty.$$

La prior diventa sempre meno informativa, il peso di $\bar{x}$ tende a zero e la stima MAP tende alla stima ML.

MAP Gaussiano:

$$\hat{x}^{MAP}(z) = \xi(z) = \frac{\sigma^2}{\sigma_0^2 + \sigma^2} \bar{x} + \frac{\sigma_0^2}{\sigma_0^2 + \sigma^2} z$$

- $\frac{\sigma^2}{\sigma_0^2 + \sigma^2}$ tende a 0
- $\frac{\sigma_0^2}{\sigma_0^2 + \sigma^2}$ tende a 1

PDF a Priori NON informativa: $\sigma_0^2 \rightarrow \infty$

Minimi quadrati che tira fuori una $\hat{x}$ dai dati è un altro modo di fare stima Non-Bayesiana.

Spiegazione – MAP gaussiana e prior non informativa

La formula MAP gaussiana e' una media pesata tra informazione a priori e misura:

$$\hat{x}^{MAP} = \frac{\sigma^2}{\sigma_0^2 + \sigma^2} \bar{x} + \frac{\sigma_0^2}{\sigma_0^2 + \sigma^2} z.$$

Il peso di $\bar{x}$ dipende dall'incertezza della misura σ^2 , mentre il peso di z dipende dall'incertezza a priori σ_0^2 . Se la prior e' molto incerta, cioe' $\sigma_0^2 \rightarrow \infty$, allora il modello a priori non aiuta piu' a localizzare x .

In quel limite,

$$\frac{\sigma^2}{\sigma_0^2 + \sigma^2} \rightarrow 0, \quad \frac{\sigma_0^2}{\sigma_0^2 + \sigma^2} \rightarrow 1,$$

quindi $\hat{x}^{MAP}(z) \rightarrow z$, cioe' la stima coincide con quella ottenuta guardando solo i dati. Questo e' il collegamento concettuale con ML: ML usa la sola verosimiglianza, mentre MAP usa verosimiglianza piu' prior.

Piccolo Recap: Si distinguono due approcci principali:

- **Bayesiano**

$$f_{\bar{X}|Z}(x | z)$$

- **Non Bayesiano** (o di *Fisher*)

$$f_{Z|\bar{X}}(z | x)$$

Nel caso bayesiano si considera la densità *a posteriori* e si cerca il massimo da cui si ottiene la stima **MAP**.

Nel caso non bayesiano si considera invece la massima verosimiglianza, da cui si ottiene la stima **MLE**.

Se $f_{\bar{X}}(x)$ è una PDF diffusa, allora MAP e MLE tendono a coincidere.

Spiegazione – Recap tra approccio bayesiano e non bayesiano

La differenza centrale e' il ruolo assegnato al parametro x . Nell'approccio non bayesiano, x e' un numero fisso ma ignoto: non gli si assegna una distribuzione di probabilita'. Per questo si lavora con

$$f_{Z|\bar{X}}(z | x),$$

cioe' con la probabilita' di osservare i dati z se il parametro fosse x .

Nell'approccio bayesiano, invece, x e' trattato come variabile aleatoria. Prima dei dati si possiede una prior $f_{\bar{X}}(x)$; dopo avere osservato z , questa viene aggiornata nella posterior

$$f_{\bar{X}|Z}(x | z).$$

MAP sceglie il punto in cui la posterior e' massima; ML sceglie il punto in cui la verosimiglianza e' massima. Se la prior e' piatta o poco informativa, la posterior e' dominata dalla verosimiglianza e i due criteri danno praticamente lo stesso risultato.

17.4 Approccio Non Bayesiano con i minimi quadrati

Un altro approccio (non bayesiano) alla stima è quello dei **minimi quadrati**.

$$z(j) = h(j, x) + W(j), \quad j = 1, \dots, K$$

dove:

- $h(j, x)$ è, in generale, **non lineare**;
- $W(j)$ rappresenta un **rumore additivo**.

Spiegazione – Modello di misura e minimi quadrati

Il modello

$$z(j) = h(j, x) + W(j)$$

separa cio' che il modello deterministico prevede, $h(j, x)$, da cio' che non viene spiegato, $W(j)$. Per ogni valore candidato di x , si puo' calcolare il residuo

$$z(j) - h(j, x).$$

Il metodo dei minimi quadrati sceglie il valore di x che rende piccoli, complessivamente, tutti questi residui.

Il quadrato serve per due ragioni: evita cancellazioni tra errori positivi e negativi, e penalizza maggiormente errori grandi. Se $h(j, x)$ e' lineare in x , il problema spesso ha una soluzione esplicita; se e' non lineare, la minimizzazione puo' richiedere metodi iterativi.

Minimi quadrati (*least squares*)

Indicati con LS oppure LSE (*least squares estimation*), sono definiti da:

$$\hat{x}^{LS}(z^K) = \arg \min_x \left\{ \sum_{j=1}^k (z(j) - h(j, x))^2 \right\}.$$

Non si fa nessuna assunzione sul rumore.

Caso particolare: $W(j)$ i.i.d., cioe' *indipendenti e identicamente distribuiti*, gaussiani a media nulla:

$$W(j) \sim \mathcal{N}(0, \sigma^2).$$

Spiegazione – Perché LS non richiede una distribuzione del rumore

La definizione LS usa solo una distanza tra dati osservati e dati predetti dal modello:

$$\sum_{j=1}^k (z(j) - h(j, x))^2.$$

Non serve conoscere la PDF del rumore per scrivere questo criterio. Per questo LS e' un criterio piu' geometrico che probabilistico: cerca il punto del modello piu' vicino alle osservazioni, nel senso della somma dei quadrati.

Quando pero' si aggiunge l'ipotesi che il rumore sia gaussiano i.i.d. a media nulla e varianza σ^2 , allora LS acquista anche un significato probabilistico: coincide con la massima verosimiglianza. In altre parole, sotto rumore gaussiano, minimizzare i quadrati equivale a massimizzare la probabilita' dei dati osservati.

Massima verosimiglianza

Esempio (caso particolare)

$$z(j) \mid x \sim \mathcal{N}(h(j, x), \sigma^2)$$

La funzione di verosimiglianza è

$$\Lambda_z(x) = f_{Z|\underline{x}}(z | x) = \prod_{j=1}^K \mathcal{N}(h(j, x), \sigma^2).$$

A meno di costanti di proporzionalità, si ha

$$\Lambda_z(x) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_{j=1}^K (z(j) - h(j, x))^2\right).$$

Quindi, nel caso gaussiano, la stima di massima verosimiglianza equivale a minimizzare

$$\sum_{j=1}^K (z(j) - h(j, x))^2 = (*),$$

ossia coincide con la stima ai minimi quadrati:

$$\text{stima ML} \equiv \text{minimizzare } (*) \equiv \text{LSE (minimi quadrati)}.$$

Nel caso gaussiano

Spiegazione – Perché ML coincide con LS nel caso gaussiano

Per dati indipendenti con rumore gaussiano, la verosimiglianza è un prodotto di gaussiane. Ogni termine contiene un esponenziale del tipo

$$\exp\left(-\frac{(z(j) - h(j, x))^2}{2\sigma^2}\right).$$

Moltiplicando questi termini, gli esponenti si sommano e compare

$$\exp\left(-\frac{1}{2\sigma^2} \sum_{j=1}^K (z(j) - h(j, x))^2\right).$$

Massimizzare questo esponenziale equivale a rendere il suo esponente il meno negativo possibile, cioè equivale a minimizzare la somma dei quadrati. Le costanti moltiplicative e il fattore $1/(2\sigma^2)$ non cambiano il punto di massimo/minimo, quindi il criterio ML diventa esattamente il criterio LS.

Per continuare l'esempio Si consideri

$$z(j) = x + w(j), \quad j = 1, \dots, k.$$

In questo caso

$$h(j, x) = x.$$

Allora la verosimiglianza diventa, ancora a meno di costanti moltiplicative,

$$\Lambda_z(x) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_{j=1}^K (z(j) - x)^2\right).$$

Ne segue che

$$\hat{x}^{ML} = \hat{x}^{LS} = ?$$

Calcoliamo il punto di minimo derivando rispetto a x :

$$\frac{d}{dx} \left(\frac{1}{2\sigma^2} \sum_{j=1}^K (z(j) - x)^2 \right) = \frac{1}{\sigma^2} \sum_{j=1}^K (z(j) - x) = \frac{1}{\sigma^2} \left(-Kx + \sum_{j=1}^K z(j) \right).$$

Ponendo la derivata uguale a zero si ottiene

$$\frac{d}{dx}(\cdot) = 0 \iff x = \frac{1}{K} \sum_{j=1}^K z(j).$$

Quindi

$$\hat{x}^{ML} = \hat{x}^{LS} = \frac{1}{K} \sum_{j=1}^K z(j) = \bar{z},$$

cioè la media campionaria.

Spiegazione – Derivazione della media campionaria

Nel caso

$$z(j) = x + w(j),$$

il modello prevede lo stesso parametro x per tutte le misure. Il criterio LS diventa

$$\sum_{j=1}^K (z(j) - x)^2.$$

La derivata rispetto a x misura come cambia la somma dei quadrati spostando il valore candidato del parametro. Ponendo la derivata uguale a zero si impone che non convenga spostare ulteriormente x né verso l'alto né verso il basso.

L'equazione ottenuta è

$$\sum_{j=1}^K (z(j) - x) = 0,$$

cioè

$$\sum_{j=1}^K z(j) = Kx.$$

Da qui segue

$$\hat{x} = \frac{1}{K} \sum_{j=1}^K z(j).$$

La stima è quindi la media delle osservazioni: ogni misura contribuisce allo stesso modo perché tutte hanno la stessa varianza e lo stesso modello.

Analogo di LS che sia Bayesiano

MMSE (Minimum Mean Square Error) (È sempre uno stimatore)

$$\hat{x}^{\text{MMSE}}(z) = \arg \min_{\hat{x}} E[(\hat{x} - x)^2 | z]$$

Spiegazione – Idea dello stimatore MMSE

MMSE significa scegliere una stima $\hat{x}$ che minimizza l'errore quadratico medio, dopo avere osservato z . A differenza di ML e LS, qui si ragiona in modo bayesiano: dopo la misura, x resta incerto ed e' descritto dalla posterior

$$f_{\hat{X}|Z}(x | z).$$

Il criterio

$$E[(\hat{x} - x)^2 | z]$$

fa la media dell'errore quadratico su tutti i valori possibili di x , pesati secondo la posterior. Quindi non si cerca il valore piu' probabile in assoluto, ma il valore che minimizza la perdita quadratica media condizionata ai dati osservati.

Caso scalare Nel caso scalare si può calcolare la condizione di ottimo derivando rispetto a $\hat{x}$:

$$\begin{aligned} \frac{d}{d\hat{x}} E[(\hat{x} - x)^2 | z] &= E \left[\frac{d}{d\hat{x}} (\hat{x} - x)^2 | z \right] = E[2(\hat{x} - x) | z] \\ &= 2(\hat{x} - E[x | z]) \end{aligned}$$

Ponendo la derivata uguale a zero si ottiene

$$\frac{d}{d\hat{x}}(\cdot) = 0 \iff \hat{x} = E[x | z].$$

Quindi

$$\hat{x}^{\text{MMSE}}(z) = E[x | z] = \int_{-\infty}^{+\infty} x f_{\hat{x}|z}(x | z) dx.$$

La stima **MMSE** coincide quindi con la stima **EAP** (*Expected A Posteriori*).

$$\text{MMSE} \equiv \text{EAP}$$

Spiegazione – Perché MMSE coincide con la media a posteriori

Nel caso scalare, la funzione da minimizzare e'

$$E[(\hat{x} - x)^2 | z].$$

Derivando rispetto alla variabile scelta $\hat{x}$ si ottiene

$$2(\hat{x} - E[x | z]).$$

Il minimo si trova quando questa quantita' e' nulla, quindi

$$\hat{x} = E[x | z].$$

Questo risultato e' importante: con perdita quadratica, la stima ottima non e' necessariamente il punto piu' probabile, ma la media della posterior. Per questo MMSE coincide con EAP, cioe' *Expected A Posteriori*.

MMSE e MAP nel caso Gaussiano

MAP nel caso Gaussiano Se la PDF a posteriori è gaussiana, si può scrivere

$$f_{\bar{x}|Z}(x | z) = \frac{1}{\sqrt{2\pi} \sigma^2} \exp\left(-\frac{[x - \xi(z)]^2}{2\sigma^2}\right).$$

Allora lo stimatore MAP vale

$$\hat{x}^{\text{MAP}}(z) = \xi(z).$$

MMSE nel caso Gaussiano Anche lo stimatore MMSE, cioè EAP, vale

$$\hat{x}^{\text{MMSE}}(z) = \hat{x}^{\text{EAP}}(z) = \xi(z).$$

Quindi, nel caso gaussiano, MMSE e MAP coincidono, perché valore atteso e valore di massimo coincidono quando la PDF a posteriori è gaussiana.

Spiegazione – Quando MAP e MMSE danno la stessa stima

MAP e MMSE usano due criteri diversi: MAP cerca il massimo della posterior, mentre MMSE cerca la media della posterior. In generale questi due valori possono essere diversi, soprattutto se la distribuzione è asimmetrica o multimodale.

Nel caso gaussiano, però, la posterior ha forma simmetrica attorno al suo centro $\xi(z)$. Per una gaussiana, media, moda e mediana coincidono. Quindi

$$\arg \max_x f_{\bar{x}|Z}(x | z) = E[x | z] = \xi(z).$$

Per questo, con posterior gaussiana, MAP e MMSE producono la stessa stima anche se nascono da criteri diversi.

Indici di bontà

Stimatori non polarizzati Si definisce l'errore di stima

$$\tilde{x} := x - \hat{x}.$$

Uno stimatore si dice *non polarizzato* se

$$E[\tilde{x}] = 0 \quad \forall k,$$

ossia se equivalentemente

$$E[\hat{x}] = E[x].$$

Stimatore asintoticamente non polarizzato Uno stimatore si dice *asintoticamente non polarizzato* se la proprietà vale per

$$k \rightarrow \infty.$$

Spiegazione – Non polarizzazione e significato del bias

La non polarizzazione riguarda l'errore medio dello stimatore. Se

$$E[\hat{x}] = E[x],$$

allora lo stimatore non tende sistematicamente a sovrastimare o sottostimare il parametro. Nel caso non bayesiano, dove il valore vero è x_0 , questa condizione si legge spesso come

$$E[\hat{x}] = x_0.$$

Uno stimatore può essere polarizzato per un numero finito di misure ma diventare asintoticamente non polarizzato quando k cresce. Questo significa che l'errore sistematico si riduce al crescere dell'informazione disponibile, anche se per campioni piccoli può rimanere un bias.

ML nel caso Gaussiano

Sia x_0 il valore “vero”.

Modello della singola misura

$$z = x + w.$$

In questo caso lo stimatore di massima verosimiglianza è

$$\hat{x}^{ML}(z) = z.$$

Infatti

$$E[\hat{x}^{ML}] = E[z] = E[x_0 + w] = x_0 + E[w] = x_0.$$

Quindi lo stimatore ML è **non polarizzato**.

Spiegazione – ML con singola misura gaussiana

Con una singola misura

$$z = x_0 + w,$$

e rumore a media nulla, la stima ML è semplicemente $\hat{x}^{ML} = z$. La ragione è intuitiva: con una sola osservazione e nessuna prior, il valore più plausibile del parametro è quello che renderebbe nullo il residuo.

La non polarizzazione segue dal fatto che il rumore ha media nulla:

$$E[z] = E[x_0 + w] = x_0.$$

Questo non significa che una singola stima sia sempre vicina a x_0 ; significa solo che, ripetendo idealmente l'esperimento molte volte, la media delle stime sarebbe centrata su x_0 .

MAP nel caso Gaussiano

Si consideri ancora

$$z = x + w.$$

Nel caso gaussiano, lo stimatore MAP è

$$\hat{x}^{MAP}(z) = \xi(z) = \frac{\sigma^2}{\sigma^2 + \sigma_0^2} \bar{x} + \frac{\sigma_0^2}{\sigma^2 + \sigma_0^2} z.$$

Calcolandone il valore atteso si ottiene

$$E[\hat{x}^{MAP}(z)] = \frac{\sigma^2}{\sigma^2 + \sigma_0^2} \bar{x} + \frac{\sigma_0^2}{\sigma^2 + \sigma_0^2} E[z].$$

Poiché

$$E[z] = \bar{x},$$

segue che

$$E[\hat{x}^{MAP}(z)] = \frac{\sigma^2}{\sigma^2 + \sigma_0^2} \bar{x} + \frac{\sigma_0^2}{\sigma^2 + \sigma_0^2} \bar{x} = \bar{x} = E[x].$$

Quindi anche lo stimatore MAP, in questo caso, è **non polarizzato**.

Spiegazione – MAP come compromesso tra prior e misura

Lo stimatore MAP gaussiano ha la forma

$$\hat{x}^{MAP} = \alpha \bar{x} + (1 - \alpha)z,$$

dove

$$\alpha = \frac{\sigma^2}{\sigma^2 + \sigma_0^2}.$$

Quindi la stima è un compromesso: si avvicina alla prior quando la misura è rumorosa, e si avvicina alla misura quando la prior è molto incerta.

Nel calcolo del valore atteso bisogna distinguere tra media rispetto al rumore di misura e media rispetto alla variabile aleatoria x . Se il modello bayesiano è centrato correttamente, cioè se la prior ha media $\bar{x}$, allora il valore atteso dello stimatore resta centrato sulla media del parametro. Per questo, nel caso riportato, MAP risulta non polarizzato rispetto alla media a priori.

Altri indici di bontà

Varianza e MSE dello stimatore

Caso non bayesiano Sia $\hat{x}(z)$ uno stimatore.

La sua varianza è definita come

$$\text{Var}[\hat{x}(z)] = E\left[\{\hat{x}(z) - E[\hat{x}(z)]\}^2\right].$$

Se $\hat{x}$ è non polarizzato, allora

$$E[\hat{x}(z)] = x_0.$$

Di conseguenza,

$$\text{Var}[\hat{x}(z)] = E\left[(\hat{x}(z) - x_0)^2\right].$$

In ogni caso si definisce

$$E\left[(\hat{x}(z) - x_0)^2\right] = \text{MSE},$$

dove MSE sta per *Mean Square Error*.

Spiegazione – Varianza, MSE e ruolo della polarizzazione

Nel caso non bayesiano, il parametro vero x_0 è fisso. L'MSE misura direttamente quanto lo stimatore si discosta da questo valore:

$$\text{MSE} = E[(\hat{x} - x_0)^2].$$

La varianza, invece, misura quanto lo stimatore oscilla attorno alla propria media:

$$\text{Var}[\hat{x}] = E[(\hat{x} - E[\hat{x}])^2].$$

Se lo stimatore è non polarizzato, allora $E[\hat{x}] = x_0$ e le due quantità coincidono:

$$\text{Var}[\hat{x}] = \text{MSE}.$$

Se invece lo stimatore è polarizzato, l'MSE contiene due contributi: la variabilità casuale dello stimatore e il quadrato del bias. Per questo uno stimatore con bassa varianza non è automaticamente buono: bisogna anche controllare se è centrato sul valore corretto.

Caso bayesiano Nel caso bayesiano si considera la media sia su z sia su x , perché qui x è una variabile aleatoria.

$$\text{MSE}[\hat{x}(z)] = E\left[(\hat{x}(z) - x)^2\right].$$

Usando il valore atteso iterato, si può anche scrivere

$$\text{MSE}[\hat{x}(z)] = E\left[E\left[(\hat{x}(z) - x)^2 \mid z\right]\right].$$

Spiegazione – MSE bayesiano e valore atteso iterato

Nel caso bayesiano l'errore dipende da due sorgenti di incertezza: il parametro aleatorio x e i dati z . Per questo l'MSE è una media globale:

$$E[(\hat{x}(z) - x)^2].$$

Si può calcolare in due passi usando il valore atteso iterato. Prima si fissa il dato osservato z e si calcola l'errore medio rispetto alla posterior:

$$E[(\hat{x}(z) - x)^2 \mid z].$$

Poi si fa la media di questa quantità su tutti i possibili dati z .

Questo passaggio spiega perché MMSE minimizza l'MSE bayesiano: per ogni valore osservato di z , sceglie la stima che minimizza l'errore quadratico medio condizionato a quel dato.

Proprietà di regolarizzazione del valore atteso Vale la proprietà

$$E[E[\bar{x} \mid \bar{y}]] = E[X].$$

Infatti

$$\begin{aligned} E[E[\bar{x} \mid \bar{y}]] &= \int_{y=-\infty}^{+\infty} \left[\int_{x=-\infty}^{+\infty} x f_{\bar{x}|\bar{y}}(x \mid y) dx \right] f_{\bar{y}}(y) dy = \\ &= \int_{x=-\infty}^{+\infty} x \int_{y=-\infty}^{+\infty} f_{\bar{x}|\bar{y}}(x, y) dy dx = \\ &= \int_{x=-\infty}^{+\infty} f_{\bar{x}}(x) dx = E[\bar{x}] \end{aligned}$$

Questa scrittura giustifica il passaggio

$$\text{MSE}[\hat{x}(z)] = E\left[E\left[(\hat{x}(z) - x)^2 \mid z\right]\right],$$

cioè la media su tutti i possibili esiti dell'esperimento di misura.

Spiegazione – Proprietà della media condizionata

La proprietà

$$E[E[X \mid Y]] = E[X]$$

si chiama anche legge dell'aspettazione totale. L'idea è che prima si fa una media di X sapendo il valore di Y , poi si fa la media rispetto a tutti i valori possibili di Y .

Nel contesto della stima, questa proprietà permette di passare da un errore medio condizionato ai dati a un errore medio complessivo. Quindi le quantità bayesiane possono essere lette su due livelli: livello locale, fissato il dato osservato, e livello globale, mediando su tutti gli esperimenti possibili.

Varianza di ML e MAP (singola misura gaussiana)

Si consideri il modello

$$z = x + w,$$

con w gaussiano.

Varianza dello stimatore ML Per lo stimatore di massima verosimiglianza, nel caso di singola misura,

$$\hat{x}^{ML} = z.$$

Quindi

$$\text{Var}[\hat{x}^{ML}] = E[(\hat{x}^{ML} - x_0)^2] = E[(z - x_0)^2].$$

Poiché

$$z = x_0 + w,$$

si ottiene

$$E[(z - x_0)^2] = E[w^2] = \sigma^2.$$

Dunque

$$\text{Var}[\hat{x}^{ML}] = \sigma^2.$$

Spiegazione – Varianza ML con una sola misura

Per ML con una singola misura gaussiana, lo stimatore coincide con il dato:

$$\hat{x}^{ML} = z = x_0 + w.$$

L'unica fonte di variabilità della stima è quindi il rumore w . Di conseguenza,

$$\text{Var}[\hat{x}^{ML}] = \text{Var}[w] = \sigma^2.$$

Questo risultato dice che, con una sola misura e senza informazione a priori, non si può ridurre la varianza sotto quella del rumore di misura: lo stimatore eredita tutta l'incertezza presente nel dato.

Varianza dello stimatore MAP Nel caso gaussiano, lo stimatore MAP è

$$\hat{x}^{MAP} = \frac{\sigma^2}{\sigma^2 + \sigma_0^2} \bar{x} + \frac{\sigma_0^2}{\sigma^2 + \sigma_0^2} z.$$

Allora

$$\text{Var}[\hat{x}^{MAP}] = E[(\hat{x}^{MAP} - x)^2].$$

Sostituendo l'espressione di $\hat{x}^{MAP}$,

$$\text{Var}[\hat{x}^{MAP}] = E\left[\left(\frac{\sigma^2}{\sigma^2 + \sigma_0^2} \bar{x} + \frac{\sigma_0^2}{\sigma^2 + \sigma_0^2} z - x\right)^2\right].$$

Usando $z = x + w$, si ha

$$\text{Var}[\hat{x}^{MAP}] = E\left[\left(\frac{\sigma^2}{\sigma^2 + \sigma_0^2} (\bar{x} - x) + \frac{\sigma_0^2}{\sigma^2 + \sigma_0^2} w\right)^2\right].$$

$$\bar{x} - x = \sigma_0^2 \quad (\text{varianza a priori}),$$

per cui il risultato finale riportato è

$$\text{Var}[\hat{x}^{MAP}] = \frac{\sigma^4 \sigma_0^2}{(\sigma^2 + \sigma_0^2)^2} + \frac{\sigma_0^4 \sigma^2}{(\sigma^2 + \sigma_0^2)^2} = \frac{\sigma^2 \sigma_0^2}{\sigma^2 + \sigma_0^2}.$$

Confronto tra ML e MAP Si confrontano quindi le due varianze:

$$\text{Var}[\hat{x}^{ML}] = \sigma^2, \quad \text{Var}[\hat{x}^{MAP}] = \frac{\sigma^2 \sigma_0^2}{\sigma^2 + \sigma_0^2}.$$

Poiché

$$\sigma^2 = \frac{\sigma^2(\sigma^2 + \sigma_0^2)}{\sigma^2 + \sigma_0^2} = \frac{\sigma^2 \sigma_0^2}{\sigma^2 + \sigma_0^2} + \frac{\sigma^4}{\sigma^2 + \sigma_0^2},$$

segue che

$$\sigma^2 > \frac{\sigma^2 \sigma_0^2}{\sigma^2 + \sigma_0^2}.$$

Quindi

$$\text{Var}[\hat{x}^{ML}] > \text{Var}[\hat{x}^{MAP}].$$

Spiegazione – Perché MAP può avere varianza minore di ML

MAP non usa solo la misura z , ma anche la prior. Per questo lo stimatore è una combinazione pesata:

$$\hat{x}^{MAP} = \frac{\sigma^2}{\sigma^2 + \sigma_0^2} \bar{x} + \frac{\sigma_0^2}{\sigma^2 + \sigma_0^2} z.$$

Il termine associato a z ha peso minore di 1, quindi il rumore di misura viene attenuato. La varianza risultante è

$$\text{Var}[\hat{x}^{MAP}] = \frac{\sigma^2 \sigma_0^2}{\sigma^2 + \sigma_0^2},$$

che è minore di σ^2 quando σ_0^2 è finita. Il prezzo di questa riduzione è che la stima dipende dalla prior: se la prior è informativa e coerente col problema, MAP migliora la stabilità; se la prior è poco affidabile, può spostare la stima in modo indesiderato.

LS gaussiano, multimisura

Si consideri

$$z(j) = x_0 + w(j), \quad j = 1, \dots, K,$$

con

$$w(j) \text{ i.i.d. } \sim \mathcal{N}(0, \sigma^2).$$

In questo caso

$$\hat{x}^{LS} = \hat{x}^{ML} = \frac{1}{k} \sum_{j=1}^k z(j).$$

Spiegazione – Perché con più misure compare la media

Con più misure indipendenti dello stesso parametro,

$$z(j) = x_0 + w(j),$$

ogni osservazione contiene lo stesso valore vero più un rumore diverso. La media campionaria

$$\frac{1}{k} \sum_{j=1}^k z(j)$$

somma i contributi utili, tutti uguali a x_0 , e tende a compensare i rumori, che hanno media nulla.

Questo è il motivo per cui LS e ML coincidono ancora e producono la media: tutte le misure sono ugualmente affidabili, quindi il modo naturale di combinarle è dare a ciascuna lo stesso peso.

Non polarizzazione Si ha

$$E[\hat{x}^{LS}] = E\left[\frac{1}{k} \sum_{j=1}^k z(j)\right] = \frac{1}{k} \sum_{j=1}^k E[z(j)].$$

Poiché

$$E[z(j)] = x_0,$$

segue che

$$E[\hat{x}^{LS}] = \frac{1}{k} k x_0 = x_0.$$

Quindi lo stimatore è **non polarizzato**.

Varianza dello stimatore

$$\text{Var}[\hat{x}^{LS}] = E\left[(\hat{x}^{LS} - x_0)^2\right].$$

Sostituendo l'espressione dello stimatore,

$$\text{Var}[\hat{x}^{LS}] = E\left[\left(\frac{1}{k} \sum_{j=1}^k z(j) - x_0\right)^2\right].$$

Poiché

$$z(j) - x_0 = w(j),$$

si ottiene

$$\text{Var}[\hat{x}^{LS}] = E\left[\left(\frac{1}{k} \sum_{j=1}^k w(j)\right)^2\right].$$

Dato che i $w(j)$ sono indipendenti e con varianza σ^2 ,

$$\text{Var}[\hat{x}^{LS}] = \frac{1}{k^2} k \sigma^2 = \frac{\sigma^2}{k}.$$

Spiegazione – Varianza della media campionaria

La varianza dello stimatore LS diminuisce come $1/k$ perché si sta facendo la media di k rumori indipendenti. Infatti

$$\hat{x}^{LS} - x_0 = \frac{1}{k} \sum_{j=1}^k w(j).$$

La varianza della somma di rumori indipendenti è la somma delle varianze:

$$\text{Var}\left[\sum_{j=1}^k w(j)\right] = k\sigma^2.$$

Il fattore $1/k$ davanti alla somma diventa $1/k^2$ nella varianza, quindi

$$\text{Var}[\hat{x}^{LS}] = \frac{1}{k^2} k\sigma^2 = \frac{\sigma^2}{k}.$$

Questo quantifica il guadagno dovuto alla ripetizione delle misure.

Consistenza Per

$$k \rightarrow \infty,$$

si ha

$$\text{Var}[\hat{x}^{LS}] \rightarrow 0.$$

Per questo lo stimatore si dice **consistente**.

Uno stimatore è consistente se, per $k \rightarrow \infty$, l'errore di stima tende a zero in qualche senso statistico.

In media quadratica:

$$\lim_{k \rightarrow \infty} E[\tilde{x}^2(z)] = 0.$$

Spiegazione – Consistenza come effetto dell'aumento dei dati

La consistenza esprime una proprietà asintotica: aumentando il numero di misure, lo stimatore deve avvicinarsi al valore vero. Nel caso della media campionaria gaussiana,

$$\text{Var}[\hat{x}^{LS}] = \frac{\sigma^2}{k} \rightarrow 0.$$

Se lo stimatore è anche non polarizzato, l'MSE coincide con la varianza; quindi anche l'errore quadratico medio tende a zero.

In termini pratici, la singola misura può essere rumorosa, ma la media di molte misure indipendenti diventa sempre più stabile. La consistenza formalizza proprio questa idea.

Altra proprietà: efficienza Esiste un limite inferiore all'MSE legato alla verosimiglianza:

$$(\text{CRLB}) \quad \text{Cramér-Rao Lower Bound.}$$

Spiegazione – Efficienza e limite inferiore dell'errore

L'efficienza riguarda quanto uno stimatore si avvicina al miglior errore teoricamente possibile. Il Cramér-Rao Lower Bound fornisce un limite inferiore alla varianza, o all'MSE nel caso non polarizzato, di qualunque stimatore non polarizzato.

Se uno stimatore raggiunge questo limite, allora non esiste un altro stimatore non polarizzato con varianza più piccola, almeno all'interno delle ipotesi del bound. In questo senso lo stimatore è efficiente: usa tutta l'informazione disponibile nei dati rispetto al parametro da stimare.

Caso scalare non bayesiano: CRLB

Nel caso scalare non bayesiano, per uno stimatore $\hat{x}(z)$ non polarizzato, vale la disuguaglianza

$$E[(\hat{x}(z) - x_0)^2] \geq J^{-1},$$

dove J è l'informazione di Fisher.

Più precisamente,

$$J := -E \left[\frac{\partial^2 \ln \Lambda_z(x)}{\partial x^2} \right]_{x=x_0}$$

e, in forma equivalente,

$$J = E \left[\left(\frac{\partial \ln \Lambda_z(x)}{\partial x} \right)^2 \right]_{x=x_0}.$$

Il CRLB è quindi l'inverso dell'informazione di Fisher:

$$\text{CRLB} = J^{-1}.$$

Spiegazione – Informazione di Fisher e CRLB

L'informazione di Fisher misura quanto la verosimiglianza cambia al variare del parametro. Se una piccola variazione di x produce una grande variazione di $\Lambda_z(x)$, allora i dati sono molto informativi su x .

Nel caso scalare non bayesiano,

$$J = E \left[\left(\frac{\partial \ln \Lambda_z(x)}{\partial x} \right)^2 \right]_{x=x_0}$$

misura la sensibilit  media del logaritmo della verosimiglianza rispetto al parametro. Il CRLB   l'inverso:

$$\text{CRLB} = J^{-1}.$$

Quindi pi  grande   l'informazione di Fisher, pi  piccolo   il limite inferiore sull'errore di stima.

Nel caso bayesiano

La verosimiglianza

$$\Lambda_z(x)$$

viene sostituita da

$$f_{z,\bar{x}}(z, x),$$

cio  dalla PDF congiunta.

Spiegazione – Lettura bayesiana del bound

Nel caso bayesiano il parametro   aleatorio, quindi l'informazione non proviene solo dalla verosimiglianza dei dati dato il parametro, ma anche dalla distribuzione a priori del parametro stesso. Per questo, invece di ragionare solo su

$$\Lambda_z(x) = f_{Z|\bar{X}}(z | x),$$

si considera la struttura probabilistica congiunta tra dati e parametro:

$$f_{Z,\bar{X}}(z, x).$$

In questo modo il bound tiene conto sia dell'informazione portata dalle misure sia dell'informazione gi  presente nella prior.

Efficienza

Se la disuguaglianza vale per un particolare stimatore con "=", cio  se

$$\text{MSE dello stimatore} = \text{CRLB},$$

allora lo stimatore   detto **efficiente**.

Uno stimatore efficiente "estrae" o "sfrutta" tutta l'informazione disponibile.

Legame tra consistenza ed efficienza

Ci si pu  chiedere come siano legate consistenza ed efficienza.

Una condizione necessaria per la consistenza in media quadratica   l'aumento dell'informazione (di Fisher) all'aumentare del numero di misure.

In particolare, se

$$\text{Informazione} \rightarrow \infty \quad \text{per } k \rightarrow \infty,$$

allora

$$\text{CRLB} \rightarrow 0 \quad \text{per } k \rightarrow \infty.$$

(Questo dipende solo dal problema)

Di conseguenza, l'MSE di uno stimatore *può* essere nullo per $k \rightarrow \infty$. (Questo dipende anche dallo stimatore)

Spiegazione – Consistenza ed efficienza non sono la stessa cosa

Consistenza ed efficienza descrivono aspetti diversi. La consistenza guarda il comportamento per $k \rightarrow \infty$: chiede che l'errore vada a zero quando aumentano i dati. L'efficienza guarda invece se, per un certo problema, lo stimatore raggiunge il limite inferiore imposto dall'informazione disponibile.

L'aumento dell'informazione di Fisher è una condizione favorevole alla consistenza, perché

$$J \rightarrow \infty \implies J^{-1} \rightarrow 0.$$

Pero' il fatto che il bound vada a zero non garantisce da solo che ogni stimatore sia consistente: serve che lo stimatore scelto riesca effettivamente a sfruttare quell'informazione. Per questo le note distinguono tra ciò che dipende dal problema e ciò che dipende dallo stimatore.

Caso matriciale

FIM

FIM = Fisher Information Matrix.

Spiegazione – Dal caso scalare alla matrice di Fisher

Quando il parametro non è uno scalare ma un vettore, l'informazione non può più essere descritta da un solo numero. Serve una matrice:

FIM.

Gli elementi diagonali misurano quanta informazione c'è sui singoli parametri, mentre gli elementi fuori diagonale descrivono l'accoppiamento tra parametri diversi.

Nel caso vettoriale, il CRLB diventa una disuguaglianza matriciale: la matrice di covarianza dello stimatore è limitata inferiormente dall'inversa della Fisher Information Matrix. Intuitivamente, una FIM grande e ben condizionata indica che i parametri sono stimabili con precisione; una FIM quasi singolare indica che alcuni parametri sono difficili da distinguere dai dati.

Esempio: stima con misure multiple Si considerino k misure

$$z(j) = x + w(j), \quad j = 1, \dots, K,$$

con rumore gaussiano i.i.d.

La verosimiglianza si può scrivere come

$$\Lambda_z(x) = C \exp \left(-\frac{1}{2\sigma^2} \sum_{j=1}^k (z(j) - x)^2 \right),$$

Che non dipende dallo stimatore (non definito ancora) e dove C è una costante.

Prendendo il logaritmo:

$$\ln \Lambda_z(x) = \ln C - \frac{1}{2\sigma^2} \sum_{j=1}^K (z(j) - x)^2.$$

Derivando rispetto a x , si ottiene

$$\frac{d}{dx} \ln \Lambda_z(x) = \frac{1}{\sigma^2} \sum_{j=1}^K (z(j) - x).$$

Derivando una seconda volta:

$$\frac{d^2}{dx^2} \ln \Lambda_z(x) = -\frac{K}{\sigma^2}.$$

Quindi l'informazione di Fisher vale

$$J = -E \left[\frac{d^2}{dx^2} \ln \Lambda_z(x) \right] = \frac{K}{\sigma^2}.$$

(Media valutato per $x = x_0$)

Di conseguenza, il *Cramér–Rao Lower Bound* è

$$\text{CRLB} = J^{-1} = \frac{\sigma^2}{K}.$$

Perciò

$$\text{MSE}[\hat{x}(z)] \geq \frac{\sigma^2}{K}$$

per qualunque stimatore non polarizzato.

Consideriamo ora lo stimatore ML, che in questo caso coincide con LS:

$$\hat{x}^{ML}(z) \equiv \hat{x}^{LS}(z).$$

Dalle note precedenti,

$$\text{MSE}[\hat{x}^{ML}(z)] = \frac{\sigma^2}{K}.$$

Poiché lo stimatore raggiunge il bound,

$$\text{MSE}[\hat{x}^{ML}(z)] = \text{CRLB},$$

segue che lo stimatore è **efficiente**.

Spiegazione – Esempio CRLB con misure multiple gaussiane

Nell'esempio

$$z(j) = x + w(j), \quad w(j) \sim \mathcal{N}(0, \sigma^2),$$

ogni misura aggiunge la stessa quantità di informazione sul parametro. Per una misura, l'informazione è proporzionale a $1/\sigma^2$; con K misure indipendenti, le informazioni si sommano:

$$J = \frac{K}{\sigma^2}.$$

Il bound diventa quindi

$$\text{CRLB} = J^{-1} = \frac{\sigma^2}{K}.$$

Ma la media campionaria, che coincide con LS e ML, ha proprio MSE

$$\text{MSE} = \frac{\sigma^2}{K}.$$

Quindi raggiunge il limite teorico: in questo problema lo stimatore ML/LS e' efficiente.

Piccolo recap delle cose viste.

Si vuole costruire uno stimatore $\hat{x}$ come funzione di z fino all'istante k .

Si distinguono due approcci principali:

- **Non bayesiano**

$$\begin{cases} \text{ML} \\ \text{LS} \end{cases}$$

- **Bayesiano**

$$\begin{cases} \text{MAP} \\ \text{MMSE} \end{cases}$$

Inoltre,

$$\text{MMSE} = \text{EAP}.$$

Gli indici di bontà considerati sono:

- polarizzazione;
- varianza / MSE;
- consistenza / efficienza.

Abbiamo visto anche:

$$\text{CRLB} \quad \text{e} \quad \text{FIM}.$$

Spiegazione – Quadro generale degli stimatori

Il recap mette ordine tra due modi diversi di impostare la stima. Nel caso non bayesiano, il parametro x e' considerato fisso ma ignoto: si stimano i valori compatibili con i dati usando criteri come ML e LS. Nel caso bayesiano, invece, x e' una variabile aleatoria: si parte da una prior e, dopo avere osservato i dati, si usa la posterior.

Gli stimatori MAP e MMSE nascono entrambi dalla posterior ma rispondono a domande diverse. MAP cerca il valore piu' probabile:

$$\hat{x}^{MAP} = \arg \max_x f_{X|Z}(x | z),$$

mentre MMSE cerca il valore che minimizza l'errore quadratico medio:

$$\hat{x}^{MMSE} = E[x | z].$$

Gli indici di bontà servono poi a valutare lo stimatore ottenuto: bias, varianza, MSE, consistenza, efficienza e confronto con il CRLB.

Approfondimento del caso gaussiano

Si assume che x e z siano variabili aleatorie congiuntamente gaussiane.

Si definisce il vettore

$$y = \begin{bmatrix} x \\ z \end{bmatrix}, \quad y \sim \mathcal{N}(\bar{y}, \Sigma_y).$$

Il vettore delle medie è

$$\bar{y} = \begin{bmatrix} \bar{y} \\ \bar{z} \end{bmatrix},$$

mentre la matrice di covarianza è

$$\Sigma_y = \begin{bmatrix} \Sigma_x & \Sigma_{xz} \\ \Sigma_{zx} & \Sigma_z \end{bmatrix}.$$

Qui:

- x è la quantità da stimare;
- z rappresenta le osservazioni.

Si considera quindi la densità marginale

$$f_{\bar{x}}(x).$$

Spiegazione – Perché il caso gaussiano è speciale

Assumere che x e z siano congiuntamente gaussiane rende il problema molto più semplice. Tutta l'informazione probabilistica rilevante è contenuta nella media e nella covarianza:

$$\bar{y}, \quad \Sigma_y.$$

La matrice a blocchi

$$\Sigma_y = \begin{bmatrix} \Sigma_x & \Sigma_{xz} \\ \Sigma_{zx} & \Sigma_z \end{bmatrix}$$

separa le incertezze di x e z e il modo in cui sono correlate.

Il blocco Σ_x descrive l'incertezza a priori su x , Σ_z descrive la variabilità delle osservazioni, mentre Σ_{xz} misura quanto le osservazioni sono informative su x . Se $\Sigma_{xz} = 0$, osservare z non aiuta a stimare x in senso lineare.

Stima MMSE (EAP)

$$\hat{x}^{\text{MMSE}} = E[x | z]$$

Sotto l'ipotesi che x e z siano congiuntamente gaussiane, vale la formula

$$E[x | z] = \bar{x} + \Sigma_{xz} \Sigma_z^{-1} (z - \bar{z}).$$

Spiegazione – Formula della media condizionata gaussiana

Nel caso congiuntamente gaussiano, la media a posteriori è un aggiornamento della media a priori:

$$E[x | z] = \bar{x} + \Sigma_{xz} \Sigma_z^{-1} (z - \bar{z}).$$

Il termine $z - \bar{z}$ è l'innovazione: misura quanto l'osservazione effettiva si discosta dal suo valore medio previsto.

Il guadagno

$$\Sigma_{xz} \Sigma_z^{-1}$$

traduce questa innovazione nello spazio del parametro x . Se z è molto variabile o poco

correlato con x , il guadagno è piccolo e la stima resta vicina a $\bar{x}$. Se invece z è molto correlato con x , l'osservazione modifica in modo significativo la stima.

Matrice di covarianza La matrice di covarianza è

$$\Sigma_{xx|z} = E[(x - \hat{x})(x - \hat{x})^T | z] = \Sigma_x - \Sigma_{xz}\Sigma_z^{-1}\Sigma_{zx}.$$

Da qui seguono due proprietà importanti:

- lo stimatore ottimo, nel senso MMSE, è **lineare in z** ;
- la covarianza **non dipende dalle particolari osservazioni**

Queste sono proprietà che discendono dall'ipotesi di gaussianità.

Spiegazione – Covarianza condizionata e riduzione dell'incertezza

La matrice

$$\Sigma_{xx|z} = \Sigma_x - \Sigma_{xz}\Sigma_z^{-1}\Sigma_{zx}$$

descrive l'incertezza residua su x dopo avere osservato z . Parte da Σ_x , cioè dall'incertezza prima della misura, e sottrae il contributo informativo portato dall'osservazione.

Il termine sottratto è tanto più grande quanto più x e z sono correlati. Se le osservazioni sono molto informative, la covarianza a posteriori diminuisce molto. Nel caso gaussiano questa covarianza non dipende dal valore specifico osservato, ma solo dalla struttura statistica del problema.

Negli altri casi In generale, negli altri casi:

- è complesso ricavare l'espressione della PDF a posteriori e quindi del suo valore atteso.

Conviene ricercare uno stimatore più "semplice", ad esempio un'espressione lineare delle osservazioni. Quindi si cerca uno stimatore "semplice" minimizzando l'MSE $\rightarrow$ *MMSE* lineare.

Spiegazione – Perché cercare uno stimatore lineare

Fuori dal caso gaussiano, la posterior può avere una forma complicata: può essere asimmetrica, multimodale o difficile da integrare. Calcolare

$$E[x | z]$$

può quindi diventare oneroso o non avere una formula chiusa.

Una scelta pratica è limitare la ricerca agli stimatori lineari o affini:

$$\hat{x} = Az + b.$$

Non si sta più cercando lo stimatore migliore in assoluto, ma il migliore dentro una classe semplice. Il risultato è il miglior stimatore lineare in senso MSE, spesso chiamato BLUE quando si impone anche la non polarizzazione.

Condizioni per lo stimatore lineare ottimo

Si impongono le seguenti condizioni:

1. stimatore non polarizzato;
2. errore di stima incorrelato con le osservazioni

Queste due condizioni costituiscono il **Principio di ortogonalità**

Spiegazione – Principio di ortogonalità

Il principio di ortogonalità dice che, per uno stimatore ottimo in senso quadratico, l'errore residuo non deve contenere informazione lineare ancora estraibile dalle osservazioni. Se l'errore fosse correlato con z , allora si potrebbe usare quella correlazione per correggere ulteriormente la stima.

Le due condizioni hanno ruoli distinti: la non polarizzazione impone che lo stimatore sia centrato correttamente, mentre l'incorrelazione tra errore e osservazioni impone che non resti una componente lineare sfruttabile. In forma compatta:

$$E[\tilde{x}] = 0, \quad E[\tilde{x}z^T] = 0.$$

Consideriamo x e z senza particolari assunzioni.

Si cerca uno stimatore della forma affine (che in realtà chiameremo lineare)

$$\hat{x} = Az + b.$$

Errore di stima Si definisce

$$\tilde{x} = x - \hat{x},$$

che rappresenta l'errore di stima.

Prima condizione: non polarizzazione Si richiede che l'errore abbia media nulla:

$$E[\tilde{x}] = 0.$$

Poiché

$$E[\tilde{x}] = \bar{x} - (A\bar{z} + b),$$

la condizione $E[\tilde{x}] = 0$ implica

$$b = \bar{x} - A\bar{z}.$$

(Che verifica la prima condizione).

Quindi lo stimatore può essere riscritto come

$$\hat{x} = Az + \bar{x} - A\bar{z} = \bar{x} + A(z - \bar{z}).$$

Spiegazione – Perché compare la forma centrata

Partendo da uno stimatore affine

$$\hat{x} = Az + b,$$

la non polarizzazione impone che la media della stima coincida con la media di x :

$$E[\hat{x}] = A\bar{z} + b = \bar{x}.$$

Da qui si ricava

$$b = \bar{x} - A\bar{z}.$$

Sostituendo b , lo stimatore diventa

$$\hat{x} = \bar{x} + A(z - \bar{z}).$$

Questa forma è molto utile: la stima parte dal valore medio a priori $\bar{x}$ e aggiunge un aggiornamento proporzionale all'innovazione $z - \bar{z}$.

Errore di stima:

$$\tilde{x} = x - \hat{x} = x - \bar{x} - A(z - \bar{z}).$$

Seconda condizione: Errore di stima incorrelato con le osservazioni Si richiede che l'errore di stima sia incorrelato con le osservazioni:

$$E[\tilde{x} z^T] = 0.$$

Equivalentemente, sostituendo l'errore di stima $\tilde{x}$ per come l'abbiamo scritto poco fa

$$E[(x - \bar{x} - A(z - \bar{z}))z^T] = 0.$$

Ma anche

$$E[\tilde{x}\bar{z}^T] = 0$$

Quindi

$$E[\tilde{x}z^T] - E[\tilde{x}\bar{z}^T] = 0$$

Dunque raccogliendo $\tilde{x}$

$$E[\tilde{x}(z - \bar{z})^T] = 0$$

Sostituendo l'espressione di $\tilde{x}$:

$$E[(x - \bar{x} - A(z - \bar{z}))(z - \bar{z})^T] = 0.$$

Da cui:

$$\Sigma_{xz} - A\Sigma_z = 0.$$

Da cui si ricava

$$A = \Sigma_{xz}\Sigma_z^{-1}.$$

(Che verifica la seconda condizione)

Spiegazione – Derivazione del guadagno lineare ottimo

Dopo avere imposto la non polarizzazione, resta da scegliere la matrice A . L'errore e'

$$\tilde{x} = x - \bar{x} - A(z - \bar{z}).$$

La condizione di ortogonalita' richiede

$$E[\tilde{x}(z - \bar{z})^T] = 0.$$

Sostituendo l'errore:

$$E[(x - \bar{x})(z - \bar{z})^T] - A E[(z - \bar{z})(z - \bar{z})^T] = 0.$$

I due valori attesi sono proprio

$$\Sigma_{xz} \quad \text{e} \quad \Sigma_z.$$

Quindi

$$\Sigma_{xz} - A\Sigma_z = 0,$$

da cui

$$A = \Sigma_{xz}\Sigma_z^{-1}.$$

$\hat{x} = Az + \bar{x} - A\bar{z} = \bar{x} + A(z - \bar{z}) = \bar{x} + \Sigma_{xz}\Sigma_z^{-1}(z - \bar{z}) \rightarrow$ MMSE Lineare o BLUE (Best Linear Unbiased Estimator)

La covarianza dell'errore di stima vale

$$E[\tilde{x}\tilde{x}^T] = \Sigma_x - \Sigma_{xz}\Sigma_z^{-1}\Sigma_{zx} = \Sigma_{xx|z}.$$

Quindi si ottiene il miglior stimatore lineare cercato tra sole funzioni lineari.

Spiegazione – BLUE e covarianza dell'errore

Inserendo il guadagno ottimo nella forma centrata si ottiene

$$\hat{x} = \bar{x} + \Sigma_{xz} \Sigma_z^{-1} (z - \bar{z}).$$

Questo e' il miglior stimatore lineare non polarizzato, cioe' BLUE. E' anche il MMSE lineare: tra tutti gli stimatori lineari, minimizza la covarianza dell'errore.

La covarianza residua e'

$$E[\tilde{x} \tilde{x}^T] = \Sigma_x - \Sigma_{xz} \Sigma_z^{-1} \Sigma_{zx}.$$

Il secondo termine rappresenta la parte di incertezza eliminata grazie alle osservazioni. Se l'osservazione e' informativa, questa sottrazione e' grande; se e' poco informativa, la covarianza rimane vicina a Σ_x .

Approfondiamo il caso di $h(\cdot, \cdot)$ lineare (non per forza Gaussiano)

$$\begin{cases} Y = Cx + V \\ x \sim (\bar{x}, \Sigma_x) \\ V \sim (0, \Sigma_V) \\ x \text{ e } V \text{ incorrelati} \end{cases}$$

Stimatore BLUE, ci mancano $\bar{y}, \Sigma_{xy}, \Sigma_y$ (verifica che sia Y o y)

Spiegazione – Modello lineare di misura

Il modello

$$Y = Cx + V$$

dice che l'osservazione Y e' una trasformazione lineare del parametro x , piu' un rumore additivo V . La matrice C descrive come il parametro entra nelle misure.

Per usare la formula del BLUE servono tre quantita':

$$\bar{y}, \quad \Sigma_{xy}, \quad \Sigma_y.$$

La media $\bar{y}$ dice quale osservazione ci si aspetta prima di misurare; la covarianza incrociata Σ_{xy} dice quanto x e Y sono collegati; la covarianza Σ_y misura l'incertezza complessiva delle osservazioni.

Media di y

$$\bar{y} = E[Y] = E[CX + V] = C\bar{x}.$$

Definiamo

$$\tilde{Y} = Y - \bar{y}.$$

Allora

$$\tilde{Y} = Cx + V - C\bar{x} = C\tilde{x} + V,$$

dove

$$\tilde{x} = x - \bar{x}.$$

Covarianza incrociata

$$\Sigma_{xy} = E[\tilde{x} \tilde{Y}^T] = E[\tilde{x} (C\tilde{x} + V)^T].$$

Poiché x e V sono incorrelati,

$$\Sigma_{xy} = \Sigma_x C^T.$$

Covarianza di Y

$$\Sigma_y = E[\tilde{Y} \tilde{Y}^T] = E[(C\tilde{x} + V)(C\tilde{x} + V)^T].$$

Ancora, usando l'incorrelazione tra x e V ,

$$\Sigma_y = C\Sigma_x C^T + \Sigma_V.$$

Spiegazione – Media e covarianze nel modello lineare

Nel modello lineare, la media delle osservazioni si ottiene propagando la media di x :

$$\bar{y} = C\bar{x}.$$

La parte aleatoria centrata e'

$$\tilde{Y} = C\tilde{x} + V.$$

La covarianza incrociata diventa

$$\Sigma_{xy} = E[\tilde{x} \tilde{Y}^T] = \Sigma_x C^T,$$

perche' il termine con V sparisce grazie all'incorrelazione tra x e rumore. La covarianza delle osservazioni e'

$$\Sigma_y = C\Sigma_x C^T + \Sigma_V.$$

Il primo termine e' l'incertezza su Y dovuta all'incertezza su x , il secondo e' l'incertezza dovuta al rumore di misura.

$$\hat{x}^{\text{BLUE}}(y) = \bar{x} + \Sigma_{xy} \Sigma_y^{-1} (y - \bar{y})$$

Sostituendo le espressioni ricavate in precedenza,

$$\begin{aligned} \hat{x}^{\text{BLUE}}(y) &= \bar{x} + \Sigma_x C^T (C\Sigma_x C^T + \Sigma_V)^{-1} (y - C\bar{x}) = \\ &= [I + \Sigma_x C^T (C\Sigma_x C^T + \Sigma_V)^{-1} C] \bar{x} + \Sigma_x C^T (C\Sigma_x C^T + \Sigma_V)^{-1} y \end{aligned}$$

Spiegazione – BLUE nel modello lineare

Sostituendo le covarianze del modello $Y = Cx + V$ nella formula generale, si ottiene

$$\hat{x}^{\text{BLUE}}(y) = \bar{x} + \Sigma_x C^T (C\Sigma_x C^T + \Sigma_V)^{-1} (y - C\bar{x}).$$

Anche qui la stima ha la forma "prior piu' aggiornamento".

Il residuo

$$y - C\bar{x}$$

e' l'innovazione della misura rispetto a cio' che ci si aspettava dalla prior. La matrice

$$\Sigma_x C^T (C\Sigma_x C^T + \Sigma_V)^{-1}$$

e' il guadagno: decide quanto fidarsi dell'innovazione. Se il rumore Σ_V e' grande, il guadagno diminuisce; se la prior e' molto incerta, il guadagno tende a dare piu' peso alla misura.

Lemma di inversione di matrice

Si usa il lemma

$$(P + CQC^T)^{-1} = P^{-1} - P^{-1}C(Q^{-1} + C^T P^{-1}C)^{-1}C^T P^{-1}$$

e inoltre

$$QC^T(P + CQC^T)^{-1} = (Q^{-1} + C^TP^{-1}C)^{-1}C^TP^{-1}.$$

Applico il lemma a $\hat{x}^{BLUE}(y)$, per il primo termine:

$$\left[\Sigma_X - \Sigma_X C^T (C \Sigma_X C^T + \Sigma_V)^{-1} C \Sigma_X \right] \Sigma_X^{-1} \bar{X}$$

si pone:

$$P^{-1} = \Sigma_x, \quad C = C^T \quad Q^{-1} = \Sigma_V$$

e diventa

$$(\Sigma_x^{-1} + C^T \Sigma_V^{-1} C)^{-1} \Sigma_x^{-1} \bar{x}$$

Per il secondo termine:

$$\Sigma_x C^T (C \Sigma_x C^T + \Sigma_V)^{-1} y$$

Si pone

$$Q = \Sigma_x, \quad C = C, \quad P = \Sigma_V$$

e diventa

$$(\Sigma_x^{-1} + C^T \Sigma_V^{-1} C)^{-1} C^T \Sigma_V^{-1} y$$

Pertanto, mettendo tutto insieme e poi raccogliendo i due contributi, si ottiene la forma compatta

$$\begin{aligned} \hat{x}^{BLUE}(y) &= (\Sigma_x^{-1} + C^T \Sigma_V^{-1} C)^{-1} \Sigma_x^{-1} \bar{x} + (\Sigma_x^{-1} + C^T \Sigma_V^{-1} C)^{-1} C^T \Sigma_V^{-1} y. = \\ &= (\Sigma_x^{-1} + C^T \Sigma_V^{-1} C)^{-1} (\Sigma_x^{-1} \bar{x} + C^T \Sigma_V^{-1} y) \end{aligned}$$

Spiegazione – Forma in informazione dello stimatore BLUE

Il lemma di inversione permette di riscrivere lo stimatore in una forma molto interpretabile:

$$\hat{x}^{BLUE} = (\Sigma_x^{-1} + C^T \Sigma_V^{-1} C)^{-1} (\Sigma_x^{-1} \bar{x} + C^T \Sigma_V^{-1} y).$$

Qui compaiono le inverse delle covarianze, cioè le informazioni.

Il termine Σ_x^{-1} rappresenta l'informazione a priori, mentre $C^T \Sigma_V^{-1} C$ rappresenta l'informazione portata dalle osservazioni. Anche il vettore a destra è una somma di contributi: $\Sigma_x^{-1} \bar{x}$ è il contributo della prior, $C^T \Sigma_V^{-1} y$ è il contributo dei dati. La stima è quindi una media pesata in termini di informazione.

$$\hat{\Sigma}_X^{BLUE} = \Sigma_x - \Sigma_{xy} \Sigma_y^{-1} \Sigma_{yx}$$

Sostituendo

$$\Sigma_{xy} = \Sigma_X C^T, \quad \Sigma_y = C \Sigma_x C^T + \Sigma_V,$$

si ottiene

$$\hat{\Sigma}_x^{BLUE} = \Sigma_x - \Sigma_x C^T (C \Sigma_x C^T + \Sigma_V)^{-1} C \Sigma_x$$

Applicando il lemma di inversione di matrice, questa espressione diventa

$$\hat{\Sigma}_x^{BLUE} = (\Sigma_x^{-1} + C^T \Sigma_V^{-1} C)^{-1}.$$

Di conseguenza,

$$(\hat{\Sigma}_x^{BLUE})^{-1} = \Sigma_x^{-1} + C^T \Sigma_V^{-1} C.$$

Spiegazione – Covarianza BLUE e somma delle informazioni

La covarianza finale dello stimatore e'

$$\hat{\Sigma}_x^{BLUE} = (\Sigma_x^{-1} + C^T \Sigma_V^{-1} C)^{-1}.$$

Prendendo l'inversa si vede meglio il significato:

$$(\hat{\Sigma}_x^{BLUE})^{-1} = \Sigma_x^{-1} + C^T \Sigma_V^{-1} C.$$

Quindi l'informazione a posteriori e' la somma dell'informazione a priori e dell'informazione portata dalle misure. Questa e' una delle forme piu' importanti della stima lineare: ogni osservazione riduce l'incertezza solo nella misura in cui porta informazione rispetto al rumore.

Osservazioni non informative

Se le osservazioni sono non informative, allora

$$\Sigma_V^{-1} \approx 0.$$

In questo caso,

$$\hat{x}^{BLUE}(y) \rightarrow \bar{x}$$

e

$$\hat{\Sigma}_x^{BLUE} \rightarrow \Sigma_x.$$

Quindi, se il rumore è molto elevato e le osservazioni portano poca informazione, lo stimatore tende semplicemente al valore medio $\bar{x}$, e la covarianza a posteriori tende a quella a priori.

Spiegazione – Caso di osservazioni poco informative

Dire che

$$\Sigma_V^{-1} \approx 0$$

significa che il rumore di misura ha varianza molto grande, quindi la sua informazione e' quasi nulla. In questo limite il termine dei dati nella formula BLUE scompare.

Lo stimatore tende a

$$\hat{x}^{BLUE} \rightarrow \bar{x},$$

perche' non conviene fidarsi dell'osservazione. Anche la covarianza resta quella a priori:

$$\hat{\Sigma}_x^{BLUE} \rightarrow \Sigma_x.$$

In parole semplici: se le misure sono troppo rumorose, il modo migliore di stimare e' restare alla conoscenza precedente.

Assenza di informazione a priori

Se invece manca informazione a priori, ovvero:

$$\Sigma_x^{-1} \approx 0.$$

In tal caso,

$$\hat{x}^{BLUE} \rightarrow (C^T \Sigma_V^{-1} C)^{-1} C^T \Sigma_V^{-1} y$$

e

$$\hat{\Sigma}_x^{BLUE} \rightarrow (C^T \Sigma_V^{-1} C)^{-1}.$$

Spiegazione – Caso senza informazione a priori

La condizione

$$\Sigma_x^{-1} \approx 0$$

significa che la prior e' molto incerta, quindi porta pochissima informazione. In questo caso la stima e la covarianza dipendono quasi solo dai dati:

$$\hat{x}^{BLUE} \rightarrow (C^T \Sigma_V^{-1} C)^{-1} C^T \Sigma_V^{-1} y.$$

Questa e' la stessa struttura dei minimi quadrati pesati. L'inversa della covarianza del rumore, Σ_V^{-1} , pesa le misure: misure piu' precise hanno peso maggiore, misure piu' rumorose hanno peso minore.

Legame con i minimi quadrati pesati

Si consideri il modello

$$Y = Cx + V.$$

Ponendo

$$W = \Sigma_V^{-1},$$

si può definire lo stimatore ai minimi quadrati pesati come

$$\hat{x}^{LS}(y) = \arg \min_x (y - Cx)^T W (y - Cx).$$

La soluzione è

$$\hat{x}^{LS} = (C^T W C)^{-1} C^T W y.$$

Questa è la pseudoinversa pesata con W .

Spiegazione – Minimi quadrati pesati

Nei minimi quadrati ordinari si minimizza la norma dei residui:

$$(y - Cx)^T (y - Cx).$$

Nei minimi quadrati pesati si introduce

$$W = \Sigma_V^{-1},$$

e si minimizza

$$(y - Cx)^T W (y - Cx).$$

Questo significa che gli errori non vengono tutti trattati allo stesso modo: un residuo associato a una misura precisa pesa di piu', mentre un residuo associato a una misura rumorosa pesa di meno. La soluzione

$$\hat{x}^{LS} = (C^T W C)^{-1} C^T W y$$

coincide con il limite del BLUE quando non si ha informazione a priori e resta solo l'informazione contenuta nelle osservazioni.

Caso non lineare

Si consideri un modello di misura non lineare della forma

$$Y = h(x, V),$$

con

$$\begin{bmatrix} x \\ V \end{bmatrix} \sim \mathcal{N}\left(\begin{bmatrix} \bar{x} \\ 0 \end{bmatrix}, \begin{bmatrix} \Sigma_x & 0 \\ 0 & \Sigma_V \end{bmatrix}\right).$$

In questo caso ricavare esplicitamente

$$\bar{y}, \quad \Sigma_y, \quad \Sigma_{xy}$$

può essere complicato.

Per affrontare il problema si possono seguire diversi approcci:

1. linearizzare $h(\cdot)$;
2. usare la *Unscented Transform*;
3. usare metodi Monte Carlo.

Spiegazione – Cosa cambia nel caso non lineare

Nel modello non lineare

$$Y = h(x, V)$$

la media e le covarianze di Y non si ottengono più semplicemente propagando x con una matrice C . Anche se x e V sono gaussiani, l'uscita Y può non essere gaussiana dopo la trasformazione non lineare.

Per questo diventano utili tre strategie. La linearizzazione approssima h localmente con una funzione lineare e permette di riutilizzare formule simili al BLUE. L'Unscented Transform propaga un insieme scelto di punti rappresentativi della distribuzione. I metodi Monte Carlo generano molti campioni casuali e stimano media e covarianza empiricamente. Tutte e tre sono tecniche per ottenere approssimazioni pratiche quando la formula chiusa non è disponibile.

Facciamo un piccolo recap sulla stima statica: (ps: fino ad ora tante x che dovevano essere X in quanto variabili aleatorie sono minuscole, magari sistemale)

$$\text{MMSE} \equiv \text{EAP}.$$

Caso gaussiano Nel caso gaussiano lo stimatore MMSE è

$$\hat{x}^{\text{MMSE}}(z) = \bar{x} + \Sigma_{XZ} \Sigma_Z^{-1} (z - \bar{z}).$$

MMSE lineare: BLUE Lo stimatore MMSE lineare prende il nome di BLUE, cioè

$$\text{BLUE} = \text{Best Linear Unbiased Estimator}.$$

Nel caso di modello di osservazione lineare

$$Y = CX + V,$$

si ottiene

$$\hat{X}^{\text{BLUE}}(y) = (\Sigma_X^{-1} + C^T \Sigma_V^{-1} C)^{-1} (\Sigma_X^{-1} \bar{x} + C^T \Sigma_V^{-1} y).$$

Modello di osservazione non lineare

Ci chiediamo cosa accade se il modello di osservazione non è lineare.

In generale, i momenti

$$\bar{y}, \quad \Sigma_{XY}, \quad \Sigma_Y$$

non sono facilmente calcolabili.

Per affrontare il problema si possono seguire tre vie:

1. linearizzazione;
2. trasformata unscented;
3. metodi Monte Carlo.

Linearizzazione

Si consideri il modello non lineare

$$Y = h(X, V),$$

con

$$\begin{bmatrix} X \\ V \end{bmatrix} \sim \left(\begin{bmatrix} \bar{x} \\ 0 \end{bmatrix}, \begin{bmatrix} \Sigma_X & 0 \\ 0 & \Sigma_V \end{bmatrix} \right).$$

Si approssima la funzione non lineare $h(X, V)$ tramite linearizzazione intorno ai valori medi a priori:

$$Y = h(X, V) \simeq CX + BV.$$

Le matrici C e B sono le matrici jacobiane valutate nelle medie a priori:

$$C = \left. \frac{\partial h(X, V)}{\partial X} \right|_{\substack{X=\bar{x} \\ V=0}}, \quad B = \left. \frac{\partial h(X, V)}{\partial V} \right|_{\substack{X=\bar{x} \\ V=0}}.$$

Quindi C e B sono matrici jacobiane calcolate rispettivamente rispetto a X e rispetto a V , valutate in

$$X = \bar{x}, \quad V = 0.$$

La matrice B fa sì che tutte le volte in cui compare Σ_V , essa debba essere sostituita da

$$B\Sigma_V B^T.$$

Trasformata Unscented

Un altro approccio è dato dalla **trasformata Unscented**.

Si consideri una variabile aleatoria

$$\underline{x} \sim (\bar{x}, \Sigma_X)$$

e una trasformazione non lineare

$$g : \underline{x} \longrightarrow \bar{y}.$$

Allora

$$\bar{y} = g(\underline{x}).$$

Il problema è calcolare i momenti di $\underline{Y}$, cioè

$$\bar{y}, \quad \Sigma_Y, \quad \Sigma_{XY}.$$

La trasformata Unscented restituisce un'approssimazione di questi momenti:

$$\bar{y}, \quad \Sigma_Y, \quad \Sigma_{XY}.$$

Storicamente, il metodo è dovuto a Uhlmann, 1995.

Si può scrivere sinteticamente:

$$UT(\bar{x}, \Sigma_X, g(\cdot)) = [\bar{y}, \Sigma_Y, \Sigma_{XY}].$$

Caso con stato e rumore Definiamo la variabile aumentata

$$X' = \begin{bmatrix} X \\ V \end{bmatrix}.$$

La trasformazione diventa

$$g(X') = h(X, V).$$

Dato che

$$\begin{bmatrix} X \\ V \end{bmatrix} \sim \left(\begin{bmatrix} \bar{x} \\ 0 \end{bmatrix}, \begin{bmatrix} \Sigma_X & 0 \\ 0 & \Sigma_V \end{bmatrix} \right),$$

si applica la trasformata Unscented come

$$UT\left(\begin{bmatrix} \bar{x} \\ 0 \end{bmatrix}, \begin{bmatrix} \Sigma_X & 0 \\ 0 & \Sigma_V \end{bmatrix}, g(\cdot)\right) = [\bar{y}, \Sigma_Y, \Sigma_{X'Y}].$$

Poiché

$$X' = \begin{bmatrix} X \\ V \end{bmatrix},$$

la covarianza incrociata con Y si può scrivere come

$$\Sigma_{X'Y} = \begin{bmatrix} \Sigma_{XY} \\ \Sigma_{VY} \end{bmatrix}.$$

Per la stima BLUE serve in particolare il blocco

$$\Sigma_{XY}.$$

Quindi, dalla trasformata Unscented, si ricavano approssimativamente i momenti necessari alla stima BLUE:

$$\bar{y}, \quad \Sigma_Y, \quad \Sigma_{XY}.$$

Caso particolare con rumore additivo

Si consideri il modello

$$Y = h(X) + V,$$

cioè un caso particolare con rumore additivo.

Definiamo la variabile aleatoria

$$Z = h(X).$$

Poiché X e V sono incorrelati, si ha:

$$\bar{y} = \bar{z},$$

e

$$\Sigma_Y = \Sigma_Z + \Sigma_V.$$

Inoltre,

$$\Sigma_{XY} = \Sigma_{XZ}.$$

I momenti

$$\bar{z}, \quad \Sigma_Z, \quad \Sigma_{XZ}$$

possono essere approssimati tramite trasformata Unscented:

$$[\bar{z}, \Sigma_Z, \Sigma_{XZ}] = UT[\bar{x}, \Sigma_X, h(\cdot)].$$

Da questi si ottengono poi:

$$\bar{y} = \bar{z}, \quad \Sigma_Y = \Sigma_Z + \Sigma_V, \quad \Sigma_{XY} = \Sigma_{XZ}.$$

Sigma-points

L'idea della trasformata Unscented è generare un insieme minimale di campioni, detti *sigma-points*, con peso associato.

Questi punti devono essere **coerenti** con i momenti di X , cioè con

$$\bar{x}, \quad \Sigma_X.$$

(media e covarianza campionarie $\equiv \bar{x}, \Sigma_X$) In particolare, se i sigma-points sono indicati con X_i e i pesi associati con w_i , devono valere:

$$\sum_i w_i X_i = \bar{x}, \tag{1}$$

$$\sum_i w_i (X_i - \bar{x})(X_i - \bar{x})^T = \Sigma_X. \tag{2}$$

La prima condizione garantisce che la media campionaria pesata coincida con la media teorica $\bar{x}$.

La seconda condizione garantisce che la covarianza campionaria pesata coincida con la covarianza teorica Σ_X .

Se

$$n = \dim(X),$$

basterebbero in teoria $n + 1$ sigma-points.

Per ragioni di simmetria, però, se ne usano

$$2n + 1.$$

In particolare:

1 punto centrale

e

$2n$ punti simmetrici a coppie rispetto al centrale.

Costruzione dei sigma-points

Siano

$$X_i \in \mathbb{R}^n, \quad i = -n, \dots, -1, 0, 1, \dots, n.$$

Fattorizzazione di Σ_X Si considera una fattorizzazione della matrice di covarianza

$$\Sigma_X = \Gamma \Gamma^T.$$

Indicando con γ_i la i -esima colonna di Γ , si può scrivere

$$\Sigma_X = \Gamma \Gamma^T = \sum_{i=1}^n \gamma_i \gamma_i^T.$$

La matrice Γ può essere ottenuta in diversi modi, ad esempio:

- decomposizione di Cholesky;
- SVD:

$$\Sigma_X = V \Lambda V^T \quad \Rightarrow \quad \Gamma = V \Lambda^{1/2};$$

- radice quadrata simmetrica:

$$\Gamma = \Gamma^T.$$

Condizione sulla covarianza campionaria pesata La seconda condizione sui sigma-points è

$$\sum_{i=-n}^n w_i (X_i - \bar{x})(X_i - \bar{x})^T = \sum_{i=1}^n \gamma_i \gamma_i^T = \Sigma_X. \quad (2)$$

Si scelgono quindi i punti in modo simmetrico rispetto alla media.

Sia a_i uno scalare. Allora:

$$X_i - \bar{x} = \begin{cases} a_i \gamma_i, & i > 0, \\ 0, & i = 0, \\ -a_i \gamma_i, & i < 0. \end{cases}$$

Equivalentemente, i sigma-points sono

$$X_i = \begin{cases} \bar{x} + a_i \gamma_i, & i > 0, \\ \bar{x}, & i = 0, \\ \bar{x} - a_i \gamma_i, & i < 0. \end{cases}$$

Il punto $X_0 = \bar{x}$ è il sigma-point centrale.

Per simmetria si scelgono pesi uguali per le coppie opposte:

$$w_i = w_{-i}.$$

Tornando alla condizione sulla covarianza, si ha

$$\sum_{i=1}^n 2w_i a_i^2 \gamma_i \gamma_i^T = \sum_{i=1}^n \gamma_i \gamma_i^T.$$

Quindi è sufficiente imporre

$$2w_i a_i^2 = 1.$$

Da cui

$$a_i = \frac{1}{\sqrt{2w_i}}, \quad \forall i = 1, 2, \dots, n.$$

Condizione sulla media

La prima condizione sui sigma-points è

$$\sum_{i=-n}^n w_i X_i = \bar{x}. \quad (1)$$

Questa condizione vale se

$$\sum_{i=-n}^n w_i = 1.$$

Infatti,

$$\sum_{i=-n}^n w_i X_i = \left(\sum_{i=-n}^n w_i \right) \bar{x} = \bar{x}.$$

Scelta dei pesi

Tutti i pesi, tranne quello centrale, vengono scelti uguali tra loro:

$$w_i = w, \quad \forall i \neq 0.$$

Dalla condizione di normalizzazione dei pesi si ottiene

$$w_0 + 2nw = 1.$$

Scelto w_0 , segue

$$w = \frac{1 - w_0}{2n}.$$

Inoltre, dalla condizione sulla covarianza,

$$a_i = a = \frac{1}{\sqrt{2w}} = \frac{1}{\sqrt{\frac{1 - w_0}{n}}} = \sqrt{\frac{n}{1 - w_0}}, \quad \forall i \neq 0.$$

Scelta di w_0

Rimane da scegliere il peso centrale w_0 .

In letteratura si pone

$$w_0 = \frac{\lambda}{n + \lambda},$$

dove λ è un parametro libero.

Con questa scelta,

$$w = \frac{1 - w_0}{2n} = \frac{1 - \frac{\lambda}{n + \lambda}}{2n}.$$

Semplificando,

$$w = \frac{\frac{n + \lambda - \lambda}{n + \lambda}}{2n} = \frac{\frac{n}{n + \lambda}}{2n} = \frac{1}{2(n + \lambda)}.$$

Sostituendo la scelta di w_0 , si ottiene

$$a = \sqrt{\frac{n}{1-w_0}} = \sqrt{\frac{n}{1-\frac{\lambda}{n+\lambda}}}.$$

Semplificando:

$$a = \sqrt{\frac{n}{\frac{n+\lambda-\lambda}{n+\lambda}}} = \sqrt{\frac{n}{\frac{n}{n+\lambda}}} = \sqrt{n+\lambda}.$$

Quindi, fissato il parametro λ , si ha

$$w = \frac{1}{2(n+\lambda)}, \quad a = \sqrt{n+\lambda}.$$

Scelta dei sigma-points

Scelto λ , i sigma-points sono dati da

$$x_i = \begin{cases} \bar{x} + \sqrt{n+\lambda} \gamma_i, & i > 0, \\ \bar{x}, & i = 0, \\ \bar{x} - \sqrt{n+\lambda} \gamma_i, & i < 0. \end{cases}$$

dove γ_i è la i -esima colonna della matrice Γ , tale che

$$\Sigma_X = \Gamma \Gamma^T.$$

Propagazione dei sigma-points

Ogni sigma-point viene propagato attraverso la funzione non lineare $g(\cdot)$:

$$Y_i = g(X_i), \quad i = -n, \dots, n.$$

In questo modo si ottengono $2n+1$ punti trasformati.

$$X_i \xrightarrow{g(\cdot)} Y_i$$

$$Y_i = g(X_i).$$

Ricostruzione dei momenti

A partire dai punti trasformati Y_i , si ricavano in maniera campionaria i momenti

$$\bar{y}, \quad \Sigma_Y, \quad \Sigma_{XY}.$$

La media trasformata è

$$\bar{y} = \sum_{i=-n}^n w_i Y_i.$$

La covarianza di Y è

$$\Sigma_Y = \sum_{i=-n}^n w'_i (Y_i - \bar{y})(Y_i - \bar{y})^T.$$

La covarianza incrociata tra X e Y è

$$\Sigma_{XY} = \sum_{i=-n}^n w'_i (X_i - \bar{x})(Y_i - \bar{y})^T.$$

I pesi w'_i possono essere scelti eventualmente diversi dai pesi w_i usati per la media, a seconda della specifica variante della trasformata Unscented. (Questo detto da chat gpt, effettivamente non ricordo perché aggiunse questi apici ai pesi).

Algoritmo più generale: SUT

L'algoritmo più generale prende il nome di

$$\text{SUT} = \textit{Scaled Unscented Transform}.$$

Rispetto alla trasformata Unscented vista prima, nella SUT si usano parametri aggiuntivi per scalare i sigma-points e modificare i pesi.

I pesi vengono scelti come

$$\begin{cases} w'_0 = w_0 + 1 - \alpha^2 + \beta, \\ w'_i = w_i \end{cases}$$

Il parametro λ viene scelto come

$$\lambda = \alpha^2(n + \kappa) - n,$$

con

$$\alpha \in (0, 1], \quad \kappa \geq 0.$$

Di conseguenza, i sigma-points non vengono più costruiti come

$$\bar{x} + \sqrt{n + \lambda} \gamma_i,$$

ma come

$$\bar{x} + \alpha \sqrt{n + \kappa} \gamma_i.$$

Ruolo di β Il parametro β è utilizzato per tenere conto della “forma” della PDF di $\underline{X}$.

Nel caso gaussiano, una scelta ottima è

$$\beta = 2.$$

Osservazioni sulla SUT

I momenti

$$\bar{y}, \quad \Sigma_Y, \quad \Sigma_{XY}$$

sono un'approssimazione al secondo ordine dei veri momenti.

La linearizzazione, invece, fornisce un'approssimazione al primo ordine.

Inoltre, la trasformata Unscented non richiede di derivare la funzione non lineare

$$h(\cdot, \cdot).$$

Parametri della SUT

La SUT dipende dai parametri

$$\alpha, \quad \kappa, \quad \beta.$$

Se

$$\alpha = 1,$$

si ottiene la trasformata non scalata. Infatti,

$$\lambda = \kappa.$$

Per quanto riguarda i pesi:

$$w'_0 = w_0 + 1 - \alpha^2 + \beta.$$

Se inoltre

$$\beta = 0,$$

allora si hanno gli stessi pesi per la media e per la covarianza:

$$w'_0 = w_0.$$

Nel caso gaussiano si sceglie solitamente

$$\beta = 2,$$

che è ottimo per distribuzioni gaussiane.

Infine, il parametro $\kappa \geq 0$ influenza i termini di ordine superiore al secondo nell'approssimazione.

Algoritmo più generale: SUT

L'algoritmo più generale prende il nome di

$$\text{SUT} = \textit{Scaled Unscented Transform}.$$

Rispetto alla trasformata Unscented vista prima, nella SUT si usano parametri aggiuntivi per scalare i sigma-points e modificare i pesi.

I pesi vengono scelti come

$$\begin{cases} w'_0 = w_0 + 1 - \alpha^2 + \beta, \\ w'_i = w_i, & i \neq 0. \end{cases}$$

Il parametro λ viene scelto come

$$\lambda = \alpha^2(n + \kappa) - n,$$

con

$$\alpha \in (0, 1], \quad \kappa \geq 0.$$

Di conseguenza, i sigma-points non vengono più costruiti come

$$\bar{x} + \sqrt{n + \lambda} \gamma_i,$$

ma come

$$\bar{x} + \alpha \sqrt{n + \kappa} \gamma_i.$$

Ruolo di β Il parametro β è utilizzato per tenere conto della “forma” della PDF di X .
Nel caso gaussiano, una scelta ottima è

$$\beta = 2.$$

Osservazioni sulla SUT

I momenti

$$\bar{y}, \quad \Sigma_Y, \quad \Sigma_{XY}$$

sono un'approssimazione al secondo ordine dei veri momenti.

La linearizzazione, invece, fornisce un'approssimazione al primo ordine.

Inoltre, la trasformata Unscented non richiede di derivare la funzione non lineare

$$h(\cdot, \cdot).$$

Parametri della SUT

La SUT dipende dai parametri

$$\alpha, \quad \kappa, \quad \beta.$$

Se

$$\alpha = 1,$$

si ottiene la trasformata non scalata. Infatti,

$$\lambda = \kappa.$$

Per quanto riguarda i pesi:

$$w'_0 = w_0 + 1 - \alpha^2 + \beta.$$

Se inoltre

$$\beta = 0,$$

allora si hanno gli stessi pesi per la media e per la covarianza:

$$w'_0 = w_0.$$

Nel caso gaussiano si sceglie solitamente

$$\beta = 2,$$

che è ottimo per distribuzioni gaussiane.

Infine, il parametro $\kappa \geq 0$ influenza i termini di ordine superiore al secondo nell'approssimazione.

Se avessi $\{\bar{\mathbf{g}}(x)\}$ gaussiana, una possibile scelta dei parametri sarebbe

$$\alpha = 1, \quad \beta = 2, \quad \kappa = 0.$$

Naturalmente non si usano sempre questi valori: la scelta dipende dal problema e dalla distribuzione considerata.

Altro approccio: metodo Monte Carlo

Si considera ora un altro approccio per approssimare gli stimatori: il **metodo Monte Carlo**.

Stima MMSE (EAP) Lo stimatore MMSE, equivalente allo stimatore EAP, è

$$\hat{X}^{\text{MMSE}} = E[\underline{X} \mid \underline{Y}].$$

In forma integrale,

$$\hat{X}^{\text{MMSE}} = \int x f_{\underline{X}|\underline{Y}}(x \mid y) dx = \frac{\int x f_{\underline{Y}|\underline{X}}(y \mid x) f_{\underline{X}}(x) dx}{\int f_{\underline{Y}|\underline{X}}(y \mid x) f_{\underline{X}}(x) dx}.$$

In generale non riusciamo a calcolare questi integrali in forma chiusa, quindi serve una loro approssimazione.

Covarianza dell'errore MMSE Si può stimare anche la covarianza dell'errore associata allo stimatore MMSE:

$$\hat{\Sigma}_X^{\text{MMSE}} = E[(\underline{X} - \hat{X}^{\text{MMSE}})(\underline{X} - \hat{X}^{\text{MMSE}})^T \mid \underline{Y}].$$

In forma integrale,

$$\hat{\Sigma}_X^{\text{MMSE}} = \frac{\int (x - \hat{X}^{\text{MMSE}})(x - \hat{X}^{\text{MMSE}})^T \dots dx}{\int \dots dx}.$$

Più in generale, questi integrali possono essere visti nella forma

$$E[g(\underline{X}) \mid \underline{Y}].$$

Approssimazione Monte Carlo L'idea del metodo Monte Carlo è approssimare gli integrali tramite somme finite, usando un numero elevato di valutazioni della funzione.

In particolare, l'integrale viene approssimato tramite una somma di Riemann:

$$\text{Riemann} \longrightarrow K^n \text{ valutazioni della funzione.}$$

Il problema è che questo approccio può diventare molto oneroso, perché richiede un numero enorme di valutazioni quando la dimensione n cresce (quindi queste valutazioni possono essere "troppe").

Approccio alternativo: campionamento casuale

Un approccio alternativo consiste nel generare casualmente N punti in cui valutare la funzione.

Si consideri l'integrale

$$\mathcal{I} = \int_S f(x) dx.$$

Si introduce una PDF $p(x)$ tale che

$$\int p(x) dx = 1. \quad \text{su tutto il dominio } \mathbb{R}^n$$

Il dominio su cui $p(x)$ è positiva è detto supporto di $p(\cdot)$:

$$S_p := \{x \in \mathbb{R}^n : p(x) > 0\}.$$

Si assume che

$$S \subseteq S_p.$$

Allora si può riscrivere l'integrale come

$$\mathcal{I} = \int_S f(x) dx = \int_S \frac{f(x)}{p(x)} p(x) dx$$

Per estendere l'integrale a tutto $\mathbb{R}^n$, si definisce l'estensione nulla di $f(x)$:

$$f^E(x) = \begin{cases} f(x), & x \in S, \\ 0, & x \notin S. \end{cases}$$

Quindi

$$\mathcal{I} = \int_{S_p} \frac{f^E(x)}{p(x)} p(x) dx.$$

Definendo

$$g(x) = \frac{f^E(x)}{p(x)},$$

si ottiene

$$\mathcal{I} = \int_{\mathbb{R}^n} g(x) p(x) dx = E_{p(\cdot)}[g(X)].$$

Quindi l'integrale $\equiv$ media di $g(X)$ secondo la distribuzione $p(\cdot)$. Si può approssimare con media campionaria (N deve essere grande)

Stimatore Monte Carlo

Si generano casualmente N campioni secondo la densità $p(\cdot)$:

$$X_i \sim p(\cdot), \quad i = 1, \dots, N.$$

I campioni X_i sono quindi generati in maniera casuale secondo $p(\cdot)$.

L'integrale viene approssimato tramite la media campionaria:

$$\mathcal{I} \simeq \mathcal{I}_N = \frac{1}{N} \sum_{i=1}^N g(X_i).$$

Poiché

$$g(x) = \frac{f^E(x)}{p(x)},$$

si ottiene

$$\mathcal{I}_N = \frac{1}{N} \sum_{i=1}^N \frac{f^E(X_i)}{p(X_i)}.$$

Poiché $f^E(x) = f(x)$ per $x \in S$ e $f^E(x) = 0$ per $x \notin S$, si può scrivere anche

$$\mathcal{I}_N = \frac{1}{N} \sum_{j: X_j \in S} \frac{f(X_j)}{p(X_j)}.$$

Proprietà dello stimatore

Lo stimatore Monte Carlo $\mathcal{I}_N$ della quantità $\mathcal{I}$ è asintoticamente non polarizzato:

$$\lim_{N \rightarrow \infty} E[\mathcal{I}_N - \mathcal{I}] = 0.$$

Inoltre, la varianza tende a zero come

$$\text{Var}[\mathcal{I}_N] \rightarrow 0 \quad \text{come} \quad \frac{1}{N}.$$

Quindi, aumentando il numero di campioni N , la stima diventa progressivamente più accurata.

Recap delle scorse lezioni (sempre stima statica) MMSE e BLUE

Nel caso di modelli lineari si considera

$$Y = CX + V.$$

Per questi modelli si sono introdotti:

$$\text{MMSE} \quad \text{e} \quad \text{BLUE}.$$

Modelli non lineari Nel caso di modelli non lineari, i momenti

$$\bar{y}, \quad \Sigma_Y, \quad \Sigma_{XY}$$

sono difficili da calcolare.

Per stimarli si possono usare tre approcci:

- linearizzazione;
- trasformata Unscented;
- metodo Monte Carlo.

Metodo Monte Carlo

Si vuole calcolare una quantità del tipo

$$E[g(\bar{X}) | \bar{Y}].$$

Nel caso della stima MMSE:

$$g(\bar{X}) = \bar{X} \quad \Rightarrow \quad \hat{X}^{MMSE}$$

Nel caso della covarianza dell'errore:

$$g(\bar{X}) = (\bar{X} - \hat{X}^{MMSE})(\bar{X} - \hat{X}^{MMSE})^T \quad \Rightarrow \quad \Sigma_X.$$

Usando la formula di Bayes, si può scrivere

$$E[\underline{X} | \underline{Y}] = \frac{\int x f_{\underline{Y}|\underline{X}}(y | x) f_{\underline{X}}(x) dx}{\int f_{\underline{Y}|\underline{X}}(y | x) f_{\underline{X}}(x) dx}.$$

Questo integrale può essere approssimato con metodi numerici:

Riemann oppure Monte Carlo.

Recap sull'integrazione Monte Carlo Dato un integrale

$$\mathcal{I} = \int_S f(x) dx,$$

lo si approssima generando campioni

$$X_i \sim p(\cdot),$$

ottenendo

$$\mathcal{I} = \int_S f(x) dx \simeq \frac{1}{N} \sum_{j: x_j \in S} \frac{f(x_j)}{p(x_j)}.$$

Fine recap

Osservazioni I campioni X_i che non appartengono a S , di fatto, non contribuiscono alla stima. Inoltre, se

$$S_p \setminus S$$

cioè il complementare di S in S_p , è più "piccolo" possibile, allora la stima è più efficiente. In altri termini, è utile scegliere S_p quanto più "aderente" possibile a S .

Scelta della distribuzione di campionamento

Per applicare il metodo Monte Carlo è utile scegliere una densità $p(\cdot)$ facilmente campionabile. Deve quindi esistere un generatore di valori casuali coerente con $p(\cdot)$.

Esempio: calcolo del volume di un insieme


Si vuole calcolare il volume di un insieme S :

$$\mathcal{I} = \int_S 1 dx = \text{vol}(S).$$

Si supponga di conoscere un insieme Ω che contiene S , ovvero Ω "aderente" ad S , cioè

$$S \subseteq \Omega,$$

e tale che Ω abbia dimensione e forma note.



Si utilizza quindi una distribuzione uniforme per il campionamento in Ω :

$$p(x) = \begin{cases} \frac{1}{\text{vol}(\Omega)}, & x \in \Omega, \\ 0, & x \notin \Omega. \end{cases}$$

Secondo l'approccio Monte Carlo, si ha

$$\mathcal{I} = \text{vol}(S) \simeq \mathcal{I}_N = \frac{1}{N} \sum_{i=1}^N \frac{f^E(x_i)}{p(x_i)}.$$

Poiché $f(x) = 1$ su S , l'estensione nulla vale

$$f^E(x_i) = \begin{cases} 1, & x_i \in S, \\ 0, & x_i \notin S. \end{cases}$$

Quindi

$$\mathcal{I}_N = \frac{1}{N} \sum_{j: x_j \in S} \frac{1}{p(x_j)}.$$

Dato che il campionamento è uniforme in Ω ,

$$p(x_j) = \frac{1}{\text{vol}(\Omega)} \quad \text{per } x_j \in \Omega.$$

Allora

$$\mathcal{I}_N = \frac{1}{N} \sum_{j: x_j \in S} \text{vol}(\Omega).$$

Se $N(S)$ è il numero di campioni contenuti in S , si ottiene

$$\mathcal{I}_N = \frac{N(S)}{N} \text{vol}(\Omega).$$

Quindi il volume di S viene stimato come frazione di punti caduti in S , moltiplicata per il volume dell'insieme noto Ω :

$$\boxed{\text{vol}(S) \simeq \frac{N(S)}{N} \text{vol}(\Omega)}$$

$N(S)$ = numero di campioni contenuti in S .

Monte Carlo per momenti di una PDF

Si vuole calcolare un momento di una PDF nella forma

$$\mu = E[g(\underline{X})] = \int g(x)p(x) dx.$$

Se si generano campioni

$$X \sim p(x), \quad N \text{ campioni } X_i$$

e poi medie campionarie.

Può essere preferibile usare una PDF diversa per il campionamento, indicata con

$$q(\cdot).$$

Riscriviamo allora l'integrale come

$$\mathcal{I} = E_{p(\cdot)}[g(X)] = \int g(x)p(x) dx.$$

Moltiplicando e dividendo per $q(x)$, si ottiene

$$\mu = \int g(x) \frac{p(x)}{q(x)} q(x) dx.$$

Definendo il peso

$$w(x) = \frac{p(x)}{q(x)},$$

segue

$$\mathcal{I} = \int g(x)w(x)q(x) dx = E_{q(\cdot)}[g(X)w(X)].$$

Condizione sul supporto

Il supporto di $q(\cdot)$ deve includere il supporto di $p(\cdot)$:

$$S_p \subseteq S_q.$$

In particolare,

$$p(x) > 0 \Rightarrow q(x) > 0,$$

oppure, equivalentemente,

$$q(x) = 0 \Rightarrow p(x) = 0.$$

Questa condizione serve per evitare divisioni per zero nel peso

$$w(x) = \frac{p(x)}{q(x)}.$$

$$\text{Per } X_i \sim q(\cdot) \quad i = 1, \dots, N$$

Quell'integrale si approssima come

$$\mathcal{I} = \mathcal{I}_N = \frac{1}{N} \sum_{i=1}^N w(x_i)g(x_i)$$

Monte Carlo per la stima MMSE

Nel caso della stima MMSE si vuole calcolare una quantità del tipo

$$\mathcal{I} = E[g(\underline{X}) \mid \underline{Y}] = \int g(x) f_{\underline{X}|\underline{Y}}(x \mid y) dx = \frac{\int g(x) f_{\underline{Y}|\underline{X}}(y \mid x) f_{\underline{X}}(x) dx}{\int f_{\underline{Y}|\underline{X}}(y \mid x) f_{\underline{X}}(x) dx}.$$

Se si usa una PDF di campionamento $q(x)$, con supporto tale da contenere il supporto di $f_{\underline{X}}(x)$, si riscrivono numeratore e denominatore come:

$$\mathcal{I} = \frac{\int g(x) f_{\underline{Y}|\underline{X}}(y \mid x) \frac{f_{\underline{X}}(x)}{q(x)} q(x) dx}{\int f_{\underline{Y}|\underline{X}}(y \mid x) \frac{f_{\underline{X}}(x)}{q(x)} q(x) dx}.$$

Definiamo:

$$w(x) = f_{\underline{Y}|\underline{X}}(y \mid x) \frac{f_{\underline{X}}(x)}{q(x)}$$

Si generano campioni

$$X_i \sim q(\cdot), \quad i = 1, \dots, N.$$

E si approssima $\mathcal{I}$ come

$$\mathcal{I} \simeq \mathcal{I}_N = \frac{\frac{1}{N} \sum_{i=1}^N w(X_i) g(X_i)}{\frac{1}{N} \sum_{i=1}^N w(X_i)}.$$

Poiché il fattore $1/N$ compare sia a numeratore sia a denominatore, si semplifica:

$$\mathcal{I}_N = \frac{\sum_{i=1}^N w(X_i) g(X_i)}{\sum_{i=1}^N w(X_i)}.$$

Definiamo quindi i pesi normalizzati

$$\bar{w}_i = \frac{w(X_i)}{\sum_{i=1}^N w(X_i)}.$$

Con questa definizione vale

$$\sum_{i=1}^N \bar{w}_i = 1.$$

Pertanto la stima può essere scritta come

$$\mathcal{I}_N = \sum_{i=1}^N \bar{w}_i g(X_i).$$

Stima MMSE tramite campioni pesati

Per la stima MMSE si prende

$$g(X_i) = X_i.$$

Quindi

$$\hat{X}^{\text{MMSE}} = E[\underline{X} \mid \underline{Y}] \simeq \sum_{i=1}^N \bar{w}_i X_i.$$

Covarianza dell'errore MMSE

Per stimare la covarianza dell'errore, si usa

$$g(X) = (X - \hat{X}^{\text{MMSE}})(X - \hat{X}^{\text{MMSE}})^T.$$

Allora

$$\hat{\Sigma}_{\text{MMSE}} \simeq \sum_{i=1}^N \bar{w}_i (X_i - \hat{X}^{\text{MMSE}})(X_i - \hat{X}^{\text{MMSE}})^T.$$

Riassunto dell'algoritmo

L'algoritmo richiede la scelta di:

- N , numero di campioni;
- $q(\cdot)$, funzione usata per il campionamento.

Poi si procede come segue.

1. Generazione dei campioni Si generano i campioni

$$X_i \sim q(\cdot), \quad i = 1, \dots, N.$$

2. Calcolo dei pesi non normalizzati Per ogni campione si calcola

$$w_i = f_{\underline{Y}|\underline{X}}(y \mid X_i) \frac{f_{\underline{X}}(X_i)}{q(X_i)}.$$

Il termine

$$f_{\underline{Y}|\underline{X}}(y \mid X_i)$$

contiene il modello di osservazione, cioè la dipendenza da $h(\cdot, \cdot)$.

3. Normalizzazione dei pesi Si normalizzano i pesi:

$$\bar{w}_i = \frac{w_i}{\sum w_i}.$$

4. Calcolo della stima La stima MMSE è

$$\hat{X}^{\text{MMSE}} \simeq \sum_{i=1}^N \bar{w}_i X_i.$$

5. Calcolo della covarianza La covarianza dell'errore è

$$\hat{\Sigma}_{\text{MMSE}} \simeq \sum_{i=1}^N \bar{w}_i (X_i - \hat{X}^{\text{MMSE}})(X_i - \hat{X}^{\text{MMSE}})^T.$$

Interpretazione del termine di verosimiglianza

Nel problema di stima MMSE si considera il modello di osservazione

$$Y = h(X, V),$$

che rappresenta il problema inverso che si sta cercando di risolvere.
La funzione $h(\cdot, \cdot)$ è “nascosta” dentro la densità condizionata

$$f_{\underline{Y}|\underline{X}}(y | X_i).$$

Questa densità è associata al modello di osservazione

$$h(X, V).$$

Caso di rumore additivo Nel caso di rumore additivo si ha

$$Y = h(\underline{X}) + V.$$

Allora

$$f_{\underline{Y}|\underline{X}}(y | x_i) = f_V(y - h(x)).$$

Se il rumore è gaussiano, cioè

$$V \sim \mathcal{N}(0, \Sigma_V),$$

ovvero

$$f_V(y - h(x)) = \frac{1}{\sqrt{(2\pi)^n \det(\Sigma_V)}} \exp \left[-\frac{1}{2} (y - h(x))^T \Sigma_V^{-1} (y - h(x)) \right].$$

La scelta più naturale per la PDF di campionamento è la densità a priori

$$f_{\underline{X}}(x).$$

In questo caso il peso non normalizzato diventa

$$w_i = f_{\underline{Y}|\underline{X}}(Y | X_i) \frac{f_{\underline{X}}(X_i)}{q(X)}.$$

Poiché

$$q(X_i) = f_{\underline{X}}(X_i),$$

si ottiene

$$w_i = f_{\underline{Y}|\underline{X}}(y | X_i).$$

Quindi, con questa scelta, il peso coincide con la verosimiglianza.

Degenerazione dei pesi


Un problema possibile è la degenerazione dei pesi, cioè la situazione in cui la verosimiglianza risulta molto “appuntita”.

Questo accade, per esempio, quando i sensori sono molto accurati, cioè quando

$$\Sigma_V$$

è piccola.

In quel caso pochi campioni ricevono peso significativo, mentre la maggior parte dei campioni ha peso praticamente nullo.



Le medie risultano quindi basate su un numero piccolo di campioni effettivamente utili.

In pratica, anche se si generano molti campioni, solo pochi contribuiscono davvero alla stima.

Possibili rimedi alla degenerazione dei pesi

Quando si verifica degenerazione dei pesi, si possono seguire due vie principali:

- scegliere una diversa densità di campionamento $q(\cdot)$;
- applicare un ricampionamento, cioè un *resampling*.

Ricampionamento

Il ricampionamento consiste nel rigenerare i campioni con probabilità data dai pesi.

Prima del ricampionamento si ha l'insieme di campioni pesati

$$\{(X_i, \bar{w}_i)\}_{i=1}^N.$$

Dopo il ricampionamento si ottiene un nuovo insieme

$$\{(X'_i, \bar{w}'_i)\}_{i=1}^N.$$

I nuovi pesi vengono posti tutti uguali:

$$w'_j = \frac{1}{N}.$$

I nuovi campioni vengono estratti dai campioni precedenti secondo la distribuzione discreta definita dai pesi:

$$X'_j = X_i \quad \text{con probabilità } \bar{w}_i.$$

In questo modo, i campioni con peso maggiore hanno maggiore probabilità di essere selezionati più volte, mentre i campioni con peso piccolo tendono a scomparire.

Problema del ricampionamento Il rischio è ottenere tanti nuovi campioni coincidenti.

Per ridurre questo problema si può perturbare casualmente i nuovi campioni.

$$X'_j = X_i + \xi_j,$$

dove

$$\xi_j \sim \mathcal{N}(0, \varepsilon I),$$

con

$$\varepsilon > 0$$

piccolo.

In questo modo si evita che il nuovo insieme di campioni sia costituito da molte copie identiche dello stesso punto.

Algoritmo di ricampionamento

Prima del ricampionamento si dispone dell'insieme di campioni pesati

$$\{(X_i, \bar{w}_i)\}_{i=1}^N.$$

Si sceglie un valore

$$\varepsilon > 0$$

che verrà usato per perturbare leggermente i campioni ricampionati.

Costruzione della distribuzione cumulativa Si definiscono le somme cumulative dei pesi:

$$S_1 = \bar{w}_1,$$

e, per

$$i = 2, \dots, N,$$

$$S_i = S_{i-1} + \bar{w}_i.$$

Poiché i pesi sono normalizzati,


$$\sum_{i=1}^N \bar{w}_i = 1,$$

si ha

$$S_N = 1.$$

Graficamente, il segmento unitario $[0, 1]$ viene suddiviso in intervalli di ampiezza pari ai pesi $\bar{w}_i$:

$$[0, 1] = [0, S_1] \cup [S_1, S_2] \cup \dots \cup [S_{N-1}, S_N].$$



Generazione dei nuovi campioni Per ogni nuovo campione

$$j = 1, \dots, N,$$

si genera un numero casuale

$$u \sim \mathcal{U}(0, 1),$$

cioè un numero random secondo distribuzione uniforme tra 0 e 1.

Inoltre si genera una perturbazione gaussiana

$$\xi \sim \mathcal{N}(0, \varepsilon I),$$

che verrà applicata al campione selezionato.

Se

$$u \in [S_{i-1}, S_i],$$

allora il nuovo campione viene scelto come

$$X'_j = X_i + \xi.$$

Il nuovo peso associato è uniforme:

$$\bar{w}'_j = \frac{1}{N}.$$

Risultato dell'algoritmo Il risultato del ricampionamento è quindi un nuovo insieme di campioni pesati

$$\{(X'_j, \bar{w}'_j)\}_{j=1}^N.$$

Tutti i nuovi pesi sono uguali, mentre i campioni con peso originario più alto hanno maggiore probabilità di essere selezionati.

Ricampionamento ripetuto

Il ricampionamento può essere effettuato più volte, suddividendo le osservazioni in sottoinsiemi.

Si suddividono quindi le osservazioni Y in K sottoinsiemi:

$$Y = [Y_1^T \quad Y_2^T \quad \dots \quad Y_K^T]^T.$$

Si generano inizialmente i campioni dalla prior:

$$X_j \sim f_{\underline{X}}(x), \quad j = 1, \dots, N.$$

Per ogni campione si calcola il peso non normalizzato tramite la verosimiglianza:

$$w_j = f_{\underline{Y}|\underline{X}}(Y, X).$$

I pesi normalizzati sono

$$\bar{w}_j = \frac{w_j}{\sum w_i}.$$

Per

$$i = 2, \dots, K,$$


si aggiorna iterativamente l'insieme dei campioni pesati:

$$\{(X_j, \bar{w}_j)\} \longrightarrow \{(X'_j, \bar{w}'_j)\}.$$

I nuovi pesi $\bar{w}'_j$ vengono aggiornati con la verosimiglianza associata al nuovo sottoinsieme di osservazioni.

Esempio: stima della posizione di un punto materiale

Si vuole stimare la posizione X di un punto materiale tramite una misura di tempo di andata e ritorno di un'onda acustica.



Si assume una distribuzione a priori gaussiana per la posizione:

$$X \sim \mathcal{N}(\bar{x}, \Sigma_X).$$

Il rumore di misura è anch'esso gaussiano:

$$V \sim \mathcal{N}(0, \Sigma_V).$$

Il modello di misura è basato sul tempo di andata e ritorno dell'onda acustica:

$$Y = \frac{2}{c}X + V.$$

Il fattore 2 compare perché si misura il tempo di andata e ritorno.

La costante c rappresenta la velocità del suono in aria:

$$c \simeq 340 \frac{\text{m}}{\text{s}}.$$

Scrivendo tutte le misure in forma vettoriale:

$$Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_N \end{bmatrix} = \begin{bmatrix} \frac{2}{c} \\ \frac{2}{c} \\ \vdots \\ \frac{2}{c} \end{bmatrix} X + \begin{bmatrix} V_1 \\ V_2 \\ \vdots \\ V_N \end{bmatrix}.$$

Quindi il modello è lineare:

$$Y = CX + V,$$

dove

$$C = \begin{bmatrix} 2 \\ - \\ c \\ 2 \\ - \\ c \\ \vdots \\ 2 \\ - \\ c \end{bmatrix}.$$

La matrice di covarianza del rumore di misura è diagonale:

$$\Sigma_V = \begin{bmatrix} \sigma_V & 0 & \cdots & 0 \\ 0 & \sigma_V & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_V \end{bmatrix}.$$

I dati indicati sono:

$$\Sigma_X = (3 \text{ m})^2,$$

$$\bar{x} = 120 \text{ m},$$

$$\sigma_V = 0.1 \text{ s}.$$

Poiché siamo nel caso bayesiano gaussiano lineare, gli stimatori coincidono:

$$\text{MMSE} = \text{BLUE} = \text{EAP} = \text{MAP}.$$

Da completare questo e aggiungere esercizio successivo.

18 Stima Dinamica

Stima statica:

$\underline{\bar{x}}$ costante nel tempo

Stima dinamica:

$\underline{\bar{x}}$ variabile nel tempo

Esempio Stima dello stato di un sistema dinamico.

Tempo discreto

$$x_{k+1} = f_k(x_k, w_k)$$

$$y_k = h_k(x_k, v_k)$$

con

$$k = 0, 1, \dots$$

$$x_k \in \mathbb{R}^n$$

$$y_k \in \mathbb{R}^p \quad (\text{misure})$$

w_k disturbo di processo

v_k rumore di misura

z_k quantità all'istante k

z^k segnale fino all'istante k

$$z^k = \{z^k, z^{k-1}, z^{k-2}, \dots\}$$

Stima dello stato:

$$x_t$$

- $t > k$

Predizione

- $t = k$

Filtraggio

- $t < k$

Regolarizzazione

Come fare?

Stimare x_k sfruttando f_k , ma tenendo conto di:

- f non ideale;
- incertezza sullo stato iniziale.

Compensare con le misure

$$y_k \quad (h_k(\cdot))$$

che però sono rumorose.

Caso LTI

Consideriamo il sistema lineare tempo-invariante

$$x_{k+1} = Ax_k + b_k + Dw_k$$

$$y_k = Cx_k + v_k$$

dove b_k rappresenta la componente deterministica dell'ingresso. In particolare,

$$b_k = Bu_k.$$

Il problema consiste nella stima in tempo reale dello stato x_k , elaborando gli ingressi noti b_k e le misure y_k , in modo da ottenere una stima

$$\hat{x}_k.$$


Osservatore

Una possibile struttura dell'osservatore è

$$\xi_{k+1} = \mathcal{A}\xi_k + \mathcal{B}b_k + \mathcal{C}y_k$$

$$\hat{x}_k = \mathcal{D}\xi_k + \mathcal{E}b_k + \mathcal{F}y_k.$$

dove ξ_k rappresenta lo stato interno dell'osservatore.



Comportamento desiderato dell'osservatore

In assenza di disturbi e rumori, si desidera che

$$\hat{x}_k \longrightarrow x_k, \quad k \rightarrow \infty,$$

indipendentemente dalle condizioni iniziali del sistema e dell'osservatore.

Vogliamo quindi costruire un **osservatore asintotico**.

Definiamo l'errore di stima dello stato come

$$\tilde{x}_k = x_k - \hat{x}_k.$$

Se

$$v_k = 0, \quad w_k = 0,$$

l'osservatore deve soddisfare

$$\boxed{\lim_{k \rightarrow \infty} \tilde{x}_k = 0 \quad \forall x_0, \xi_0}$$

ossia la stima deve convergere asintoticamente allo stato reale:

$$\hat{x}_k \longrightarrow x_k.$$

Osservatore di Luenberger

L'osservatore di Luenberger è definito da

$$\hat{x}_{k+1} = A\hat{x}_k + b_k + K(y_k - C\hat{x}_k),$$

dove

- il termine

$$A\hat{x}_k + b_k$$

rappresenta una *copia del sistema*;

- il termine

$$K(y_k - C\hat{x}_k)$$

rappresenta la *correzione* basata sull'errore di stima dell'uscita.

Sviluppando l'espressione,

$$\hat{x}_{k+1} = (A - KC)\hat{x}_k + b_k + Ky_k.$$

L'uscita dell'osservatore coincide con la stima dello stato,

$$\hat{x}_k = \hat{x}_k.$$

Confrontando questa forma con l'osservatore generale,

$$\xi_{k+1} = \mathcal{A}\xi_k + \mathcal{B}b_k + \mathcal{C}y_k,$$

$$\hat{x}_k = \mathcal{D}\xi_k + \mathcal{E}b_k + \mathcal{F}y_k,$$

si ottengono

$$\begin{aligned} \mathcal{A} &= A - KC, \\ \mathcal{B} &= I, \\ \mathcal{C} &= K, \\ \mathcal{D} &= I, \\ \mathcal{E} &= 0, \\ \mathcal{F} &= 0. \end{aligned}$$

Dinamica dell'errore di stima

Definiamo l'errore di stima

$$\tilde{x}_k = x_k - \hat{x}_k.$$

Allora

$$\begin{aligned} \tilde{x}_{k+1} &= x_{k+1} - \hat{x}_{k+1} \\ &= (Ax_k + b_k + Dw_k) - (A\hat{x}_k + b_k + K(y_k - C\hat{x}_k)). \end{aligned}$$

Poiché

$$y_k = Cx_k + v_k,$$

segue che

$$\begin{aligned} \tilde{x}_{k+1} &= A(x_k - \hat{x}_k) + Dw_k - K(Cx_k + v_k - C\hat{x}_k) \\ &= (A - KC)\tilde{x}_k + Dw_k - Kv_k. \end{aligned}$$

Pertanto

$$\tilde{x}_{k+1} = (A - KC)\tilde{x}_k + Dw_k - Kv_k.$$

Nel caso ideale, cioè

$$v_k = 0, \quad w_k = 0,$$

(si tratta proprio della definizione di osservatore asintotico),

$$\tilde{x}_{k+1} = (A - KC)\tilde{x}_k.$$

L'osservatore di Luenberger è asintotico se e solo se

$$A - KC$$

ha tutti gli autovalori all'interno del cerchio unitario.

Infatti,

$$\text{L'osservatore è asintotico} \iff \rho(A - KC) < 1,$$

dove $\rho(\cdot)$ indica il raggio spettrale.

Infine, tutti gli autovalori di $A - KC$ possono essere assegnati arbitrariamente se e solo se la coppia

$$(A, C)$$

è completamente osservabile.

In particolare,

$$\text{Esiste un osservatore asintotico} \iff (A, C) \text{ è rilevabile.}$$

Presenza di rumore di processo e di misura

In presenza di rumore di processo w_k e di rumore di misura v_k , la dinamica dell'errore di stima diventa

$$\tilde{x}_{k+1} = (A - KC)\tilde{x}_k + Dw_k - Kv_k.$$

Sviluppando ricorsivamente,

$$\tilde{x}_1 = (A - KC)\tilde{x}_0 + Dw_0 - Kv_0,$$

$$\tilde{x}_2 = (A - KC)^2\tilde{x}_0 + (A - KC)Dw_0 - (A - KC)Kv_0 + Dw_1 - Kv_1,$$

e, in generale,

$$\tilde{x}_k = (A - KC)^k\tilde{x}_0 + \sum_{i=0}^{k-1} (A - KC)^{k-1-i} Dw_i - \sum_{j=0}^{k-1} (A - KC)^{k-1-j} Kv_j.$$

Supponiamo che

1. l'osservatore sia asintotico;
2. w_k e v_k siano processi stazionari a media nulla.

Ci si chiede quale sia il comportamento di $\tilde{x}_k$ a regime.
In queste ipotesi,

$$\tilde{x}_k \text{ è un processo stazionario (P.S.S.) a media nulla a regime.}$$

Rimane quindi da scegliere opportunamente il guadagno K .
L'idea è scegliere il guadagno che minimizza la varianza dell'errore di stima, cioè

$$\min_K \mathbb{E}[\tilde{x}_k \tilde{x}_k^T].$$

Questa scelta porta al **filtro di Kalman**, che fornisce il guadagno ottimo nel senso della minima covarianza dell'errore di stima.

19 Recap Stima Dinamica

Stima dinamica

Obiettivo: stimare lo stato x_t sulla base delle informazioni disponibili fino all'istante k ,

$$z^k = \{z_k, z_{k-1}, \dots\}.$$

A seconda dell'istante da stimare si distinguono:

- $t > k$: **predizione**;
- $t = k$: **filtraggio**;
- $t < k$: **regolarizzazione (smoothing)**.

Il sistema dinamico generale è descritto da

$$x_{k+1} = f_k(x_k, w_k),$$

$$y_k = h_k(x_k, v_k).$$

Caso LTI

Nel caso lineare tempo-invariante,

$$x_{k+1} = Ax_k + b_k + Dw_k,$$

$$y_k = Cx_k + v_k.$$

L'osservatore di Luenberger è

$$\hat{x}_{k+1} = A\hat{x}_k + b_k + K(y_k - C\hat{x}_k).$$

L'errore di stima evolve secondo

$$\tilde{x}_k = (A - KC)^k \tilde{x}_0 + \sum_{i=0}^{k-1} (A - KC)^{k-1-i} Dw_i - \sum_{j=0}^{k-1} (A - KC)^{k-1-j} K v_j.$$

Se

- l'osservatore è asintotico;

- w_k e v_k sono processi stazionari a media nulla,

allora

$$\tilde{x}_k$$

è un processo stazionario a media nulla a regime.

Il guadagno viene quindi scelto in modo da minimizzare

$$\mathbb{E}[\tilde{x}_k \tilde{x}_k^T].$$

Caso LTV

Per un sistema lineare tempo-variante,

$$x_{k+1} = A_k x_k + b_k + D_k w_k,$$

$$y_k = C_k x_k + v_k.$$

L'osservatore di Luenberger tempo-variante diventa

$$\hat{x}_{k+1} = A_k \hat{x}_k + b_k + K_k (y_k - C_k \hat{x}_k),$$

ovvero,

$$\hat{x}_{k+1} = (A_k - K_k C_k) \hat{x}_k + b_k + K_k y_k.$$

Dinamica dell'errore di stima

Nel caso tempo-variante, la dinamica dell'errore di stima è

$$\tilde{x}_{k+1} = (A_k - K_k C_k) \tilde{x}_k + D_k w_k - K_k v_k.$$

Ipotesi statistiche

Assumiamo che il rumore di processo sia un rumore bianco, a media nulla e covarianza

$$Q_k = Q_k^T > 0,$$

cioè

$$w_k \sim \mathcal{WN}(0, Q_k).$$

Analogamente, il rumore di misura è

$$v_k \sim \mathcal{WN}(0, R_k).$$

Lo stato iniziale è una variabile aleatoria con

$$\mathbb{E}[x_0] = \hat{x}_0,$$

e matrice di covarianza

$$P_0 = P_0^T > 0.$$

Inoltre si assume

$$\mathbb{E}[w_i v_j^T] = 0, \quad \forall i, j,$$

ossia rumore di processo e rumore di misura sono incorrelati.

Si assume inoltre che lo stato iniziale sia incorrelato con entrambi i processi di rumore.

Problema dell'osservatore ottimo

Per ogni

$$k = 0, 1, \dots$$

determinare il guadagno

$$K_k$$

in modo da minimizzare l'errore quadratico medio di stima.

Definiamo

$$P_{k+1} = \mathbb{E}[\tilde{x}_{k+1} \tilde{x}_{k+1}^T].$$

Poiché

$$\tilde{x}_{k+1} = (A_k - K_k C_k) \tilde{x}_k + D_k w_k - K_k v_k,$$

segue

$$P_{k+1} = \mathbb{E} \left[((A_k - K_k C_k) \tilde{x}_k + D_k w_k - K_k v_k) \cdot ((A_k - K_k C_k) \tilde{x}_k + D_k w_k - K_k v_k)^T \right].$$

Espansione dell'errore

Introduciamo la matrice di transizione

$$\Phi_k = A_k - K_k C_k.$$

La soluzione ricorsiva dell'errore è

$$\tilde{x}_k = \Phi_{k,0} \tilde{x}_0 + \sum_{i=0}^{k-1} \Phi_{k,i+1} D_i w_i - \sum_{j=0}^{k-1} \Phi_{k,j+1} K_j v_j.$$

dove

$$\Phi_{k,i} = \begin{cases} \Phi_{k-1} \Phi_{k-2} \cdots \Phi_i, & k > i, \\ I, & k = i. \end{cases}$$

Proprietà di incorrelazione

Le seguenti proprietà verranno utilizzate nello sviluppo di P_{k+1} .

$$\tilde{x}_k \quad \text{e} \quad w_k$$

sono incorrelati perché

- w_k è incorrelato con $\tilde{x}_0$;
- w_k è incorrelato con v_j ;
- w_k è incorrelato con w_i , $i = 0, \dots, k-1$.

Analogamente,

$$\tilde{x}_k \quad \text{e} \quad v_k$$

sono incorrelati.

Infine,

$$w_k \quad \text{e} \quad v_k$$

sono incorrelati per ipotesi.

Derivazione del guadagno ottimo di Kalman

Dalla definizione della matrice di covarianza dell'errore,

$$P_{k+1} = \mathbb{E}[\tilde{x}_{k+1}\tilde{x}_{k+1}^T],$$

e sfruttando le ipotesi di incorrelazione tra errore, rumore di processo e rumore di misura, si ottiene

$$P_{k+1} = (A_k - K_k C_k) P_k (A_k - K_k C_k)^T + D_k Q_k D_k^T + K_k R_k K_k^T.$$

Il problema consiste quindi nel determinare

$$K_k = \arg \min_K P_{k+1}.$$

Espandendo il primo termine,

$$\begin{aligned} P_{k+1} &= (A_k - K C_k) P_k (A_k - K C_k)^T + D_k Q_k D_k^T + K R_k K^T \\ &= K (R_k + C_k P_k C_k^T) K^T - K C_k P_k A_k^T - A_k P_k C_k^T K^T + D_k Q_k D_k^T + A_k P_k A_k^T. \end{aligned}$$

Introduciamo le matrici

$$S_k = R_k + C_k P_k C_k^T,$$

$$V_k = A_k P_k C_k^T.$$

L'espressione precedente diventa

$$P_{k+1} = K S_k K^T - K V_k^T - V_k K^T + D_k Q_k D_k^T + A_k P_k A_k^T.$$

A questo punto si completa il quadrato matriciale,

$$\begin{aligned}
P_{k+1} = & (K - V_k S_k^{-1}) S_k (K - V_k S_k^{-1})^T \\
& - V_k S_k^{-1} V_k^T \\
& + D_k Q_k D_k^T + A_k P_k A_k^T.
\end{aligned}$$

Poiché il primo termine è sempre semidefinito positivo, esso è minimo quando

$$K_k = V_k S_k^{-1}.$$

Sostituendo le definizioni di V_k e S_k ,

$$K_k = A_k P_k C_k^T (R_k + C_k P_k C_k^T)^{-1}.$$

L'osservatore ottimo diventa quindi

$$\hat{x}_{k+1} = A_k \hat{x}_k + b_k + K_k (y_k - C_k \hat{x}_k).$$

Infine, sostituendo il guadagno ottimo nell'equazione della covarianza si ottiene

$$\begin{aligned}
P_{k+1} = & A_k P_k A_k^T + D_k Q_k D_k^T \\
& - A_k P_k C_k^T (R_k + C_k P_k C_k^T)^{-1} C_k P_k A_k^T.
\end{aligned}$$

Le tre equazioni

1. aggiornamento del guadagno K_k ;
2. aggiornamento della stima $\hat{x}_k$;
3. aggiornamento della covarianza P_k ;

costituiscono il **Filtro di Kalman** (Kalman, 1960).

Forma ricorsiva del filtro di Kalman

Osservazioni:

- è il miglior stimatore lineare per sistemi lineari;
- nel caso gaussiano è ottimo anche tra tutti gli stimatori non lineari (MMSE).

L'ipotesi di gaussianità riguarda

- il disturbo di processo;
- il rumore di misura;
- lo stato iniziale.

Si osserva inoltre che

- K_k e P_{k+1} non dipendono dalle osservazioni e possono quindi essere calcolati offline;
- $\hat{x}_k$ e P_k sono invece basati sulle osservazioni disponibili fino all'istante $k - 1$, cioè rappresentano una *predizione*.

Per evitare ambiguità di notazione è preferibile scrivere

$$\hat{x}_k \equiv \hat{x}_{k|k-1},$$

ossia la stima dello stato all'istante k basata sulle misure fino all'istante $k-1$. Analogamente,

$$P_k \equiv P_{k|k-1}.$$

Aggiornamento mediante la nuova misura

In pratica interessa ottenere una stima *filtrata*, cioè utilizzando anche la misura disponibile all'istante corrente.

Infatti

$$Y^k = Y^{k-1} \cup \{y_k\}.$$

La stima filtrata viene ottenuta combinando

$$(\hat{x}_{k|k-1}, P_{k|k-1})$$

con la nuova osservazione

$$y_k,$$

ottenendo

$$\boxed{\hat{x}_{k|k}, P_{k|k}}.$$

Questo aggiornamento può essere visto come un problema di stima statica, la cui soluzione è lo stimatore BLUE.

Equazioni di aggiornamento

Lo stato viene corretto mediante

$$\boxed{\hat{x}_{k|k} = \hat{x}_{k|k-1} + \Sigma_{xy} \Sigma_y^{-1} (y_k - \hat{y}_{k|k-1}).}$$

Poiché

$$\hat{y}_{k|k-1} = C_k \hat{x}_{k|k-1},$$

e

$$\Sigma_{xy} = P_{k|k-1} C_k^T,$$

$$\Sigma_y = C_k P_{k|k-1} C_k^T + R_k,$$

l'equazione precedente diventa

$$\boxed{\hat{x}_{k|k} = \hat{x}_{k|k-1} + P_{k|k-1} C_k^T (C_k P_{k|k-1} C_k^T + R_k)^{-1} (y_k - C_k \hat{x}_{k|k-1}).}$$

Infine, la matrice di covarianza aggiornata è

$$\boxed{P_{k|k} = P_{k|k-1} - \Sigma_{xy} \Sigma_y^{-1} \Sigma_{xy}^T.}$$

Esplicitando le matrici,

$$P_{k|k} = P_{k|k-1} - P_{k|k-1} C_k^T (C_k P_{k|k-1} C_k^T + R_k)^{-1} C_k P_{k|k-1}.$$

Forma predizione–correzione del filtro di Kalman

L'aggiornamento della stima filtrata può essere scritto nella forma

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + L_k (y_k - C_k \hat{x}_{k|k-1}),$$

dove


$$L_k = P_{k|k-1} C_k^T (C_k P_{k|k-1} C_k^T + R_k)^{-1}$$

è il **guadagno di correzione** (Kalman Gain).

La covarianza della stima filtrata diventa

$$P_{k|k} = P_{k|k-1} - P_{k|k-1} C_k^T (C_k P_{k|k-1} C_k^T + R_k)^{-1} C_k P_{k|k-1}.$$

La logica del filtro è quindi la seguente:



La stima predetta

$$\hat{x}_{k|k-1}$$

viene corretta sfruttando la nuova osservazione disponibile all'istante k , ottenendo

$$\hat{x}_{k|k}.$$

Successivamente la stima filtrata viene propagata nel modello dinamico per ottenere la previsione all'istante successivo.

Equazione di predizione

Introduciamo il guadagno

$$K_k = A_k L_k.$$

L'osservatore di Luenberger può essere scritto come

$$\hat{x}_{k+1|k} = A_k \hat{x}_{k|k-1} + b_k + K_k (y_k - C_k \hat{x}_{k|k-1}).$$

Poiché

$$K_k = A_k L_k,$$

si ottiene

$$\begin{aligned}\hat{x}_{k+1|k} &= A_k \hat{x}_{k|k-1} + A_k L_k (y_k - C_k \hat{x}_{k|k-1}) + b_k \\ &= A_k [\hat{x}_{k|k-1} + L_k (y_k - C_k \hat{x}_{k|k-1})] + b_k.\end{aligned}$$

Riconoscendo il termine tra parentesi come la stima filtrata,

$$\boxed{\hat{x}_{k|k} = \hat{x}_{k|k-1} + L_k (y_k - C_k \hat{x}_{k|k-1}),}$$

segue immediatamente l'equazione di predizione

$$\boxed{\hat{x}_{k+1|k} = A_k \hat{x}_{k|k} + b_k.}$$

Quest'ultima rappresenta il passo di **predizione** del filtro di Kalman: una volta corretta la stima con la misura all'istante k , essa viene propagata al tempo $k + 1$ attraverso il modello dinamico.

20 Filtro di Kalman – Ricapitolazione

Consideriamo il sistema dinamico lineare tempo-variante

$$x_{k+1} = A_k x_k + b_k + D_k w_k,$$

$$y_k = C_k x_k + v_k.$$

Assumiamo

$$x_0 \sim \mathcal{N}(\hat{x}_0, P_0),$$

$$w_k \sim \mathcal{N}(0, Q_k),$$

$$v_k \sim \mathcal{N}(0, R_k),$$

con

- w_k e v_k rumori bianchi (WN); - stato iniziale, rumore di processo e rumore di misura mutuamente incorrelati.

Partendo dalla predizione

$$\hat{x}_{k|k-1}, \quad P_{k|k-1},$$

le tre equazioni del filtro di Kalman sono

$$\boxed{\hat{x}_{k+1|k} = A_k \hat{x}_{k|k-1} + b_k + K_k (y_k - C_k \hat{x}_{k|k-1})}$$

$$\boxed{K_k = A_k P_{k|k-1} C_k^T (R_k + C_k P_{k|k-1} C_k^T)^{-1}}$$

$$\boxed{\begin{aligned}P_{k+1|k} &= A_k P_{k|k-1} A_k^T \\ &\quad - A_k P_{k|k-1} C_k^T (R_k + C_k P_{k|k-1} C_k^T)^{-1} C_k P_{k|k-1} A_k^T \\ &\quad + D_k Q_k D_k^T.\end{aligned}}$$

Le tre equazioni precedenti costituiscono il ****filtro di Kalman**** e producono la nuova predizione

$$\hat{x}_{k+1|k}, \quad P_{k+1|k}.$$

Passo di correzione (stima statica)

La misura disponibile all'istante k ,

$$y_k,$$

viene utilizzata per correggere la predizione

$$\hat{x}_{k|k-1}$$

ottenendo la stima filtrata

$$\hat{x}_{k|k}.$$

Questo equivale ad un problema di ****stima statica****, risolto mediante lo stimatore BLUE. Il guadagno di correzione è

$$L_k = P_{k|k-1} C_k^T (R_k + C_k P_{k|k-1} C_k^T)^{-1}.$$

La correzione dello stato è

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + L_k (y_k - C_k \hat{x}_{k|k-1}).$$

La covarianza filtrata diventa

$$P_{k|k} = P_{k|k-1} - P_{k|k-1} C_k^T (R_k + C_k P_{k|k-1} C_k^T)^{-1} C_k P_{k|k-1}.$$

Passo di predizione

Definendo

$$K_k = A_k L_k,$$

la predizione successiva è

$$\hat{x}_{k+1|k} = A_k \hat{x}_{k|k} + b_k,$$

mentre la covarianza evolve secondo il modello dinamico

$$P_{k+1|k} = A_k P_{k|k} A_k^T + D_k Q_k D_k^T.$$

Infine, il modello dinamico reale è

$$x_{k+1} = A_k x_k + b_k + D_k w_k,$$

$$y_k = C_k x_k + v_k.$$

Interpretazione ricorsiva del filtro di Kalman

Il filtro di Kalman alterna due fasi:

$$\boxed{(\hat{x}_{k|k-1}, P_{k|k-1}) \xrightarrow[\text{osservazione}]{\text{BLUE}} (\hat{x}_{k|k}, P_{k|k}) \xrightarrow[\text{modello dinamico}]{\text{predizione}} (\hat{x}_{k+1|k}, P_{k+1|k})}$$

ovvero

$$\text{Predizione} \longrightarrow \text{Correzione} \longrightarrow \text{Predizione} \longrightarrow \dots$$

In particolare,

$$\hat{x}_{k|k-1} \xrightarrow{y_k} \hat{x}_{k|k} \xrightarrow{\text{predizione}} \hat{x}_{k+1|k} \xrightarrow{y_{k+1}} \hat{x}_{k+1|k+1} \longrightarrow \dots$$

Filtro di Kalman in forma ricorsiva

Sono noti

$$A_k, \quad D_k, \quad C_k, \quad Q_k, \quad R_k.$$

Inoltre sono assegnate la stima iniziale

$$\hat{x}_{1|0}, \quad P_{1|0}.$$

Per

$$k = 1, 2, \dots$$

si eseguono i seguenti passi.

1. Correzione ($k|k-1 \rightarrow k|k$)

L'innovazione è definita come

$$\boxed{e_k = y_k - C_k \hat{x}_{k|k-1}.$$

Infatti

$$y_k = C_k x_k + v_k,$$

mentre la misura prevista è

$$\hat{y}_{k|k-1} = C_k \hat{x}_{k|k-1},$$

per cui

$$e_k = y_k - \hat{y}_{k|k-1}.$$

La covarianza dell'innovazione è

$$\boxed{S_k = R_k + C_k P_{k|k-1} C_k^T.}$$

Il guadagno di correzione è

$$\boxed{L_k = P_{k|k-1} C_k^T S_k^{-1}.}$$

Covarianza dell'innovazione

Per definizione,

$$e_k = y_k - \hat{y}_{k|k-1}.$$

Poiché

$$y_k = C_k x_k + v_k,$$

e

$$\hat{y}_{k|k-1} = C_k \hat{x}_{k|k-1},$$

segue che

$$e_k = C_k \tilde{x}_{k|k-1} + v_k.$$

La covarianza dell'innovazione vale quindi

$$\begin{aligned}\mathbb{E}[e_k e_k^T] &= C_k \mathbb{E}[\tilde{x}_{k|k-1} \tilde{x}_{k|k-1}^T] C_k^T + \mathbb{E}[v_k v_k^T] \\ &= C_k P_{k|k-1} C_k^T + R_k.\end{aligned}$$

Pertanto

$$S_k = C_k P_{k|k-1} C_k^T + R_k.$$

Correzione ($k|k-1 \rightarrow k|k$)

La stima filtrata è

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + L_k e_k.$$

La covarianza associata è

$$P_{k|k} = P_{k|k-1} - L_k S_k L_k^T.$$

Predizione ($k|k \rightarrow k+1|k$)

Una volta corretta la stima, la si propaga mediante il modello dinamico:

$$\hat{x}_{k+1|k} = A_k \hat{x}_{k|k} + b_k.$$

La covarianza evolve come

$$P_{k+1|k} = A_k P_{k|k} A_k^T + D_k Q_k D_k^T.$$

Osservazioni

- La correzione è sempre associata ad una riduzione dell'incertezza (riduzione della matrice di covarianza).
- La forma

$$P_{k|k} = P_{k|k-1} - L_k S_k L_k^T$$

può perdere la definita positività per effetto degli errori numerici (differenza tra matrici definite positive).

Per questo motivo viene spesso utilizzata la **forma di Joseph**

$$P_{k|k} = (I - L_k C_k) P_{k|k-1} (I - L_k C_k)^T + L_k R_k L_k^T.$$

Essa è matematicamente equivalente alla formula precedente, ma è numericamente più robusta e preserva meglio la simmetria e la definita positività della matrice di covarianza.

Errore di stima dopo la correzione

L'errore filtrato è

$$\tilde{x}_{k|k} = x_k - \hat{x}_{k|k}.$$

Sostituendo l'equazione di aggiornamento,

$$\begin{aligned}\tilde{x}_{k|k} &= x_k - \hat{x}_{k|k-1} - L_k (y_k - C_k \hat{x}_{k|k-1}) \\ &= \tilde{x}_{k|k-1} - L_k (C_k x_k + v_k - C_k \hat{x}_{k|k-1}) \\ &= \tilde{x}_{k|k-1} - L_k (C_k \tilde{x}_{k|k-1} + v_k).\end{aligned}$$

Pertanto

$$\tilde{x}_{k|k} = (I - L_k C_k) \tilde{x}_{k|k-1} - L_k v_k.$$

Forma di Joseph

La matrice di covarianza della stima filtrata può essere scritta come

$$P_{k|k} = \mathbb{E}[\tilde{x}_{k|k} \tilde{x}_{k|k}^T] = (I - L_k C_k) P_{k|k-1} (I - L_k C_k)^T + L_k R_k L_k^T.$$

Questa espressione è nota come **forma di Joseph**.

Osservazioni

- Il filtro di Kalman nella forma *correzione-predizione* è anche un filtro *predittore*.
- Le matrici di covarianza

$$P_{k|k-1} \quad \text{e} \quad P_{k|k}$$

sono utilizzate per il calcolo dei guadagni e, poiché rappresentano la covarianza della stima, consentono anche di costruire gli intervalli di confidenza.

- Il filtro di Kalman è applicabile a qualunque sistema lineare.
 - Nel caso gaussiano è lo stimatore ottimo.
 - Nel caso non gaussiano è ottimo all'interno della classe degli stimatori lineari.

Sistemi non lineari

Per sistemi non lineari si utilizzano estensioni del filtro di Kalman.

Le principali sono:

- **Extended Kalman Filter (EKF)**: basato sulla linearizzazione locale del modello;
- **Unscented Kalman Filter (UKF)**: basato sulla trasformazione Unscented (UT);
- **Particle Filter**: basato su tecniche Monte Carlo.

Rappresentazione come osservatore LTV

La dinamica della predizione può essere riscritta nella forma

$$\begin{aligned}\hat{x}_{k+1|k} &= A_k \hat{x}_{k|k} + b_k \\ &= A_k [\hat{x}_{k|k-1} + L_k (y_k - C_k \hat{x}_{k|k-1})] + b_k \\ &= (A_k - K_k C_k) \hat{x}_{k|k-1} + b_k + K_k y_k,\end{aligned}$$

dove

$$K_k = A_k L_k.$$

La stima filtrata, che costituisce l'uscita dell'osservatore, è invece

$$\begin{aligned}\hat{x}_{k|k} &= \hat{x}_{k|k-1} + L_k (y_k - C_k \hat{x}_{k|k-1}) \\ &= (I - L_k C_k) \hat{x}_{k|k-1} + L_k y_k.\end{aligned}$$

Confrontando questa espressione con l'osservatore LTV generale,

$$\xi_{k+1} = \mathcal{A}_k \xi_k + \mathcal{B}_k b_k + \mathcal{C}_k y_k,$$

$$\hat{x}_k = \mathcal{D}_k \xi_k + \mathcal{E}_k b_k + \mathcal{F}_k y_k,$$

si ottengono i parametri

$$\begin{aligned}\mathcal{A}_k &= A_k - K_k C_k, \\ \mathcal{B}_k &= I, \\ \mathcal{C}_k &= K_k, \\ \mathcal{D}_k &= I - L_k C_k, \\ \mathcal{E}_k &= 0, \\ \mathcal{F}_k &= L_k.\end{aligned}$$

In particolare, lo stato interno dell'osservatore coincide con la predizione

$$\xi_k = \hat{x}_{k|k-1},$$

mentre l'uscita dell'osservatore è la stima filtrata

$$\hat{x}_{k|k}.$$

Innovazione

L'innovazione è definita come

$$e_k = y_k - C_k \hat{x}_{k|k-1}.$$

Se il modello descrive correttamente il sistema, allora il processo di innovazione è un rumore bianco gaussiano

$$e_k \sim \mathcal{WN}(0, S_k),$$

dove S_k è la covarianza dell'innovazione.

L'innovazione ha diversi impieghi.

1. **Progettazione del filtro** (validazione del modello).
2. **Diagnosi di malfunzionamenti e guasti**, mediante test di bianchezza.
3. **Rilevamento di outlier**, cioè misure spurie o incoerenti con il modello.

Nel problema di rilevamento degli outlier si verifica se l'innovazione è coerente con la distribuzione

$$\mathcal{N}(0, S_k),$$

mediante un opportuno test a soglia.

La distanza euclidea non è sufficiente, poiché non tiene conto della covarianza del rumore.

Ad esempio, due innovazioni possono soddisfare

$$D_M(e_k^{(1)}) < D_M(e_k^{(2)}),$$

pur avendo una distanza euclidea opposta.

Distanza di Mahalanobis

La distanza di Mahalanobis dell'innovazione è definita come

$$D_M(e_k) = \sqrt{(e_k - \mu_{e_k})^T S_k^{-1} (e_k - \mu_{e_k})}.$$

Poiché

$$\mu_{e_k} = 0,$$

si ottiene

$$D_M(e_k) = \sqrt{e_k^T S_k^{-1} e_k}.$$

Un'innovazione viene generalmente considerata anomala quando la sua distanza di Mahalanobis supera una soglia prefissata.

In pratica, si confronta la distanza dalla media espressa in termini della covarianza dell'innovazione, piuttosto che la semplice distanza euclidea.

Caso particolare: sistema LTI

Consideriamo il sistema lineare tempo-invariante

$$x_{k+1} = Ax_k + bu_k + Dw_k,$$

$$y_k = Cx_k + v_k,$$

con

$$w_k \sim \mathcal{N}(0, Q),$$

$$v_k \sim \mathcal{N}(0, R).$$

Le equazioni del filtro di Kalman diventano

$$K_k = AP_{k|k-1}C^T (R + CP_{k|k-1}C^T)^{-1},$$

$$\hat{x}_{k+1|k} = A\hat{x}_{k|k-1} + bu_k + K_k (y_k - C\hat{x}_{k|k-1}),$$

$$\begin{aligned} P_{k+1|k} = & AP_{k|k-1}A^T \\ & - AP_{k|k-1}C^T (R + CP_{k|k-1}C^T)^{-1} CP_{k|k-1}A^T \\ & + DQD^T. \end{aligned}$$

Le prime due equazioni costituiscono la ricorsione del filtro di Kalman, mentre la terza è la ricorsione della matrice di covarianza (equazione di Riccati).

Osservazione Anche se il sistema è LTI, il filtro rimane in generale **LTV**, poiché il guadagno

$$K_k$$

dipende dalla soluzione ricorsiva dell'equazione di Riccati.

Filtro di Kalman stazionario

Ci si chiede sotto quali condizioni esistano i limiti

$$\lim_{k \rightarrow \infty} P_{k|k-1} = P, \quad P = P^T > 0,$$

e, di conseguenza,

$$\lim_{k \rightarrow \infty} K_k = K.$$

In tal caso il filtro diventa tempo-invariante.

La matrice limite P deve soddisfare la **Discrete Algebraic Riccati Equation (DARE)**

$$\begin{aligned} P = & APA^T - APC^T (R + CPC^T)^{-1} CPA^T \\ & + DQD^T. \end{aligned}$$

Spesso si introduce una matrice B tale che

$$BB^T = DQD^T,$$

così da poter riscrivere il rumore di processo come

$$Dw_k = B\bar{w}_k,$$

dove

$$\bar{w}_k \sim \mathcal{WN}(0, I).$$

In questo modo

$$DQD^T = BB^T.$$

Condizioni di esistenza

L'equazione algebrica di Riccati ammette una soluzione stabilizzante se

$$(A, C) \text{ è rilevabile,}$$

e

$$(A, B) \text{ è stabilizzabile,}$$

ossia:

- tutti i modi non osservabili sono stabili (rilevabilità); - tutti i modi instabili sono controllabili (stabilizzabilità).

In tali condizioni il filtro di Kalman converge ad un guadagno costante

$$K_k \longrightarrow K,$$

ottenendo il cosiddetto **filtro di Kalman stazionario**.

Convergenza del filtro di Kalman stazionario

Sotto le ipotesi viste in precedenza vale che

- esiste una soluzione della DARE

$$P = P^T > 0;$$

- per qualunque condizione iniziale la DRE converge alla DARE.

In particolare,

$$\lim_{k \rightarrow \infty} P_{k+1|k} = P = AMA^T + DQD^T,$$

dove

$$M = P - PC^T(R + CPC^T)^{-1}CP.$$

Infatti,

$$\lim_{k \rightarrow \infty} P_{k|k} = M.$$

Il guadagno di correzione converge a

$$\lim_{k \rightarrow \infty} L_k = L = PC^T(R + CPC^T)^{-1}.$$

Di conseguenza,

$$\lim_{k \rightarrow \infty} K_k = K = AL.$$

Filtro di Kalman stazionario

A regime il filtro assume la forma

$$\hat{x}_{k+1|k} = A\hat{x}_{k|k-1} + bu_k + K(y_k - C\hat{x}_{k|k-1}),$$

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + L(y_k - C\hat{x}_{k|k-1}).$$

Il filtro stazionario costituisce un osservatore asintotico.

Infatti,

$$A - KC$$

ha tutti gli autovalori all'interno del cerchio unitario.

Pertanto l'errore di stima converge asintoticamente a zero in assenza di rumori.

Osservazione La convergenza ai valori stazionari

$$P, \quad M, \quad L, \quad K$$

è indipendente dalla scelta della stima iniziale

$$(\hat{x}_0, P_0),$$

purché siano soddisfatte le ipotesi di esistenza della soluzione stabilizzante della DARE.

21 Filtraggio non lineare

Consideriamo il sistema dinamico non lineare

$$x_{k+1} = f_k(x_k, w_k),$$

$$y_k = h_k(x_k, v_k).$$

Si assumono valide le stesse ipotesi viste nel caso lineare riguardo:

- rumore di processo;
- rumore di misura;
- condizioni iniziali.

Gli approcci al filtraggio non lineare derivano dai metodi di stima statica per modelli non lineari.

I principali sono:

- **Linearizzazione** → **Extended Kalman Filter (EKF)**;
- **Trasformata Unscented** → **Unscented Kalman Filter (UKF)**;
- **Metodi Monte Carlo** → **Particle Filter**.

Extended Kalman Filter

L'Extended Kalman Filter si basa su una approssimazione al primo ordine (linearizzazione locale) delle funzioni

$$f_k(\cdot), \quad h_k(\cdot).$$

Predizione

Si propaga la stima filtrata mediante il modello non lineare

$$(k|k) \longrightarrow (k+1|k)$$

calcolando

$$\hat{x}_{k+1|k} = f_k(\hat{x}_{k|k}, 0).$$

La covarianza viene propagata come

$$P_{k+1|k} = F_k P_{k|k} F_k^T + D_k Q_k D_k^T.$$

Le matrici della linearizzazione sono i Jacobiani del modello dinamico valutati nel punto di lavoro

$$F_k = \left. \frac{\partial f_k(x, w)}{\partial x} \right|_{\substack{x=\hat{x}_{k|k} \\ w=0}}$$

e

$$D_k = \left. \frac{\partial f_k(x, w)}{\partial w} \right|_{\substack{x=\hat{x}_{k|k} \\ w=0}}.$$

Correzione

La fase di correzione aggiorna la stima

$$(k|k-1) \longrightarrow (k|k),$$

utilizzando il modello di misura non lineare

$$h_k(\cdot).$$

Si introducono i Jacobiani della funzione di misura

$$H_k = \left. \frac{\partial h_k(x, v)}{\partial x} \right|_{\substack{x=\hat{x}_{k|k-1} \\ v=0}}$$

e

$$M_k = \left. \frac{\partial h_k(x, v)}{\partial v} \right|_{\substack{x=\hat{x}_{k|k-1} \\ v=0}}.$$

La linearizzazione locale della misura è

$$y_k = C_k x_k + v_k.$$

(non so perché lo scriva così y ma vabbè)

L'innovazione è

$$e_k = y_k - h_k(\hat{x}_{k|k-1}, 0).$$

La covarianza dell'innovazione vale

$$S_k = H_k P_{k|k-1} H_k^T + M_k R_k M_k^T.$$

Il guadagno di Kalman è

$$L_k = P_{k|k-1} H_k^T S_k^{-1}.$$

La stima corretta è

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + L_k e_k.$$

Infine, la covarianza aggiornata è

$$P_{k|k} = P_{k|k-1} - L_k S_k L_k^T.$$

Unscented Kalman Filter (UKF)

L'Unscented Kalman Filter è basato sulla **Trasformata Unscented (Unscented Transform, UT)**.

La fase di correzione viene ricondotta ad un problema di stima statica BLUE.

Correzione

Applicando la Trasformata Unscented al vettore aleatorio

$$\begin{bmatrix} \hat{x}_{k|k-1} \\ 0 \end{bmatrix},$$

con matrice di covarianza

$$\begin{bmatrix} P_{k|k-1} & 0 \\ 0 & R_k \end{bmatrix},$$

attraverso il modello di misura

$$h_k(\cdot),$$

si ottengono

$$\hat{y}_{k|k-1},$$

$$\Sigma_y,$$

$$\Sigma_{xy},$$

dove:

- Σ_y è la covarianza della misura prevista;
- Σ_{xy} è il momento incrociato (covarianza incrociata) tra stato e misura.

Il guadagno di Kalman è quindi

$$L_k = \Sigma_{xy} \Sigma_y^{-1}.$$

La stima filtrata viene aggiornata come

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + L_k (y_k - \hat{y}_{k|k-1}).$$

La covarianza aggiornata è

$$P_{k|k} = P_{k|k-1} - L_k \Sigma_y L_k^T.$$

Dove, nella notazione usata dal prof:

$$\Sigma_y = S_k$$

Predizione

Per propagare la stima si applica nuovamente la Trasformata Unscented.

Si considera il vettore

$$\begin{bmatrix} \hat{x}_{k|k} \\ 0 \end{bmatrix},$$

con matrice di covarianza

$$\begin{bmatrix} P_{k|k} & 0 \\ 0 & Q_k \end{bmatrix},$$

e lo si propaga attraverso il modello dinamico

$$f_k(\cdot).$$

La Trasformata Unscented restituisce direttamente

$$\hat{x}_{k+1|k},$$

$$P_{k+1|k}.$$

In questa fase il momento incrociato non viene utilizzato.

Particle Filter

Il Particle Filter può essere visto come l'analogo dinamico del metodo Monte Carlo per la stima statica.

L'idea è quella di ricavare i momenti della distribuzione a posteriori mediante medie campionarie su "tanti" (N) campioni (particelle).

Si considerano N campioni

$$(x_i, w_i), \quad i = 1, \dots, N,$$

dove

- x_i è l' i -esima particella; - w_i è il peso associato.

La PDF (densità di probabilità) $p(x)$ viene quindi rappresentata mediante l'insieme

$$\{(x_i, w_i)\}_{i=1}^N.$$

Approssimazione della PDF

La distribuzione viene approssimata come

$$p(x) \simeq \sum_{i=1}^N w_i \delta(x - x_i),$$

dove $\delta(\cdot)$ è la delta di Dirac.

Media

La media della distribuzione vale

$$\bar{x} = \int x p(x) dx.$$

Utilizzando l'approssimazione precedente,

$$\begin{aligned} \bar{x} &\simeq \int x \sum_{i=1}^N w_i \delta(x - x_i) dx \\ &= \sum_{i=1}^N w_i \int x \delta(x - x_i) dx \\ &= \sum_{i=1}^N w_i x_i. \end{aligned}$$

Covarianza

La matrice di covarianza è

$$\Sigma_x = \int (x - \bar{x})(x - \bar{x})^T p(x) dx.$$

Sostituendo l'approssimazione della PDF,

$$\begin{aligned} \Sigma_x &\simeq \int (x - \bar{x})(x - \bar{x})^T \sum_{i=1}^N w_i \delta(x - x_i) dx \\ &= \sum_{i=1}^N w_i \int (x - \bar{x})(x - \bar{x})^T \delta(x - x_i) dx \\ &= \sum_{i=1}^N w_i (x_i - \bar{x})(x_i - \bar{x})^T. \end{aligned}$$

Aggiornamento della distribuzione a posteriori

L'approssimazione mediante particelle può essere utilizzata anche per rappresentare la distribuzione *a priori*

$$p_{k|k-1}(x) \simeq \sum_{i=1}^N w_{k|k-1}^{(i)} \delta(x - x_{k|k-1}^{(i)}).$$

L'obiettivo è determinare la distribuzione *a posteriori*, tenendo conto della misura y_k , ottenendone una nuova approssimazione mediante particelle

$$\left(x_{k|k}^{(i)}, w_{k|k}^{(i)} \right),$$

tale che

$$p_{k|k}(x) \simeq \sum_{i=1}^N w_{k|k}^{(i)} \delta\left(x - x_{k|k}^{(i)}\right).$$

Dalla formula di Bayes,

$$\begin{aligned} p_{k|k}(x) &= f_{X|Y}(x|y) \\ &= \frac{f_{Y|X}(y|x) f_X(x)}{\int f_{Y|X}(y|\zeta) f_X(\zeta) d\zeta} \\ &= \frac{f_{Y|X}(y_k|x) p_{k|k-1}(x)}{\int f_{Y|X}(y_k|\zeta) p_{k|k-1}(\zeta) d\zeta}. \end{aligned}$$

Sostituendo l'approssimazione particellare della distribuzione a priori,

$$p_{k|k}(x) \simeq \frac{f_{Y|X}(y_k|x) \sum_{i=1}^N w_{k|k-1}^{(i)} \delta\left(x - x_{k|k-1}^{(i)}\right)}{\int f_{Y|X}(y_k|\zeta) \sum_{i=1}^N w_{k|k-1}^{(i)} \delta\left(\zeta - x_{k|k-1}^{(i)}\right) d\zeta}.$$

Applicando la proprietà della delta di Dirac,

$$p_{k|k}(x) \simeq \frac{\sum_{i=1}^N w_{k|k-1}^{(i)} f_{Y|X}\left(y_k \mid x_{k|k-1}^{(i)}\right) \delta\left(x - x_{k|k-1}^{(i)}\right)}{\sum_{i=1}^N w_{k|k-1}^{(i)} f_{Y|X}\left(y_k \mid x_{k|k-1}^{(i)}\right)}.$$

Si osserva quindi che:

$$x_{k|k}^{(i)} = x_{k|k-1}^{(i)},$$

ossia la fase di aggiornamento non modifica la posizione delle particelle, ma solamente i loro pesi.

Infatti,

$$w_{k|k}^{(i)} = \frac{w_{k|k-1}^{(i)} f_{Y|X}\left(y_k \mid x_{k|k-1}^{(i)}\right)}{\sum_{j=1}^N w_{k|k-1}^{(j)} f_{Y|X}\left(y_k \mid x_{k|k-1}^{(j)}\right)}.$$

I nuovi pesi sono quindi ottenuti normalizzando il prodotto tra il peso a priori e la likelihood della misura.

Correzione

La fase di correzione aggiorna le particelle utilizzando la nuova misura

$$(k|k-1) \longrightarrow (k|k),$$

attraverso il modello di misura

$$h_k(\cdot).$$

Le particelle non vengono spostate:

$$x_{k|k}^{(i)} = x_{k|k-1}^{(i)}.$$

Vengono invece aggiornati i pesi

$$w_{k|k}^{(i)} = w_{k|k-1}^{(i)} f_{Y|X}\left(y_k \mid x_{k|k-1}^{(i)}\right),$$

seguiti da una normalizzazione in modo che

$$\sum_{i=1}^N w_{k|k}^{(i)} = 1.$$

Predizione

La fase di predizione propaga le particelle dal tempo k al tempo $k+1$

$$(k|k) \longrightarrow (k+1|k),$$

attraverso il modello dinamico

$$f_k(\cdot).$$

Ogni particella evolve secondo

$$x_{k+1|k}^{(i)} = f_k\left(x_{k|k}^{(i)}, w_k^{(i)}\right),$$

dove

$$w_k^{(i)} \sim \mathcal{WN}(0, Q_k)$$

è un campione del rumore di processo.

Durante la predizione i pesi non vengono modificati,

$$w_{k+1|k}^{(i)} = w_{k|k}^{(i)}.$$

Inizializzazione

Lo stato iniziale è assunto distribuito come

$$x_0 \sim (\hat{x}_0, P_0).$$

L'insieme iniziale delle particelle si ottiene campionando N volte dalla distribuzione iniziale,

$$x_0^{(i)} \sim (\hat{x}_0, P_0), \quad i = 1, \dots, N,$$

assegnando inizialmente a tutte lo stesso peso

$$w_0^{(i)} = \frac{1}{N}, \quad i = 1, \dots, N.$$

21.1 recap Filtraggio non lineare

$$\begin{cases} x_{k+1} = f_k(x_k, w_k) \\ y_k = h_k(x_k, v_k) \end{cases}$$

Si assumono le consuete ipotesi sulle distribuzioni.

Metodi principali:

$$\boxed{\text{EKF} \quad \text{UKF} \quad \text{PF}}$$

21.2 Particle Filter (PF)

Inizializzazione Lo stato iniziale

$$x_0 \sim (\hat{x}_0, P_0)$$

viene approssimato mediante un numero elevato N di campioni (particelle), ciascuno con peso iniziale uniforme

$$W = \frac{1}{N}.$$

L'insieme iniziale delle particelle è

$$\left\{ \left(x_{1|0}^{(i)}, W_{1|0}^{(i)} \right) \right\}_{i=1}^N.$$

Correzione Passaggio

$$k|k-1 \xrightarrow{y_k} k|k,$$

utilizzando la misura y_k e la funzione di osservazione $h_k(\cdot)$.

Le particelle non vengono spostate:

$$x_{k|k}^{(i)} = x_{k|k-1}^{(i)}.$$

I pesi vengono aggiornati tramite la likelihood della misura

$$W_{k|k}^{(i)} = W_{k|k-1}^{(i)} f_{Y|X} \left(y_k \mid x_{k|k-1}^{(i)} \right),$$

e successivamente normalizzati.

Predizione Passaggio

$$k|k \longrightarrow k+1|k,$$

utilizzando il modello dinamico $f_k(\cdot)$.

Ogni particella viene propagata come

$$x_{k+1|k}^{(i)} = f_k\left(x_{k|k}^{(i)}, w_k^{(i)}\right),$$

dove

$$w_k^{(i)}$$

è una **realizzazione del rumore di processo** (*non* il peso della particella).

Durante la predizione i pesi rimangono invariati:

$$W_{k+1|k}^{(i)} = W_{k|k}^{(i)}.$$

21.3 Ricampionamento (Resampling)

Nel filtro SIR-PF (*Sequential Importance Resampling*) si esegue un ricampionamento dopo la fase di correzione.

$$\left(x_{k|k}^{(i)}, W_{k|k}^{(i)}\right) \longrightarrow \left(\tilde{x}_{k|k}^{(i)}, \tilde{W}_{k|k}^{(i)}\right)$$

dove le nuove particelle vengono estratte secondo la distribuzione dei pesi:

$$\tilde{x}_{k|k}^{(i)} = x_{k|k}^{(j)} \quad \text{con probabilità} \quad W_{k|k}^{(j)}.$$

Una stessa particella può quindi essere estratta più volte, mentre altre possono non essere selezionate.

Dopo il ricampionamento tutti i pesi vengono riportati a valori uniformi:

$$\tilde{W}_{k|k}^{(i)} = \frac{1}{N}$$

Nella fase di predizione i pesi rimangono invariati:

$$W_{k+1|k}^{(i)} = \frac{1}{N}.$$

Alla successiva correzione essi vengono nuovamente aggiornati mediante la likelihood della misura:

$$W_{k+1|k+1}^{(i)} = W_{k+1|k}^{(i)} f_{Y|X}\left(y_{k+1} \mid x_{k+1|k}^{(i)}\right).$$

I pesi rappresentano quindi la **verosimiglianza** delle particelle rispetto alla misura osservata.

Alternativa al ricampionamento continuo Invece di ricampionare ad ogni iterazione, si può stimare il numero effettivo di particelle che contribuiscono realmente alla stima:

$$N_{\text{eff}} = \frac{1}{\sum_{i=1}^N \left(W_{k|k}^{(i)}\right)^2}$$

e ricampionare solamente quando N_{eff} scende sotto una determinata soglia.

Caso limite Se tutte le particelle contribuiscono allo stesso modo,

$$W_{k|k}^{(i)} = \frac{1}{N}, \quad \forall i,$$

allora

$$N_{\text{eff}} = \frac{1}{N \left(\frac{1}{N}\right)^2} = N.$$

In questo caso tutte le particelle hanno la stessa importanza e il ricampionamento non è necessario.

Caso limite Se una sola particella possiede peso unitario

$$W^{(i)} = 1,$$

mentre tutte le altre hanno peso nullo,

$$W^{(j)} = 0, \quad j \neq i,$$

allora

$$N_{\text{eff}} = 1.$$

Pertanto si calcola il rapporto

$$\frac{N_{\text{eff}}}{N}$$

e lo si confronta con una soglia prefissata per decidere se effettuare il ricampionamento.

Riferimento:

Arulampalam et al., *A Tutorial on Particle Filters for Online Nonlinear/Non-Gaussian Bayesian Tracking*, IEEE Transactions on Signal Processing, 2002.

Con questo si conclude la parte dedicata al filtraggio.

Si passa quindi al problema della regolarizzazione (*smoothing*), cioè alla stima dello stato utilizzando anche misure future.

$$k|n, \quad n > k.$$

Riferimento classico:

Rauch, Tung e Striebel (1965).

21.4 Rauch–Tung–Striebel Smoother

L'algoritmo è composto da due fasi.

1. Passata in avanti Si esegue un normale filtro di Kalman (oppure EKF), ottenendo per ogni istante

$$\hat{x}_{k|k}, \quad P_{k|k},$$

e successivamente la predizione

$$\hat{x}_{k+1|k}, \quad P_{k+1|k},$$

per

$$k = 1, \dots, n.$$

Nel caso dell'EKF la matrice

$$F_k$$

è la matrice del modello (Jacobiana della dinamica).

2. Passata all'indietro Si procede dall'istante finale verso quello iniziale

$$n \longrightarrow 1.$$

Si introduce il guadagno di smoothing

$$C_k = P_{k|k} F_{k+1}^T P_{k+1|k}^{-1}$$

e si aggiorna la stima secondo

$$\hat{x}_{k|n} = \hat{x}_{k|k} + C_k (\hat{x}_{k+1|n} - \hat{x}_{k+1|k}).$$

La covarianza associata alla stima smoothed viene aggiornata come

$$P_{k|n} = P_{k|k} + C_k (P_{k+1|n} - P_{k+1|k}) C_k^T$$

dove il termine

$$P_{k+1|n} - P_{k+1|k}$$

rappresenta il miglioramento ottenuto sulla covarianza grazie all'utilizzo delle misure future.

L'algoritmo procede ricorsivamente all'indietro:

$$n|n$$

(stima finale fornita dal filtro di Kalman)

$$\Downarrow$$

$$n-1|n$$

$$\Downarrow$$

$$n-2|n$$

$\Downarrow$

$\dots$

$\Downarrow$

$1|n.$

Aggiungere ultimi due esercizi